

Ingeniería de características y limpieza de datos

Cómo el Visa Bulletin crudo se convierte en un objetivo entrenable, decisión por decisión y con ledger vivo

Reporte automático generado con el boletín de septiembre 2026 — se rehace con cada boletín nuevo.

9

decisiones de FE documentadas

44→1

selección de características (FDR)

≤3 meses


tope de interpolación de huecos

58%

filas F entrenables

De HTML congelado a objetivo evaluable: 6 etapas, cero correcciones en silencio

Cada etapa publica su ledger: los ceros son inalcanzables por construcción (guardias que abortan el build) y lo anómalo se anota, jamás se recorta.



Decisiones magistrales de limpieza (1 de 2)

Las 12 decisiones que blindan el dato crudo; cada una vive en código citado, no en prosa suelta.

1 Régimen C/F/U/UNK como anotación, F como único objetivo

`vp_data/visa_common.py:classify_status`

Aplanar C→fecha y U→NaN destruía el régimen administrativo. La columna status lo preserva; solo las celdas F (fecha específica) son objetivo predictivo (formulación v5.1) y la evaluación enmascara todo lo demás (B1).

2 Centinela UNK (nunca el string NA)

`vp_data/visa_common.py:classify_status`

El literal 'NA' colisiona con la coerción por defecto de `pandas.read_csv` (lo lee como NaN) y borraba la anotación. UNK distingue 'sin dato' de 'Unavailable' y sobrevive a cualquier consumidor downstream.

3 Pivote de siglo con guardia de época

`vp_data/visa_common.py:string_to_datetime`

Las celdas publican años de 2 dígitos ('01MAY16'); `strptime` pivota 69..99→19xx. Una fecha F anterior a `t0=1975` haría `days_since_base` negativo: `build_panel` aborta (underflow) y el CHECK `days_is_datediff` del almacén re-verifica la aritmética completa.

4 Tolerancia a erratas y notas de la fuente

`vp_data/visa_common.py:string_to_datetime/classify_status`

20 años de boletines traen footnotes (C*/U*), espacios y erratas ('4rd'). El parser normaliza sin descartar el mes; lo imparseable queda UNK con su `raw_value` intacto (nada se corrige en silencio: la celda cruda se conserva).

5 Deduplicación por preferencia de régimen F>C>U>UNK

`pipeline/build_panel.py:main`

En transiciones de etiqueta (p.ej. EB-5 'Unreserved' 2022) una categoría canónica aparece dos veces el mismo mes. 'first' era una moneda al aire que podía tirar una observación F entrenable; se prefiere F y se ABORTA si dos F del mismo mes discrepan (conflicto de fuente que resuelve un humano).

6 Fechas imparseables abortan en la causa

`pipeline/build_panel.py:main`

Una fecha F coercionada a NaT violaría `days_iff_F` lejos de su causa (en el CHECK del almacén); un `bulletin_date` NaT viajaría hasta el merge de `dim_date`. Ambos abortan en `build_panel` con las filas culpables (AA3).

Decisiones magistrales de limpieza (2 de 2)

Las 12 decisiones que blindan el dato crudo; cada una vive en código citado, no en prosa suelta.

7 Dominios de categoría validados al leer

`pipeline/build_panel.py:load_employment/load_family`

`keep_default_na=False` protege el centinela UNK pero desactiva la coerción NA de todo el frame; un literal extraño en `F_level/EB_level` pasaría como string. El dominio se valida explícitamente tras cada `read_csv` (AA4).

8 Huecos de entrenamiento: relleno CAUSAL (LOCF), jamás puntuado

`vp_model/preprocess.py:to_regular_monthly_causal` · `vp_model/models.py:to_timeseries`

Los huecos son meses C/U (MNAR: la ausencia es señal). La rejilla de modelado se rellena hacia adelante con la última observación (LOCF, US-F1): el valor de un mes faltante usa SOLO observaciones anteriores, así ningún origen del walk-forward ve el bracket futuro del hueco (la interpolación lineal bidireccional previa filtraba el futuro al pasado). El relleno da continuidad al entrenamiento — jamás es objetivo: la evaluación puntúa únicamente fechas F reales (máscara B1, fuente única `metrics._aligned`) y los GBM reciben las máscaras MNAR para descontar el arrastre.

9 Caracterización EDA imputa con Kalman, nunca rampas sin tope

`vp_model/series_characterization.py:_clean` · `vp_model/missingness.py:kalman_impute`

STL/espectro/catch22 exigen series completas. Los huecos largos se imputan con suavizado de Kalman (espacio de estados, `imputeTS::na_kalman`), no con interpolación lineal multi-año ni extrapolación de bordes: una rampa inventada fabrica tendencia y contamina Hurst/changepoints/entropía (AB1).

10 Pruebas formales sobre las F crudas (con caveat de espaciado)

`experiments/build_eda_facts.py:_formal_tests`

ADF/KPSS/DF-GLS corren sobre las observaciones F sin imputar: imputar antes de una prueba de raíz unitaria sesga hacia 'integrada'. Costo aceptado y documentado: en series con huecos el índice queda comprimido y la estructura de rezagos asume espaciado regular (AB3).

11 Retrogresiones = señal; outliers se cuentan, jamás se recortan

`vp_model/series_characterization.py:count_outliers` · `pipeline/mega_audit.py:d9_jumps`

Las retrogresiones y saltos >8 años son eventos administrativos reales que el modelo debe tolerar (la tesis lo argumenta). Ningún paso winsoriza ni elimina valores extremos del dato; solo se CUENTAN con estadísticos robustos (z-STL, Hampel) y las figuras anotan lo que quede fuera de rango en vez de recortarlo en silencio (AC1/AC2).

12 El contrato se re-verifica declarativamente en el almacén

`schema.sql:days_iff_F/pdate_iff_F/days_is_datediff/rank_iff_F`

Las invariantes de limpieza no viven solo en Python: los CHECK/PK/FK del esquema estrella rechazan en la carga cualquier fila que las viole, con el nombre exacto de la invariante rota.

Decisiones magistrales de FE (1 de 3)

Las 9 transformaciones que convierten fechas administrativas en regresores sin fuga.

1 Objetivo = días desde t0 (1975-01-01), solo estado F

`pipeline/build_panel.py · schema.sql:days_is_datediff`

La fecha de prioridad se convierte a un entero de días desde una época fija anterior a la prioridad más antigua observada (1979-11, Filipinas F4). Un objetivo numérico continuo, con contrato aritmético re-verificado en el almacén, en lugar de fechas crudas imposibles de regresar.

2 Rejilla mensual regular con relleno causal (LOCF)

`vp_model/preprocess.py:to_regular_monthly_causal`

Los modelos exigen índice regular; los meses C/U no son objetivo. Cada hueco se rellena hacia adelante con la última observación (LOCF): el valor de un mes faltante usa SOLO observaciones anteriores, de modo que ningún origen del walk-forward ve el bracket futuro del hueco (US-F1; la interpolación lineal bidireccional previa filtraba el futuro al pasado). El relleno de continuidad jamás se puntúa (máscara F-only B1).

3 Máscaras MNAR (observed, months_since_obs) como covariables de los GBM

`vp_model/missingness.py:masking_features · vp_model/config.py:MASK_COVARIATES`

La ausencia es señal (MNAR): los árboles diferenciados reciben la máscara de observación y los meses desde la última observación con retardo -1 (el último mes CERRADO, conocido en el origen; el régimen del mes objetivo no se conoce antes de publicarse el boletín y dárselo a retardo 0 sería fuga). Así el modelo puede descontar los tramos arrastrados por el LOCF en lugar de tomarlos por fechas publicadas; los modelos sin covariables usan la política forward-only explícita del relleno causal (US-F1).

4 Árboles predicen la primera diferencia, no el nivel

`vp_model/models.py:Differenced · vp_model/preprocess.py:difference/undifference`

Un árbol no extrapola fuera del rango visto: sobre el nivel (tendencia creciente de décadas) se satura al máximo histórico. Modelar Δy mensual (estacionario) y reintegrar de forma causal (cumsum anclado al último nivel observado) resuelve la extrapolación gratis.

Decisiones magistrales de FE (2 de 3)

Las 9 transformaciones que convierten fechas administrativas en regresores sin fuga.

5 Calendario fiscal codificado cíclicamente (seno/coseno)

`vp_model/preprocess.py:calendar_features`

El año fiscal de visas arranca en octubre (las cuotas se reinician ahí). Codificar mes y posición fiscal con seno/coseno evita imponer un orden falso entre diciembre y enero — un entero 1..12 haría que el modelo viera esos meses vecinos como los más lejanos.

6 24 rezagos mensuales como memoria de los regresores

`vp_model/config.py:HYPERPARAMS['trees']/r'linear'`

Dos años de historia por origen: cubre un ciclo fiscal completo con margen y deja grados de libertad suficientes (series evaluables ≥ 84 F). Constante externalizada en config, no enterrada por modelo.

7 Escalado ajustado SOLO en la ventana inicial

`vp_model/feature_builder.py:fit_scaler`

Las redes torch operan mal sobre magnitudes de $\sim 18,000$ días. El Scaler se ajusta únicamente con la ventana de entrenamiento explícita y se invierte tras predecir: ajustarlo sobre la serie completa filtraría el futuro al pasado (leakage).

8 Política de covariables explícita por familia de modelo

`vp_model/config.py:COVARIATES`

Solo los árboles diferenciados reciben covariables: calendario a retardo 0 y máscaras MNAR a retardo -1 (US-F1); rlinear y las NN van conscientemente sin covariables. 'year' (monótona, no acotada sobre target diferenciado) fue RETIRADA en la re-campaña AQ del 4-jul-2026 (PENDIENTES #12).

Decisiones magistrales de FE (3 de 3)

Las 9 transformaciones que convierten fechas administrativas en regresores sin fuga.

9


Selección FRESH (FDR) + des-redundancia mRMR del catálogo

`vp_model/feature_select.py:select` · `experiments/build_fe_facts.py`

Con series de longitud corta (decenas a cientos de observaciones) cada grado de libertad cuenta. El conjunto unido de características de caracterización (catch22 + descriptores) se filtra por relevancia con corrección Benjamini-Yekutieli y se colapsa la colinealidad conservando una representante por grupo ($|\text{Spearman}| > 0.9$), contra la dificultad real de pronóstico de cada serie (MASE del campeón).

De HTML congelado a objetivo evaluable: 6 etapas, cero correcciones en silencio

Cada etapa publica su ledger: los ceros son inalcanzables por construcción (guardias que abortan el build) y lo anómalo se anota, jamás se recorta.




25 años de deriva de formato, normalizados a 4 regímenes

Cada fila llama al parser real (vp_data.visa_common) con la celda tal cual se publicó: nada se corrige en silencio y la celda cruda se conserva siempre en raw_value.

celda cruda		valor parseado	regla aplicada
01MAY16	F	2016-05-01	fecha exacta: strptime %d%b%y
080CT79	F	1979-10-08	pivote de siglo: %y 69-99 → 19xx (guardia anti-futuro contra el boletín)
15JUL05*	F	2005-07-15	footnote tolerado: se extrae el token de fecha y se valida con strptime
C	C	Current	Current — sin atraso ese mes; anotación descriptiva, no objetivo
U*	U	Unavailable	footnote tolerado también en el estado (U* → U)
(vacía)	UNK	sin dato	celda vacía → centinela UNK (nunca el string NA); raw_value se preserva


C y U son anotación, no objetivo: solo se puntúan las 235 fechas publicadas

India · EB-2 · FAD: la línea existe solo en los meses F; los fondos marcan el régimen del boletín (35 meses Current, 12 Unavailable, 16 sin dato). La franja inferior muestra los meses que la evaluación puntúa (máscara F-only).




Huecos de hasta 3 meses se interpolan; los 2 tramos largos jamás se inventan

México · EB4_RW (trabajadores religiosos) · FAD: 140 meses sin fecha en 22 corridas (la más larga, 105 meses). Las corridas cortas (≤ 3) se interpolan linealmente para la rejilla de entrenamiento; las largas quedan vacías y solo el EDA las caracteriza con suavizado de Kalman.




Los árboles no extrapolan: se les entrena sobre el avance mensual, no el nivel

Serie Resto del mundo · F2A · FAD: el nivel arrastra décadas de tendencia (un árbol se satura en el máximo visto); la primera diferencia es estacionaria y el pronóstico se reintegra de forma causal.




Diciembre y enero son vecinos: el calendario fiscal se codifica en círculo

Seno/coseno de la posición del mes en el año fiscal (arranca en octubre, cuando se reinician las cuotas), generados por el encoder canónico que consumen los modelos.




(b) Meses sobre el círculo unitario



La característica dominante: Avance en $t - 3$

Importancia por ganancia de un LightGBM entrenado sobre el avance mensual de las series familiares FAD (rezagos del avance + calendario cíclico).



Fuente: U.S. Department of State, Visa Bulletin (dic 2001 - septiembre 2026).

Ledger de limpieza del corte vigente

Publicado por pipeline/build_panel.py en cada build; el reporte lo re-lee, no lo re-calcula.

corte del panel	2026-09
filas del panel	27,911
series estructurales	194
filas F (fecha publicada)	16,117
filas C (Current)	11,168
filas U (Unavailable)	625
filas UNK (sin dato)	1
duplicados colapsados (preferencia F>C>U>UNK)	0
fechas de boletín imparseables	0
fechas F imparseables	0
desbordes de época (fecha F < t0)	0
saltos >8 años (anotados, no recortados)	14

Por qué los ceros son ceros

Los ceros del ledger no son suerte: son inalcanzables por construcción. Una fecha F imparseable o un desborde de época ABORTAN el build en la causa (build_panel), y el almacén estrella re-verifica el contrato con CHECKs declarativos (days_iff_F, pdate_iff_F, days_is_datediff). Los 14 saltos >8 años sí existen: son eventos administrativos reales que el modelo debe tolerar — se anotan en la auditoría, jamás se recortan del dato.

Selección de características: 44 → 1 → 1

FRESH (relevancia con FDR Benjamini-Yekutieli, $\alpha=0.05$) + des-redundancia mRMR ($|\text{Spearman}|>0.9$) sobre 50 series con campaña canónica.



La superviviente

DN_OutlierInclude_p_001_mdrmd

Variable objetivo de la selección

hold-out MASE del campeón por serie (elegido con sel_mase; campaign pool canónico)

Lectura honesta

Con 50 series efectivas y 44 candidatas, la corrección por FDR deja UNA sola característica de caracterización asociada de forma robusta a la dificultad de pronóstico. El catálogo completo se conserva como herramienta descriptiva del EDA; NO entra como covariable a los modelos.

Notas metodológicas y linaje

Fuente única

Todas las cifras de este reporte provienen de `reports/fe/fe_facts.json` (generado por `experiments/build_fe_facts.py`, versión de builder v2.0.0) y del panel `data/processed/visa_panel_long.csv`. Ninguna cifra visible está escrita a mano.

Código citado

Cada decisión referencia su módulo vivo: `vp_model/feature_builder.py` (FE_DECISIONS, FE_VERSION), `vp_data/cleaning.py` (CLEANING_DECISIONS + ledger), `vp_model/preprocess.py` (huecos, diferenciación, calendario) y `vp_data/visa_common.py` (parser). El detalle narrativo vive en `docs/CLEANING.md`.

Figuras

Las figuras f01-f07 se insertan como la MISMA figura viva de `experiments/make_fe_figures.py` en vector (cero re-rasterización); la galería PNG bilingüe (claro/oscuro) que consume el web sale del mismo script.

Reproducibilidad

`make fe-all` (fe-facts + fe-figures + fe-report) en el pipeline público github.com/UACJ-MIAAD/VisaPredictAI. Se regenera automáticamente con cada boletín nuevo; el gate de vintage aborta si el catálogo va detrás del panel.

Aviso

Documento académico y demostrativo (UACJ · MIAAD). No constituye asesoría migratoria ni predicción oficial.