UNIVERSIDAD AUTÓNOMA DE CIUDAD JUÁREZ

Instituto de Ingeniería y Tecnología

Departamento de Ingeniería Eléctrica y Computación

Maestría en Inteligencia Artificial y Analítica de Datos

Predicción de fechas de prioridad en el Visa Bulletin de Estados Unidos considerando país o área de cargabilidad, categoría migratoria y tipo de tabla

Proyecto de innovación presentado por:

Javier Augusto Rebull Saucedo Matrícula 263483

Requisito para la obtención del título de

Maestro(a) en Inteligencia Artificial y Analítica de Datos

Asesor (es)

Dr. Vicente García Jiménez

Ciudad Juárez, Chihuahua Octubre de 2026

A13 Avance acumulativo

Contenido

1 Desarrollo de la propuesta de solución

1.1 Recolección de datos

1.1.1 Identificación de fuentes de datos

1.1.2 Obtención de los datos y conversión al formato adecuado

1.2 Análisis de datos

1.2.1 Análisis exploratorio de datos

1.2.2 Preprocesamiento de datos

1.3 Diseño del modelo

1.3.1 Definición de las técnicas de modelado

1.3.2 Arquitectura general del sistema y flujo de trabajo

1.4 Desarrollo

1.4.1 Implementación del modelo

1.4.2 Ajustes al modelo con diferentes configuraciones

1.4.3 Evaluación del modelo

1.4.4 Optimización de parámetros y pruebas avanzadas

Este avance reúne el desarrollo de la propuesta y la actividad indicada. Sus resultados científicos corresponden al panel hasta septiembre de 2026; la versión extensa de la investigación se conserva en el documento académico principal.

1 Desarrollo de la propuesta de solución

VisaPredict AI integra un archivo mensual del Visa Bulletin, una evaluación reproducible de pronósticos y un portal público. La variable de interés es la fecha de prioridad publicada para una combinación de país o área de cargabilidad, categoría migratoria y tabla. El producto ayuda a examinar su trayectoria y la incertidumbre de un pronóstico; no determina elegibilidad migratoria ni sustituye la información oficial.

Este documento deriva del desarrollo académico principal y del corte científico 2026-09-805d624d2ecf, publicado antes de preparar estas actividades. Los resultados corresponden al panel hasta septiembre de 2026. La recepción del boletín de octubre constituye una actualización operativa independiente y no convierte sus observaciones en una nueva evaluación retrospectiva. El resultado principal es que ningún modelo entrenado supera con significancia al naïve-1 a un paso en el protocolo estudiado.

1.1 Recolección de datos

La recolección conserva la procedencia de cada boletín y distingue una fuente inaccesible de un mes que aún no se ha publicado. El archivo congelado permite repetir la extracción sin consultar de nuevo la página, y el panel largo conserva la identidad de cada observación.

1.1.1 Identificación de fuentes de datos

La fuente primaria es el Visa Bulletin mensual del Departamento de Estado de Estados Unidos [1]. Se utilizan las tablas de preferencias familiares y de empleo, separadas en fechas de acción final (FAD) y fechas para presentar documentación (DFF). Las fechas representan umbrales administrativos, no tiempos de resolución individuales. El estado C indica disponibilidad corriente y U indisponibilidad; ninguno debe confundirse con una fecha observada.

El corte reúne 27,911 observaciones, 298 meses y 194 series estructurales entre 2001-12 y 2026-09. Hay 136 series con alguna fecha y 74 evaluables bajo los criterios del experimento. Estos universos son distintos: una combinación estructural puede existir aunque no tenga longitud suficiente para entrenar o evaluar un modelo.

1.1.2 Obtención de los datos y conversión al formato adecuado

El flujo conserva una instantánea por mes, extrae las cuatro combinaciones bloque por tabla y normaliza países, categorías y fechas. La representación intermedia se guarda en CSV; el panel largo añade estado, fecha de prioridad y días desde una época fija. DuckDB ofrece una copia analítica regenerable con dimensiones y hechos, mientras JSON alimenta el portal y el índice del asistente.

El acceso automatizado a la fuente ha encontrado un cortafuegos de aplicación. Por ello se mantiene una vía de captura manual validada: el contenido debe corresponder al mes declarado, contener las matrices esperadas y superar el mínimo de completitud antes de congelarse. Un archivo de bloqueo o una tabla incompleta se rechaza. La vía manual no autoriza sobrescribir una instantánea previa ni presentar una fecha de descarga como fecha de publicación del boletín.

1.2 Análisis de datos

El análisis exploratorio identifica propiedades que condicionan el diseño temporal: periodos congelados, saltos, retrocesos y cambios entre fecha, disponibilidad corriente e indisponibilidad. Las decisiones de preparación se documentan por su efecto sobre la información disponible en cada origen.

1.2.1 Análisis exploratorio de datos

El censo registra 382 retrogresiones y un 45 % de meses congelados. La persistencia elevada explica por qué repetir la última fecha es una referencia exigente. Las distribuciones y longitudes difieren por tabla y categoría; no se agregan como si todas las series fueran intercambiables.

En la caracterización de series se evaluaron 44 descriptores candidatos. Con el protocolo y control de falsos descubrimientos establecidos, 0 asociaciones superaron el umbral sobre 50 series. Este resultado no demuestra ausencia de señal ni superioridad de un conjunto de características: los modelos comparados no consumen esos descriptores. La selección estadística del catálogo y las variables de entrada de los predictores son procesos distintos.

1.2.2 Preprocesamiento de datos

La preparación vigente utiliza relleno causal con la última observación disponible y máscaras de ausencia. Nunca interpola con un extremo futuro respecto del origen de pronóstico. La normalización, la escala de MASE y las características temporales se obtienen únicamente del tramo de entrenamiento. Los valores imputados ayudan a construir entradas, pero la puntuación se limita a meses con fecha real publicada.

Los árboles predicen el avance mensual y después reconstruyen el nivel de la fecha. Se incorporan rezagos y calendario cíclico; el boletín siguiente y sus variables derivadas permanecen fuera de las entradas. Los estados C y U se conservan como anotaciones. Convertirlos en una fecha arbitraria o puntuar el relleno como objetivo real produciría una mejora ficticia.

1.3 Diseño del modelo

La solución separa el repertorio experimental del campeón desplegado. El primero permite comparar modelos bajo un protocolo común; el segundo genera una receta operativa verificable. Un resultado de selección o una recomendación retrospectiva no autoriza por sí solos una promoción.

1.3.1 Definición de las técnicas de modelado

El repertorio considera 24 modelos que incluyen persistencia, tendencia, métodos autorregresivos, suavizamiento exponencial, árboles y redes para series temporales. Los métodos parsimoniosos permiten comprobar cuánto aporta la complejidad. El naïve-1 conserva el último valor; los demás deben justificar su costo frente a esa referencia y a la escala estacional [2].

La selección contempla error, incertidumbre, estabilidad y disponibilidad de resultados por serie. Las redes globales comparten información entre series compatibles; los métodos locales se ajustan a cada una. Estas estrategias pueden aportar ventajas en horizontes distintos y no deben confundirse con una mejora uniforme en todas las tablas.

1.3.2 Arquitectura general del sistema y flujo de trabajo

El flujo enlaza captura y validación de la fuente, panel y base analítica, preparación causal, entrenamiento y evaluación, artefactos de gobierno y consumidores. Las salidas viajan en un manifiesto con hashes y un identificador de corte. El portal verifica esos bytes antes de servirlos; la tarjeta del modelo y el índice del asistente se construyen desde el mismo corte.

La infraestructura combina Git para código, DVC y almacenamiento de objetos para datos y artefactos, DuckDB para consulta, Python para el pipeline y Next.js para el portal. CI aplica contratos, consistencia, tipos y pruebas. La revisión humana requerida para publicar una

campaña se mantiene separada de la ejecución automatizada. El archivo histórico y las campañas fallidas se conservan como evidencia, no se reemplazan para presentar un resultado favorable.

1.4 Desarrollo

La implementación se organizó como incrementos verificables. La preparación y el protocolo se congelaron antes del cómputo causal; posteriormente se corrigieron consumidores y se reconciliaron resultados, figuras y prosa. Cada actividad de esta sección describe evidencia existente, sin atribuirse entrenamientos nuevos durante su redacción.

1.4.1 Implementación del modelo

El código separa catálogo, fábricas de modelos, construcción de conjuntos temporales, evaluación por origen y exportación de hechos. Los modelos clásicos se reajustan en cada origen; el entrenamiento de las redes se controla mediante un calendario explícito de reajuste. Los hiperparámetros, semillas, entradas y salidas se registran para identificar cada corrida.

La implementación protege la frontera entre selección y conjunto reservado. Las omisiones por convergencia se declaran y la agregación conserva sus poblaciones. Los recibos de campaña y complementarias acreditan procedencia; la reconciliación evita mezclar salidas nuevas con recibos antiguos. Los consumidores rechazan cifras que carezcan de la acreditación exigida, en lugar de dibujarlas por la mera presencia de un archivo.

1.4.2 Ajustes al modelo con diferentes configuraciones

Las configuraciones se compararon por grupos que tienen una interpretación técnica: representación de la variable objetivo, complejidad del predictor, rezagos y calendario, regularización y forma de reajuste. En los métodos clásicos se contrastaron persistencia, tendencia amortiguada y componentes autorregresivos. En los árboles se exploraron

capacidad, tasa de aprendizaje y submuestreo. En las redes se modificaron tamaño oculto, regularización y arquitectura.

Los datos de selección son anteriores a los 24 meses reservados. Las ventanas iniciales son de 60 meses para FAD y 36 para DFF; los modelos clásicos se reajustan con información pasada en cada origen. Las redes se reajustan cada doce meses bajo el compromiso documentado de costo y evaluación. Una ventana más grande o un modelo más profundo no se acepta por intuición, sino por el resultado en la región correspondiente.

En FAD familiar, el MASE medio es 0.157 para naïve-1, 0.167 para ETS y 0.171 para Theta. La comparación descriptiva no favorece a los modelos más complejos. Debe leerse junto a los contrastes pareados y la cobertura de cada modelo; medias de poblaciones diferentes no constituyen por sí solas un experimento controlado.

En DFF, BiTCN tiene media 0.122 frente a 0.125 del naïve-1. La diferencia es descriptiva: no se presenta como superioridad significativa frente a ese piso. El contraste DM documentado de BiTCN corresponde a ARIMA y no puede trasladarse a otra pareja de modelos.

La corrección del relleno y el cambio de tramo evaluado ocurrieron juntos en la re-derivación causal. Por tanto, la diferencia respecto de una versión histórica no identifica el efecto aislado del relleno ni de una arquitectura. El criterio final conserva la receta validada y exige evidencia prospectiva para cualquier promoción. El hallazgo útil del ajuste es reconocer cuándo una variante no justifica su complejidad.

Tabla 1 Ajustes al modelo con diferentes configuraciones

Configuración	Variable modificada	Lectura del resultado
Métodos clásicos	Persistencia, tendencia y estructura temporal	La referencia naïve-1 sigue siendo exigente a un mes.
Árboles	Rezagos, profundidad y regularización	La selección ocurre antes del conjunto reservado.
Redes globales	Arquitectura, capacidad y semillas	La variabilidad y el costo se documentan.
Preparación causal	Relleno y máscaras de ausencia	No se atribuye el cambio histórico a una sola intervención.

1.4.3 Evaluación del modelo

La tarea principal es pronosticar una fecha o su avance, por lo que las métricas de clasificación no son el criterio primario. Precisión, recall y F1 sólo serían pertinentes si se definiera otra tarea sobre estados; no se inventan para completar una rúbrica. MAE resume error en días y facilita interpretar la magnitud. RMSE penaliza con mayor intensidad errores extremos. sMAPE expresa error relativo, con cautela cuando el avance está cerca de cero.

MASE normaliza por un error ingenuo calculado en el entrenamiento [2]. Se informa la escala estacional y, cuando corresponde, la escala naïve-1. Un valor menor que uno respecto de la escala estacional no demuestra que se haya superado al naïve-1 fuera de muestra. Para concluir eso se necesitan los mismos objetivos observados, el tamaño del efecto y el contraste adecuado.

El agregado prospectivo contiene 2,944 pronósticos puntuados: MAE 146 días, MASE 0.347 y cobertura empírica al 95 % de 92 %. Reúne ambas tablas y horizontes de uno a doce meses. No es la métrica del campeón FAD a un paso ni debe dividirse entre esa cifra para afirmar una degradación comparable.

La incertidumbre se evalúa mediante cobertura, amplitud y CRPS [6]. La cobertura sola puede mejorar ensanchando indefinidamente los intervalos, por lo que se examina junto con su utilidad. El CRPS se calcula con un protocolo de muestras y semilla declarado; la repetibilidad del cálculo no elimina su error Monte Carlo. Los intervalos de evaluación se distinguen de los usados para calibrar.

Los resultados se desagregan por tabla, población y horizonte. Las fechas imputadas, los estados C/U y las omisiones de convergencia no se convierten en objetivos reales. Las pruebas de Diebold–Mariano y las correcciones múltiples complementan la comparación descriptiva [4, 5]; ausencia de significancia no equivale a equivalencia entre modelos.

Tabla 2 Evaluación del modelo

Indicador	Interpretación	Precaución
MAE	Magnitud del error en días	Agregación dependiente de población y horizonte.
RMSE	Mayor penalización de errores grandes	No atribuir una mejora a todos los casos.
MASE	Error respecto de una escala del entrenamiento	La escala estacional no es un contraste OOS contra naïve-1.
Cobertura y amplitud	Incertidumbre empírica del intervalo	Separar calibración de evaluación.
CRPS	Calidad de la distribución predictiva	Declarar muestreo, semilla y procedencia.

1.4.4 Optimización de parámetros y pruebas avanzadas

La búsqueda de hiperparámetros utiliza Optuna con muestreo TPE y poda por mediana [3]. Los parámetros internos los aprende el modelo; los hiperparámetros establecen su capacidad y su entrenamiento. La tasa de aprendizaje se explora en escala logarítmica y el espacio incluye profundidad, rezagos, submuestreo y regularización. Los estudios persistentes permiten auditar configuraciones ensayadas y descartadas.

El protocolo separa entrenamiento, una cola de ajuste de 24 meses y una cola de confirmación de doce meses dentro de la región de selección. La búsqueda ve la cola de ajuste; la decisión se verifica sobre confirmación. Los 24 meses finales reservados quedan fuera de ambas decisiones. Este anidamiento importa más que aumentar indiscriminadamente el presupuesto de búsqueda.

El resumen canónico declara 12 grupos y 9 aceptaciones de ajuste, repartidas en 5 familiares y 4 de empleo. Son aceptaciones dentro del protocolo de optimización, no victorias

significativas en el conjunto reservado ni permisos de promoción. Las configuraciones por defecto se conservan cuando resultan preferibles por serie.

El registro distingue el presupuesto de ensayos, los intentos podados y los resultados completos. Una mejora del valor objetivo no basta: se examinan la mediana, la proporción de series que mejoran, la estabilidad y el costo computacional. No se afirma que todo ensayo configurado haya completado el mismo entrenamiento ni se suman épocas como si fueran observaciones independientes.

Las pruebas avanzadas incluyen evaluación multi-horizonte, repeticiones con semillas controladas y cohortes pre-registradas. Se mantienen límites explícitos: un cambio en el flujo de semillas no cuantifica por sí mismo el error de muestreo; una repetición de bytes confirma reproducibilidad del cálculo, no certeza estadística. Las decisiones finales se justifican con la evidencia adecuada a cada pregunta.

Referencias

[1] U.S. Department of State, “Visa Bulletin,” Bureau of Consular Affairs. Fuente primaria: travel.state.gov/content/travel/en/legal/visa-law0/visa-bulletin.html.

[2] R. J. Hyndman y A. B. Koehler, “Another look at measures of forecast accuracy,” International Journal of Forecasting, vol. 22, no. 4, pp. 679–688, 2006.

[3] T. Akiba et al., “Optuna: A next-generation hyperparameter optimization framework,” Proc. ACM SIGKDD, pp. 2623–2631, 2019.

[4] F. X. Diebold y R. S. Mariano, “Comparing predictive accuracy,” Journal of Business & Economic Statistics, vol. 13, no. 3, pp. 253–263, 1995.

[5] J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” Journal of Machine Learning Research, vol. 7, pp. 1–30, 2006.

[6] T. Gneiting y A. E. Raftery, “Strictly proper scoring rules, prediction, and estimation,” Journal of the American Statistical Association, vol. 102, no. 477, pp. 359–378, 2007.

Procedencia de las cifras

Corte científico 2026-09-805d624d2ecf; datos main 6ff06fd, con artefactos de evaluación y hechos versionados. Autoridad académica: ProyectoI_VisaPredictAI.tex, repositorio UACJ-MIAAD/VisaPredictAI_LaTeX. Los metadatos de producción pueden cambiar por un build sin que cambie la añada científica.