UNIVERSIDAD AUTÓNOMA DE CIUDAD JUÁREZ

Instituto de Ingeniería y Tecnología

Departamento de Ingeniería Eléctrica y Computación

Maestría en Inteligencia Artificial y Analítica de Datos

PREDICCIÓN DE FECHAS DE PRIORIDAD EN EL VISA BULLETIN DE ESTADOS UNIDOS CONSIDERANDO PAÍS O ÁREA DE CARGABILIDAD, CATEGORÍA MIGRATORIA Y TIPO DE TABLA

Proyecto de innovación presentado por:

Javier Augusto Rebull Saucedo Matrícula 263483

Requisito para la obtención del título de

Maestro(a) en Inteligencia Artificial y Analítica de Datos

Asesor (es)

Dr. Vicente García Jiménez

Ciudad Juárez, Chihuahua Octubre de 2026

Índice de contenido

1 Desarrollo de la propuesta de solución....4
1.1 Recolección de datos....4
1.1.1 Identificación de fuentes de datos....4
1.1.2 Obtención de los datos y conversión al formato adecuado....5
1.2 Análisis de datos....5
1.2.1 Análisis exploratorio de datos....6
1.2.2 Preprocesamiento de datos....6
1.3 Diseño del modelo....7
1.3.1 Definición de las técnicas de modelado....7
1.3.2 Arquitectura general del sistema y flujo de trabajo....7
1.4 Desarrollo....8
1.4.1 Implementación del modelo....8
1.4.2 Ajustes al modelo con diferentes configuraciones....8
1.4.3 Evaluación del modelo....10
1.4.4 Optimización de parámetros y pruebas avanzadas....12
Referencias....14
Apéndice....15

Índice de figuras

Este avance no incluye figuras; las figuras del proyecto se encuentran en el documento académico principal.

Índice de tablas

Tabla 1. Configuraciones ensayadas y efecto medido en el conjunto reservado (MASE medio, un paso).....10

Tabla 2. Evaluación en el conjunto reservado a un paso, por tabla.....12

1 Desarrollo de la propuesta de solución

VisaPredict AI integra un archivo mensual del Visa Bulletin, una evaluación reproducible de pronósticos y una aplicación pública de consulta. La variable de interés es la fecha de prioridad publicada para una combinación de país o área de cargabilidad, categoría migratoria y tabla. El producto permite examinar la trayectoria de esa fecha y la incertidumbre de su pronóstico; no determina elegibilidad migratoria ni sustituye la información oficial.

Las cifras experimentales de este avance provienen del corte de evaluación de septiembre de 2026, publicado antes de redactar estas actividades. Los boletines posteriores se incorporan al panel operativo, pero no se convierten en una evaluación nueva. El resultado principal es que ningún modelo entrenado supera con significancia al naïve-1 (repetir el último corte publicado) a un paso dentro del protocolo estudiado.

1.1 Recolección de datos

La recolección conserva la procedencia de cada boletín y distingue una fuente inaccesible de un mes que aún no se ha publicado. El archivo congelado permite repetir la extracción sin consultar de nuevo la página, y el panel largo conserva la identidad de cada observación.

1.1.1 Identificación de fuentes de datos

La fuente primaria es el Visa Bulletin mensual del Departamento de Estado de Estados Unidos [1]. Se utilizan las tablas de preferencias familiares y de empleo, separadas en fechas de acción final (Final Action Dates, FAD) y fechas para presentar documentación (Dates for Filing, DFF). Las fechas representan umbrales administrativos, no tiempos de resolución individuales. El estado C indica disponibilidad corriente y U indisponibilidad; ninguno se confunde con una fecha observada.

El panel del corte de evaluación de septiembre reúne 27,911 observaciones, 298 meses y 194 series estructurales entre 2001-12 y 2026-09. Hay 136 series con alguna fecha y 74 evaluables bajo los criterios del experimento. Estos universos son distintos: una combinación estructural puede existir aunque no tenga longitud suficiente para entrenar o evaluar un modelo. El panel operativo continúa con los boletines siguientes; en el corte publicado de noviembre suma 28,211 observaciones y 300 meses, sin modificar la evaluación de septiembre.

1.1.2 Obtención de los datos y conversión al formato adecuado

El flujo conserva una instantánea por mes, extrae las cuatro combinaciones de bloque y tabla y normaliza países, categorías y fechas. La representación intermedia se guarda en CSV; el panel largo añade estado, fecha de prioridad y días desde una época fija. DuckDB ofrece una copia analítica regenerable con dimensiones y hechos, y los archivos JSON alimentan la aplicación y el índice del asistente.

El acceso automatizado a la fuente encuentra un cortafuegos de aplicación. La modalidad manual-automatizada separa la descarga humana del procesamiento local: el operador deposita el PDF oficial en la carpeta de entrada y ejecuta make bulletin MONTH=AAAA-MM. Poppler extrae el texto y valida las cuatro matrices y las 150 celdas. Conserva PDF, texto y HTML; reconstruye panel y DuckDB en un área temporal sin reemplazar datos vigentes y cierra con un recibo de fuentes y resultados. Rechaza PDF ambiguos o sin texto utilizable. Publicar exige PUBLISH=1 y el recibo: archiva el HTML validado en S3 sin sobrescribir y solicita el flujo mensual gobernado, con sus contratos, scoring, corte y CI.

1.2 Análisis de datos

El análisis exploratorio identifica propiedades que condicionan el diseño temporal: periodos congelados, saltos, retrocesos y cambios entre fecha, disponibilidad corriente e

indisponibilidad. Las decisiones de preparación se documentan por su efecto sobre la información disponible en cada origen de pronóstico.

1.2.1 Análisis exploratorio de datos

En el corte de septiembre, el censo registra 382 retrogresiones y un 45 % de meses congelados. La persistencia elevada explica por qué repetir la última fecha es una referencia exigente. Las distribuciones y longitudes difieren por tabla y categoría, por lo que no se agregan como si todas las series fueran intercambiables.

En la caracterización de series se evaluaron 44 descriptores candidatos. Con el protocolo y el control de falsos descubrimientos establecidos, 0 asociaciones superaron el umbral sobre 50 series. Este resultado no demuestra ausencia de señal ni superioridad de un conjunto de características: los modelos comparados no consumen esos descriptores. La selección estadística del catálogo y las variables de entrada de los predictores son procesos distintos.

1.2.2 Preprocesamiento de datos

La preparación vigente rellena de forma causal con la última observación disponible y añade máscaras de ausencia. Nunca interpola con un extremo futuro respecto del origen de pronóstico. La normalización, la escala de MASE y las características temporales se obtienen únicamente del tramo de entrenamiento. Los valores imputados ayudan a construir entradas, pero la puntuación se limita a meses con fecha real publicada.

Los árboles predicen el avance mensual y después reconstruyen el nivel de la fecha. Se incorporan rezagos y calendario cíclico; el boletín siguiente y sus variables derivadas permanecen fuera de las entradas. Los estados C y U se conservan como anotaciones. Convertirlos en una fecha arbitraria o puntuar el relleno como objetivo real produciría una mejora ficticia.

1.3 Diseño del modelo

La solución separa el repertorio experimental del campeón desplegado. El primero permite comparar modelos bajo un protocolo común; el segundo genera una receta operativa verificable. Un resultado de selección o una recomendación retrospectiva no autorizan por sí solos una promoción.

1.3.1 Definición de las técnicas de modelado

El repertorio considera 24 modelos que incluyen persistencia, tendencia, métodos autorregresivos, suavizamiento exponencial, árboles de potenciación de gradiente y redes para series temporales. Los métodos parsimoniosos permiten comprobar cuánto aporta la complejidad. El naïve-1 conserva el último valor; los demás deben justificar su costo frente a esa referencia y a la escala estacional [2].

La selección contempla error, incertidumbre, estabilidad y disponibilidad de resultados por serie. Las redes globales comparten información entre series compatibles; los métodos locales se ajustan a cada una. Estas estrategias pueden aportar ventajas en horizontes distintos y no deben confundirse con una mejora uniforme en todas las tablas.

1.3.2 Arquitectura general del sistema y flujo de trabajo

El flujo enlaza captura y validación de la fuente, panel y base analítica, preparación causal, entrenamiento y evaluación, artefactos de gobierno y consumidores. Las salidas viajan en un manifiesto con huellas criptográficas y un identificador de corte. La aplicación verifica esos archivos antes de servirlos; la tarjeta del modelo y el índice del asistente se construyen desde el mismo corte.

La infraestructura combina Git para el código, DVC y almacenamiento de objetos para datos y artefactos, DuckDB para consulta, Python para el flujo de procesamiento y Next.js para la

aplicación. La integración continua aplica contratos, consistencia, tipos y pruebas. La revisión humana requerida para publicar una campaña se mantiene separada de la ejecución automatizada. El archivo histórico y las campañas fallidas se conservan como evidencia; no se reemplazan para presentar un resultado favorable.

1.4 Desarrollo

La implementación se organizó como incrementos verificables. La preparación y el protocolo se congelaron antes del cómputo causal; después se corrigieron consumidores y se reconciliaron resultados, figuras y prosa. Cada actividad de esta sección describe evidencia existente, sin atribuirse entrenamientos nuevos durante su redacción.

1.4.1 Implementación del modelo

El código separa catálogo, fábricas de modelos, construcción de conjuntos temporales, evaluación por origen y exportación de hechos. Los modelos clásicos se reajustan en cada origen; el entrenamiento de las redes sigue un calendario explícito de reajuste. Los hiperparámetros, semillas, entradas y salidas se registran para identificar cada corrida.

La implementación protege la frontera entre selección y conjunto reservado. Las omisiones por convergencia se declaran y la agregación conserva sus poblaciones. Cada campaña deja un registro de entradas y salidas que permite comprobar su procedencia, y la reconciliación impide mezclar salidas nuevas con registros antiguos. Los consumidores rechazan cifras sin esa acreditación, en lugar de mostrarlas por la mera presencia de un archivo.

1.4.2 Ajustes al modelo con diferentes configuraciones

Las configuraciones se ensayaron por grupos con una interpretación técnica: representación de la variable objetivo, complejidad del predictor, rezagos y calendario, regularización y forma de reajuste. Los datos de selección son anteriores a los 24 meses reservados. Las

ventanas iniciales son de 60 meses para FAD y 36 para DFF; los modelos clásicos se reajustan con información pasada en cada origen y las redes cada doce meses.

En los árboles se exploraron tasa de aprendizaje en escala logarítmica, profundidad y submuestreo de filas y columnas con Optuna [3], con un presupuesto de 150 a 300 ensayos por grupo de modelo, tabla y bloque. La búsqueda aceptó una configuración distinta de la predeterminada en 9 de 12 grupos (5 familiares y 4 de empleo) según la cola de confirmación. Esa aceptación no se trasladó al conjunto reservado: en FAD familiar los árboles optimizados obtienen MASE entre 0.172 y 0.176, por encima del 0.157 del naïve-1.

En los métodos clásicos se contrastaron persistencia, tendencia amortiguada y componentes autorregresivos. En FAD familiar, el MASE medio del conjunto reservado es 0.157 para naïve-1, 0.167 para ETS amortiguado y 0.171 para Theta; Auto-ARIMA re-especificado queda en 0.212 en FAD y 0.146 en DFF. Añadir estructura autorregresiva o tendencia no redujo el error frente a la persistencia.

En las redes globales se modificaron arquitectura, capacidad y regularización, y la configuración ganadora se repitió con cinco semillas. En DFF, BiTCN promedia 0.122 con desviación 0.0006 frente a 0.125 del naïve-1; la diferencia es descriptiva y ninguna prueba registrada la contrasta. En FAD, AutoBiTCN promedia 0.162 con desviación 0.005, por encima del naïve-1. La Tabla 1 resume las configuraciones ensayadas y su efecto medido.

La corrección del relleno y el cambio de tramo evaluado ocurrieron juntos en la re-derivación causal; por tanto, la diferencia respecto de una versión histórica no identifica el efecto aislado de una sola intervención. El hallazgo útil del ajuste es reconocer cuándo una variante no justifica su complejidad.

Tabla 1. Configuraciones ensayadas y efecto medido en el conjunto reservado (MASE medio, un paso)

Configuración	Qué se modificó	Efecto medido
Persistencia (naïve-1)	Ninguno: repite el último corte	FAD 0.157; DFF 0.125. Piso de referencia.
Clásicos	Tendencia amortiguada, Theta, orden ARIMA por criterio de información	FAD: ETS 0.167, Theta 0.171, Auto-ARIMA 0.212. No mejoran al piso.
Árboles optimizados	Tasa de aprendizaje, profundidad, submuestreo; 150–300 ensayos por grupo	Aceptados 9/12 grupos en confirmación; FAD reservado 0.172–0.176.
Redes globales	Arquitectura, capacidad, regularización; cinco semillas	DFF BiTCN 0.122 ± 0.0006; FAD AutoBiTCN 0.162 ± 0.005.
Preparación causal	Relleno con la última observación y máscaras	Cambio conjunto con el tramo evaluado; no se aísla su efecto.

Fuente: elaboración propia con los artefactos del corte de evaluación de septiembre de 2026.

1.4.3 Evaluación del modelo

La tarea es pronosticar una fecha o su avance mensual, de modo que se usan métricas de regresión temporal. Precisión, exhaustividad (recall) y F1 corresponden a tareas de clasificación; sólo aplicarían a una tarea distinta sobre los estados C, F y U, que queda fuera del alcance, por lo que no se reportan. MAE resume el error en días. RMSE penaliza con mayor intensidad los errores extremos. sMAPE expresa el error relativo, con cautela cuando el avance está cerca de cero.

MASE normaliza por un error ingenuo calculado en el entrenamiento [2] y permite comparar series de escalas distintas; por eso es la métrica primaria. Un valor menor que uno respecto de la escala estacional no demuestra que se haya superado al naïve-1 fuera de muestra: para concluirlo se requieren los mismos objetivos observados, el tamaño del efecto y el contraste adecuado.

La Tabla 2 desagrega el conjunto reservado a un paso por tabla. En FAD familiar el naïve-1 obtiene MASE medio 0.157 y mediano 0.135, con sMAPE 0.39; ETS obtiene 0.167 y sMAPE 0.42. En DFF el naïve-1 obtiene 0.125 de media y 0.101 de mediana. Sobre las 15 series FAD distintas, el campeón desplegado (mediana de Theta, ETS y SARIMA) promedia 0.152 frente a 0.140 del naïve-1; en las 12 series DFF comparables, el campeón SARIMA promedia 0.121 frente a 0.103.

La incertidumbre se evalúa mediante cobertura, amplitud y la puntuación probabilística continua (Continuous Ranked Probability Score, CRPS) [4]. El CRPS acreditado del campeón es 41.5 días en FAD y 27.9 en DFF; se calcula con un protocolo de muestras y semilla declarado, y su repetibilidad no elimina el error Monte Carlo. La cobertura sola puede mejorar ensanchando los intervalos, por lo que se examina junto con su amplitud.

El registro por horizonte es una reconstrucción retrospectiva sin fuga de información, no un conjunto de pronósticos servidos en tiempo real. Contiene 2,944 pronósticos de ambas tablas y horizontes de uno a doce meses: MAE 146 días, MASE 0.347 y cobertura empírica al 95 % de 0.92. No es la métrica del campeón a un paso. Los pares servidos en vivo y puntuados después suman 158 y se informan por separado.

Las fechas imputadas, los estados C y U y las omisiones por convergencia no se convierten en objetivos reales. Las pruebas de Diebold-Mariano y las correcciones por comparaciones múltiples complementan la comparación descriptiva [5, 6]; la ausencia de significancia no equivale a equivalencia entre modelos.

Tabla 2. Evaluación en el conjunto reservado a un paso, por tabla

Indicador	FAD	DFF
MASE naïve-1 (media / mediana)	0.157 / 0.135 (25 series familiares)	0.125 / 0.101 (25 series familiares)
MASE ETS y Theta (media)	0.167 y 0.171	0.129 y 0.125
Campeón desplegado (MASE media)	Mediana de Theta, ETS y SARIMA: 0.152 (15 series distintas)	SARIMA: 0.121 (12 series)
naïve-1 en la misma población	0.140	0.103
CRPS del campeón (días)	41.5	27.9
sMAPE reservado	naïve-1 0.39; ETS 0.42	Se informa en el documento principal

Fuente: elaboración propia con los artefactos del corte de evaluación de septiembre de 2026.

1.4.4 Optimización de parámetros y pruebas avanzadas

Los parámetros internos los aprende el modelo; los hiperparámetros fijan su capacidad y su entrenamiento. La optimización sigue tres vías según la familia. Los árboles usan Optuna con muestreo TPE y poda por mediana [3], con 150 a 300 ensayos por grupo y estudios persistentes que permiten auditar configuraciones ensayadas y descartadas. Las redes usan búsqueda automática con 15 ensayos TPE y cinco semillas. Los modelos estadísticos eligen su orden por criterio de información (AICc) dentro de cada ajuste.

TPE se prefirió a la cuadrícula y a la búsqueda aleatoria porque el espacio es amplio, mezcla escalas logarítmicas y enteras, y cada entrenamiento es costoso; concentra ensayos en las regiones prometedoras sin recorrer combinaciones inútiles. La validación es temporal y no k-fold aleatorio, porque mezclar meses futuros y pasados filtraría información.

El protocolo separa entrenamiento, una cola de ajuste de 24 meses y una cola de confirmación de doce meses dentro de la región de selección. La búsqueda sólo ve la cola de ajuste; la aceptación se decide en la de confirmación, y los 24 meses finales reservados quedan fuera de ambas decisiones. Este anidamiento importa más que aumentar el presupuesto de búsqueda.

El resultado se mide en dos niveles. En la cola de confirmación se aceptaron 9 de 12 grupos (5 familiares y 4 de empleo), con reversión por serie a los valores predeterminados cuando éstos ganan. En el conjunto reservado, los árboles optimizados (LightGBM, CatBoost y XGBoost) quedan entre 0.172 y 0.176 de MASE en FAD familiar frente a 0.157 del naïve-1. La optimización mejora la selección, pero no supera el piso ingenuo: es un resultado negativo y se informa como tal.

El costo se registra por bloque. El barrido de arquitecturas profundas de frontera se ejecutó en una instancia efímera de Amazon Web Services con GPU NVIDIA A10G, con un costo del orden de ocho a nueve dólares, terminada al finalizar. Las pruebas avanzadas incluyen evaluación multi-horizonte, repeticiones con semillas controladas y cohortes pre-registradas. Una repetición idéntica confirma la reproducibilidad del cálculo, no certeza estadística.

Referencias

[1] U.S. Department of State, Bureau of Consular Affairs, “Visa Bulletin,” [En línea]. Disponible en: travel.state.gov/content/travel/en/legal/visa-law0/visa-bulletin.html.

[2] R. J. Hyndman y A. B. Koehler, “Another look at measures of forecast accuracy,” International Journal of Forecasting, vol. 22, no. 4, pp. 679–688, 2006.

[3] T. Akiba, S. Sano, T. Yanase, T. Ohta y M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” en Proc. 25th ACM SIGKDD Int. Conf. Knowledge Discovery & Data Mining, 2019, pp. 2623–2631.

[4] T. Gneiting y A. E. Raftery, “Strictly proper scoring rules, prediction, and estimation,” Journal of the American Statistical Association, vol. 102, no. 477, pp. 359–378, 2007.

[5] F. X. Diebold y R. S. Mariano, “Comparing predictive accuracy,” Journal of Business & Economic Statistics, vol. 13, no. 3, pp. 253–263, 1995.

[6] J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” Journal of Machine Learning Research, vol. 7, pp. 1–30, 2006.

Apéndice

A.1 Reproducibilidad. El código y los artefactos se versionan en el repositorio UACJ-MIAAD/VisaPredictAI; el documento académico principal, en UACJ-MIAAD/VisaPredictAI_LaTeX. Las cifras de este avance corresponden al corte de evaluación 2026-09-805d624d2ecf; el manifiesto del corte enumera cada archivo con su huella criptográfica.

A.2 Alcance de este avance. Este informe es un recorte acumulativo del documento principal, que contiene la versión extensa con figuras, tablas completas, glosario y bibliografía. Las secciones posteriores a la actividad indicada se incorporarán en las entregas siguientes.