UNIVERSIDAD AUTÓNOMA DE CIUDAD JUÁREZ

Instituto de Ingeniería y Tecnología

Departamento de Ingeniería Eléctrica y Computación

Maestría en Inteligencia Artificial y Analítica de Datos

PREDICCIÓN DE FECHAS DE PRIORIDAD EN EL VISA BULLETIN DE ESTADOS UNIDOS CONSIDERANDO PAÍS O ÁREA DE CARGABILIDAD, CATEGORÍA MIGRATORIA Y TIPO DE TABLA

Proyecto de innovación presentado por:

Javier Augusto Rebull Saucedo Matrícula 263483

Requisito para la obtención del título de

Maestro(a) en Inteligencia Artificial y Analítica de Datos

Asesor (es)

Dr. Vicente García Jiménez

Ciudad Juárez, Chihuahua Noviembre de 2026

Índice de contenido

1 Desarrollo de la propuesta de solución....4
1.1 Recolección de datos....4
1.1.1 Identificación de fuentes de datos....4
1.1.2 Obtención de los datos y conversión al formato adecuado....5
1.2 Análisis de datos....5
1.2.1 Análisis exploratorio de datos....6
1.2.2 Preprocesamiento de datos....6
1.3 Diseño del modelo....7
1.3.1 Definición de las técnicas de modelado....7
1.3.2 Arquitectura general del sistema y flujo de trabajo....7
1.4 Desarrollo....8
1.4.1 Implementación del modelo....8
1.4.2 Ajustes al modelo con diferentes configuraciones....8
1.4.3 Evaluación del modelo....10
1.4.4 Optimización de parámetros y pruebas avanzadas....12
1.5 Pruebas y validación final....13
1.5.1 Evaluación final del rendimiento del modelo....14
1.5.2 Validación de generalización y estabilidad del sistema....15
2 Resultados....16
2.1 Diseño de experimentos....16
2.2 Validación de los resultados....17
2.3 Robustez de la solución....19
3 Conclusiones....20
Referencias....21
Apéndice....22

Índice de figuras

Este avance no incluye figuras; las figuras del proyecto se encuentran en el documento académico principal.

Índice de tablas

Tabla 1. Configuraciones ensayadas y efecto medido en el conjunto reservado (MASE medio, un paso).....10
Tabla 2. Evaluación en el conjunto reservado a un paso, por tabla.....12
Tabla 3. Rendimiento final en el conjunto reservado a un paso.....15
Tabla 4. Diseño experimental por bloque.....17

1 Desarrollo de la propuesta de solución

VisaPredict AI integra un archivo mensual del Visa Bulletin, una evaluación reproducible de pronósticos y una aplicación pública de consulta. La variable de interés es la fecha de prioridad publicada para una combinación de país o área de cargabilidad, categoría migratoria y tabla. El producto permite examinar la trayectoria de esa fecha y la incertidumbre de su pronóstico; no determina elegibilidad migratoria ni sustituye la información oficial.

Las cifras experimentales de este avance provienen del corte de evaluación de septiembre de 2026, publicado antes de redactar estas actividades. Los boletines posteriores se incorporan al panel operativo, pero no se convierten en una evaluación nueva. El resultado principal es que ningún modelo entrenado supera con significancia al naïve-1 (repetir el último corte publicado) a un paso dentro del protocolo estudiado.

1.1 Recolección de datos

La recolección conserva la procedencia de cada boletín y distingue una fuente inaccesible de un mes que aún no se ha publicado. El archivo congelado permite repetir la extracción sin consultar de nuevo la página, y el panel largo conserva la identidad de cada observación.

1.1.1 Identificación de fuentes de datos

La fuente primaria es el Visa Bulletin mensual del Departamento de Estado de Estados Unidos [1]. Se utilizan las tablas de preferencias familiares y de empleo, separadas en fechas de acción final (Final Action Dates, FAD) y fechas para presentar documentación (Dates for Filing, DFF). Las fechas representan umbrales administrativos, no tiempos de resolución individuales. El estado C indica disponibilidad corriente y U indisponibilidad; ninguno se confunde con una fecha observada.

El panel del corte de evaluación de septiembre reúne 27,911 observaciones, 298 meses y 194 series estructurales entre 2001-12 y 2026-09. Hay 136 series con alguna fecha y 74 evaluables bajo los criterios del experimento. Estos universos son distintos: una combinación estructural puede existir aunque no tenga longitud suficiente para entrenar o evaluar un modelo. El panel operativo continúa con los boletines siguientes; en el corte publicado de noviembre suma 28,211 observaciones y 300 meses, sin modificar la evaluación de septiembre.

1.1.2 Obtención de los datos y conversión al formato adecuado

El flujo conserva una instantánea por mes, extrae las cuatro combinaciones de bloque y tabla y normaliza países, categorías y fechas. La representación intermedia se guarda en CSV; el panel largo añade estado, fecha de prioridad y días desde una época fija. DuckDB ofrece una copia analítica regenerable con dimensiones y hechos, y los archivos JSON alimentan la aplicación y el índice del asistente.

El acceso automatizado a la fuente encuentra un cortafuegos de aplicación. La modalidad manual-automatizada separa la descarga humana del procesamiento local: el operador deposita el PDF oficial en la carpeta de entrada y ejecuta make bulletin MONTH=AAAA-MM. Poppler extrae el texto y valida las cuatro matrices y las 150 celdas. Conserva PDF, texto y HTML; reconstruye panel y DuckDB en un área temporal sin reemplazar datos vigentes y cierra con un recibo de fuentes y resultados. Rechaza PDF ambiguos o sin texto utilizable. Publicar exige PUBLISH=1 y el recibo: archiva el HTML validado en S3 sin sobrescribir y solicita el flujo mensual gobernado, con sus contratos, scoring, corte y CI.

1.2 Análisis de datos

El análisis exploratorio identifica propiedades que condicionan el diseño temporal: periodos congelados, saltos, retrocesos y cambios entre fecha, disponibilidad corriente e

indisponibilidad. Las decisiones de preparación se documentan por su efecto sobre la información disponible en cada origen de pronóstico.

1.2.1 Análisis exploratorio de datos

En el corte de septiembre, el censo registra 382 retrogresiones y un 45 % de meses congelados. La persistencia elevada explica por qué repetir la última fecha es una referencia exigente. Las distribuciones y longitudes difieren por tabla y categoría, por lo que no se agregan como si todas las series fueran intercambiables.

En la caracterización de series se evaluaron 44 descriptores candidatos. Con el protocolo y el control de falsos descubrimientos establecidos, 0 asociaciones superaron el umbral sobre 50 series. Este resultado no demuestra ausencia de señal ni superioridad de un conjunto de características: los modelos comparados no consumen esos descriptores. La selección estadística del catálogo y las variables de entrada de los predictores son procesos distintos.

1.2.2 Preprocesamiento de datos

La preparación vigente rellena de forma causal con la última observación disponible y añade máscaras de ausencia. Nunca interpola con un extremo futuro respecto del origen de pronóstico. La normalización, la escala de MASE y las características temporales se obtienen únicamente del tramo de entrenamiento. Los valores imputados ayudan a construir entradas, pero la puntuación se limita a meses con fecha real publicada.

Los árboles predicen el avance mensual y después reconstruyen el nivel de la fecha. Se incorporan rezagos y calendario cíclico; el boletín siguiente y sus variables derivadas permanecen fuera de las entradas. Los estados C y U se conservan como anotaciones. Convertirlos en una fecha arbitraria o puntuar el relleno como objetivo real produciría una mejora ficticia.

1.3 Diseño del modelo

La solución separa el repertorio experimental del campeón desplegado. El primero permite comparar modelos bajo un protocolo común; el segundo genera una receta operativa verificable. Un resultado de selección o una recomendación retrospectiva no autorizan por sí solos una promoción.

1.3.1 Definición de las técnicas de modelado

El repertorio considera 24 modelos que incluyen persistencia, tendencia, métodos autorregresivos, suavizamiento exponencial, árboles de potenciación de gradiente y redes para series temporales. Los métodos parsimoniosos permiten comprobar cuánto aporta la complejidad. El naïve-1 conserva el último valor; los demás deben justificar su costo frente a esa referencia y a la escala estacional [2].

La selección contempla error, incertidumbre, estabilidad y disponibilidad de resultados por serie. Las redes globales comparten información entre series compatibles; los métodos locales se ajustan a cada una. Estas estrategias pueden aportar ventajas en horizontes distintos y no deben confundirse con una mejora uniforme en todas las tablas.

1.3.2 Arquitectura general del sistema y flujo de trabajo

El flujo enlaza captura y validación de la fuente, panel y base analítica, preparación causal, entrenamiento y evaluación, artefactos de gobierno y consumidores. Las salidas viajan en un manifiesto con huellas criptográficas y un identificador de corte. La aplicación verifica esos archivos antes de servirlos; la tarjeta del modelo y el índice del asistente se construyen desde el mismo corte.

La infraestructura combina Git para el código, DVC y almacenamiento de objetos para datos y artefactos, DuckDB para consulta, Python para el flujo de procesamiento y Next.js para la

aplicación. La integración continua aplica contratos, consistencia, tipos y pruebas. La revisión humana requerida para publicar una campaña se mantiene separada de la ejecución automatizada. El archivo histórico y las campañas fallidas se conservan como evidencia; no se reemplazan para presentar un resultado favorable.

1.4 Desarrollo

La implementación se organizó como incrementos verificables. La preparación y el protocolo se congelaron antes del cómputo causal; después se corrigieron consumidores y se reconciliaron resultados, figuras y prosa. Cada actividad de esta sección describe evidencia existente, sin atribuirse entrenamientos nuevos durante su redacción.

1.4.1 Implementación del modelo

El código separa catálogo, fábricas de modelos, construcción de conjuntos temporales, evaluación por origen y exportación de hechos. Los modelos clásicos se reajustan en cada origen; el entrenamiento de las redes sigue un calendario explícito de reajuste. Los hiperparámetros, semillas, entradas y salidas se registran para identificar cada corrida.

La implementación protege la frontera entre selección y conjunto reservado. Las omisiones por convergencia se declaran y la agregación conserva sus poblaciones. Cada campaña deja un registro de entradas y salidas que permite comprobar su procedencia, y la reconciliación impide mezclar salidas nuevas con registros antiguos. Los consumidores rechazan cifras sin esa acreditación, en lugar de mostrarlas por la mera presencia de un archivo.

1.4.2 Ajustes al modelo con diferentes configuraciones

Las configuraciones se ensayaron por grupos con una interpretación técnica: representación de la variable objetivo, complejidad del predictor, rezagos y calendario, regularización y forma de reajuste. Los datos de selección son anteriores a los 24 meses reservados. Las

ventanas iniciales son de 60 meses para FAD y 36 para DFF; los modelos clásicos se reajustan con información pasada en cada origen y las redes cada doce meses.

En los árboles se exploraron tasa de aprendizaje en escala logarítmica, profundidad y submuestreo de filas y columnas con Optuna [3], con un presupuesto de 150 a 300 ensayos por grupo de modelo, tabla y bloque. La búsqueda aceptó una configuración distinta de la predeterminada en 9 de 12 grupos (5 familiares y 4 de empleo) según la cola de confirmación. Esa aceptación no se trasladó al conjunto reservado: en FAD familiar los árboles optimizados obtienen MASE entre 0.172 y 0.176, por encima del 0.157 del naïve-1.

En los métodos clásicos se contrastaron persistencia, tendencia amortiguada y componentes autorregresivos. En FAD familiar, el MASE medio del conjunto reservado es 0.157 para naïve-1, 0.167 para ETS amortiguado y 0.171 para Theta; Auto-ARIMA re-especificado queda en 0.212 en FAD y 0.146 en DFF. Añadir estructura autorregresiva o tendencia no redujo el error frente a la persistencia.

En las redes globales se modificaron arquitectura, capacidad y regularización, y la configuración ganadora se repitió con cinco semillas. En DFF, BiTCN promedia 0.122 con desviación 0.0006 frente a 0.125 del naïve-1; la diferencia es descriptiva y ninguna prueba registrada la contrasta. En FAD, AutoBiTCN promedia 0.162 con desviación 0.005, por encima del naïve-1. La Tabla 1 resume las configuraciones ensayadas y su efecto medido.

La corrección del relleno y el cambio de tramo evaluado ocurrieron juntos en la re-derivación causal; por tanto, la diferencia respecto de una versión histórica no identifica el efecto aislado de una sola intervención. El hallazgo útil del ajuste es reconocer cuándo una variante no justifica su complejidad.

Tabla 1. Configuraciones ensayadas y efecto medido en el conjunto reservado (MASE medio, un paso)

Configuración	Qué se modificó	Efecto medido
Persistencia (naïve-1)	Ninguno: repite el último corte	FAD 0.157; DFF 0.125. Piso de referencia.
Clásicos	Tendencia amortiguada, Theta, orden ARIMA por criterio de información	FAD: ETS 0.167, Theta 0.171, Auto-ARIMA 0.212. No mejoran al piso.
Árboles optimizados	Tasa de aprendizaje, profundidad, submuestreo; 150–300 ensayos por grupo	Aceptados 9/12 grupos en confirmación; FAD reservado 0.172–0.176.
Redes globales	Arquitectura, capacidad, regularización; cinco semillas	DFF BiTCN 0.122 ± 0.0006; FAD AutoBiTCN 0.162 ± 0.005.
Preparación causal	Relleno con la última observación y máscaras	Cambio conjunto con el tramo evaluado; no se aísla su efecto.

Fuente: elaboración propia con los artefactos del corte de evaluación de septiembre de 2026.

1.4.3 Evaluación del modelo

La tarea es pronosticar una fecha o su avance mensual, de modo que se usan métricas de regresión temporal. Precisión, exhaustividad (recall) y F1 corresponden a tareas de clasificación; sólo aplicarían a una tarea distinta sobre los estados C, F y U, que queda fuera del alcance, por lo que no se reportan. MAE resume el error en días. RMSE penaliza con mayor intensidad los errores extremos. sMAPE expresa el error relativo, con cautela cuando el avance está cerca de cero.

MASE normaliza por un error ingenuo calculado en el entrenamiento [2] y permite comparar series de escalas distintas; por eso es la métrica primaria. Un valor menor que uno respecto de la escala estacional no demuestra que se haya superado al naïve-1 fuera de muestra: para concluirlo se requieren los mismos objetivos observados, el tamaño del efecto y el contraste adecuado.

La Tabla 2 desagrega el conjunto reservado a un paso por tabla. En FAD familiar el naïve-1 obtiene MASE medio 0.157 y mediano 0.135, con sMAPE 0.39; ETS obtiene 0.167 y sMAPE 0.42. En DFF el naïve-1 obtiene 0.125 de media y 0.101 de mediana. Sobre las 15 series FAD distintas, el campeón desplegado (mediana de Theta, ETS y SARIMA) promedia 0.152 frente a 0.140 del naïve-1; en las 12 series DFF comparables, el campeón SARIMA promedia 0.121 frente a 0.103.

La incertidumbre se evalúa mediante cobertura, amplitud y la puntuación probabilística continua (Continuous Ranked Probability Score, CRPS) [4]. El CRPS acreditado del campeón es 41.5 días en FAD y 27.9 en DFF; se calcula con un protocolo de muestras y semilla declarado, y su repetibilidad no elimina el error Monte Carlo. La cobertura sola puede mejorar ensanchando los intervalos, por lo que se examina junto con su amplitud.

El registro por horizonte es una reconstrucción retrospectiva sin fuga de información, no un conjunto de pronósticos servidos en tiempo real. Contiene 2,944 pronósticos de ambas tablas y horizontes de uno a doce meses: MAE 146 días, MASE 0.347 y cobertura empírica al 95 % de 0.92. No es la métrica del campeón a un paso. Los pares servidos en vivo y puntuados después suman 158 y se informan por separado.

Las fechas imputadas, los estados C y U y las omisiones por convergencia no se convierten en objetivos reales. Las pruebas de Diebold-Mariano y las correcciones por comparaciones múltiples complementan la comparación descriptiva [5, 6]; la ausencia de significancia no equivale a equivalencia entre modelos.

Tabla 2. Evaluación en el conjunto reservado a un paso, por tabla

Indicador	FAD	DFF
MASE naïve-1 (media / mediana)	0.157 / 0.135 (25 series familiares)	0.125 / 0.101 (25 series familiares)
MASE ETS y Theta (media)	0.167 y 0.171	0.129 y 0.125
Campeón desplegado (MASE media)	Mediana de Theta, ETS y SARIMA: 0.152 (15 series distintas)	SARIMA: 0.121 (12 series)
naïve-1 en la misma población	0.140	0.103
CRPS del campeón (días)	41.5	27.9
sMAPE reservado	naïve-1 0.39; ETS 0.42	Se informa en el documento principal

Fuente: elaboración propia con los artefactos del corte de evaluación de septiembre de 2026.

1.4.4 Optimización de parámetros y pruebas avanzadas

Los parámetros internos los aprende el modelo; los hiperparámetros fijan su capacidad y su entrenamiento. La optimización sigue tres vías según la familia. Los árboles usan Optuna con muestreo TPE y poda por mediana [3], con 150 a 300 ensayos por grupo y estudios persistentes que permiten auditar configuraciones ensayadas y descartadas. Las redes usan búsqueda automática con 15 ensayos TPE y cinco semillas. Los modelos estadísticos eligen su orden por criterio de información (AICc) dentro de cada ajuste.

TPE se prefirió a la cuadrícula y a la búsqueda aleatoria porque el espacio es amplio, mezcla escalas logarítmicas y enteras, y cada entrenamiento es costoso; concentra ensayos en las regiones prometedoras sin recorrer combinaciones inútiles. La validación es temporal y no k-fold aleatorio, porque mezclar meses futuros y pasados filtraría información.

El protocolo separa entrenamiento, una cola de ajuste de 24 meses y una cola de confirmación de doce meses dentro de la región de selección. La búsqueda sólo ve la cola de ajuste; la aceptación se decide en la de confirmación, y los 24 meses finales reservados quedan fuera de ambas decisiones. Este anidamiento importa más que aumentar el presupuesto de búsqueda.

El resultado se mide en dos niveles. En la cola de confirmación se aceptaron 9 de 12 grupos (5 familiares y 4 de empleo), con reversión por serie a los valores predeterminados cuando éstos ganan. En el conjunto reservado, los árboles optimizados (LightGBM, CatBoost y XGBoost) quedan entre 0.172 y 0.176 de MASE en FAD familiar frente a 0.157 del naïve-1. La optimización mejora la selección, pero no supera el piso ingenuo: es un resultado negativo y se informa como tal.

El costo se registra por bloque. El barrido de arquitecturas profundas de frontera se ejecutó en una instancia efímera de Amazon Web Services con GPU NVIDIA A10G, con un costo del orden de ocho a nueve dólares, terminada al finalizar. Las pruebas avanzadas incluyen evaluación multi-horizonte, repeticiones con semillas controladas y cohortes pre-registradas. Una repetición idéntica confirma la reproducibilidad del cálculo, no certeza estadística.

1.5 Pruebas y validación final

Las pruebas finales separan validez estadística e integridad del software. La primera requiere observaciones no empleadas en el ajuste; la segunda verifica que los datos, modelos y consumidores respeten sus contratos. Una integración continua en verde no sustituye un contraste estadístico ni acredita un boletín nuevo.

1.5.1 Evaluación final del rendimiento del modelo

La prueba final usa los 24 meses reservados por serie, con pronósticos emitidos desde orígenes que sólo conocen el pasado. El repertorio, los hiperparámetros y las configuraciones se fijaron antes de evaluar esa región. Se trata de un conjunto reservado retrospectivo consultado por varias comparaciones pre-registradas (repertorio, campeón y retador, cohortes), no de una prueba única e intacta; por eso las conclusiones se apoyan en contrastes con corrección por comparaciones múltiples y no en la mejor cifra observada.

La Tabla 3 resume el rendimiento final por tabla. En FAD, el campeón desplegado es la mediana de Theta, ETS y SARIMA, con MASE medio 0.152 y CRPS 41.5 días; sobre las mismas 15 series el naïve-1 promedia 0.140 y lo supera con significancia tras la corrección de Holm ($p = 0.00042$). En DFF, el campeón es SARIMA, con MASE 0.121 y CRPS 27.9 días; el naïve-1 promedia 0.103 sin significancia (p de Holm = 0.134), y la mediana de SARIMA, ETS y Theta lo mejora con significancia ($p = 0.00294$).

La comparación del mejor modelo profundo con el mejor parsimonioso, pre-registrada para cada tabla, favorece al naïve-1 frente a AutoBiTCN en FAD (Diebold-Mariano, $p = 0.0003$) y no encuentra diferencia significativa entre BiTCN y ARIMA en DFF ($p = 0.065$) [5]. El retador apto en cada tabla no se promueve automáticamente: la promoción exige además evidencia prospectiva.

El experimento no se considera exitoso por obtener una métrica menor que uno en una escala conveniente. El criterio incluye ausencia de fuga, comparación justa, reporte de omisiones y una decisión coherente con el protocolo. La utilidad de la plataforma reside también en conservar pronósticos, cuantificar la incertidumbre y hacer auditable una conclusión negativa.

Tabla 3. Rendimiento final en el conjunto reservado a un paso

Tabla	Campeón desplegado	Resultado frente al naïve-1
FAD	Mediana de Theta, ETS y SARIMA. MASE 0.152; CRPS 41.5 días; 15 series distintas	naïve-1 0.140; mejor que el campeón (Holm p = 0.00042). Diebold-Mariano frente a AutoBiTCN: p = 0.0003 a favor del naïve-1.
DFF	SARIMA. MASE 0.121; CRPS 27.9 días; 12 series	naïve-1 0.103, sin significancia (Holm p = 0.134); retador mediana de SARIMA, ETS y Theta 0.107 (Holm p = 0.00294).

Fuente: elaboración propia con los artefactos del corte de evaluación de septiembre de 2026.

1.5.2 Validación de generalización y estabilidad del sistema

La estabilidad por cohortes se evaluó con una partición previa: 74 series evaluables, 39 estables y 35 inestables. Las 4 celdas de enrutado producen 0 ganadoras bajo el criterio de tres horizontes. El resultado es exploratorio y no prueba que toda segmentación futura carezca de utilidad.

Las redes y los métodos probabilísticos se reproducen con semillas controladas y se conservan sus omisiones. La variación entre semillas es pequeña en DFF (desviación 0.0006) y mayor en FAD (0.005). La repetición no transforma las series correlacionadas en evidencia independiente: varias series mundiales de DFF coinciden con las de países, por lo que sus contrastes y tamaños efectivos se interpretan con cautela.

Las pruebas adversariales verifican el rechazo de registros inválidos, salidas ausentes o alteradas y candidatos de publicación incompletos. Los contratos de datos, las comprobaciones de consistencia y las pruebas de la aplicación protegen la propagación. La generalización futura exige observaciones nuevas y pronósticos congelados de antemano; una nueva compilación no se presenta como un ciclo prospectivo observado.

2 Resultados

Los resultados se presentan con el corte, la población y la pregunta que los originan. Se distinguen los experimentos retrospectivos, el ajuste de configuraciones, la campaña por cohortes y el registro prospectivo. Esta organización impide convertir decisiones de desarrollo en pruebas finales.

2.1 Diseño de experimentos

Las variables independientes son la familia de modelo, su configuración, la tabla, la cohorte y el horizonte. Las variables dependientes son el error (MASE, MAE, sMAPE), la cobertura y la amplitud de los intervalos, el CRPS y los contrastes derivados. Se mantienen constantes la identidad del panel, las reglas de preparación causal, la máscara de objetivos observados y el esquema temporal de cada bloque. El efecto de un cambio sólo se interpreta de forma aislada cuando el diseño mantiene constante lo demás.

La unidad de comparación es la serie en un origen con objetivo válido, y las comparaciones entre modelos se emparejan por esa identidad. No se usa k-fold aleatorio sobre meses, porque mezclaría información futura y pasada. La selección se realiza antes del conjunto reservado y la confirmación de hiperparámetros tiene su propia cola temporal.

El número de pruebas se fija por bloque (Tabla 4). El repertorio evalúa 24 modelos sobre 25 series familiares por tabla (15 distintas en FAD y 14 en DFF tras descontar la pseudo-replicación del corte mundial), con 24 orígenes mensuales reservados por serie. La optimización cubre 12 grupos con 150 a 300 ensayos cada uno; las redes ganadoras se repiten con cinco semillas; la campaña por cohortes registra 42 corridas con recetas pre-definidas, que no equivalen a 42 series independientes; el registro por horizonte puntúa 2,944 pronósticos.

El entorno de prueba es un equipo local con macOS sobre Apple Silicon y Python 3.14, con todas las dependencias fijadas en archivos de bloqueo; la integración continua repite las pruebas en Linux con los bloqueos de esa plataforma. El barrido de redes profundas de frontera se ejecutó en una instancia efímera EC2 g5.xlarge con GPU NVIDIA A10G. Para cada bloque se conservan código, versión de datos, parámetros, semillas y salidas, incluidos los experimentos fallidos.

Tabla 4. Diseño experimental por bloque

Bloque	Intervención y número de pruebas	Salida y frontera
Repertorio	24 modelos; 25 series por tabla; 24 orígenes reservados	Errores por serie; reservado intacto durante la selección.
Optimización	12 grupos; 150–300 ensayos por grupo	Ajuste y confirmación temporal separados.
Probabilístico	Distribución predictiva con muestras y semilla declaradas	CRPS, cobertura y amplitud.
Multi-semilla	Cinco semillas por red ganadora	Dispersión del MASE por tabla.
Cohortes	42 corridas; estables e inestables	Criterio pre-registrado de tres horizontes.
Registro por horizonte	2,944 pronósticos, horizontes 1 a 12	Reconstrucción retrospectiva separada de lo servido en vivo.
Software	Entradas y artefactos adversariales	Rechazo de corrupción; no prueba generalización.

Fuente: elaboración propia con los artefactos del corte de evaluación de septiembre de 2026.

2.2 Validación de los resultados

La validación usa un conjunto reservado temporal de 24 meses con orígenes móviles y ventana de entrenamiento expansible; las métricas finales no se reutilizan para escoger hiperparámetros. MASE es la métrica primaria por ser libre de escala y comparable entre series; MAE expresa el error en días; cobertura, amplitud y CRPS evalúan la incertidumbre.

Para múltiples comparaciones se controla la familia de hipótesis en lugar de seleccionar únicamente el contraste favorable [5, 6].

La prueba de Friedman rechaza la igualdad de los modelos en ambas tablas ($p < 0.001$), y el naïve-1 obtiene el mejor rango promedio en FAD (1.6) y en DFF (2.86). El conjunto de confianza de modelos al 90 % [7] retiene únicamente al naïve-1 en FAD y al naïve-1 con ETS amortiguado en DFF. Pertenecer a ese conjunto no prueba equivalencia ni establece un orden absoluto de calidad.

Las tablas FAD y DFF se evalúan por separado. En FAD, el campeón desplegado es la mediana de Theta, ETS y SARIMA y el naïve-1 lo supera con significancia (p de Holm = 0.00042). En DFF, el campeón es SARIMA; el retador apto es la mediana de SARIMA, ETS y Theta (p de Holm = 0.00294), mientras que la ventaja descriptiva del naïve-1 no es significativa ($p = 0.134$). La aptitud retrospectiva de un retador no autoriza su despliegue ni sustituye la evaluación prospectiva.

Los 2,944 pronósticos del registro por horizonte, con MAE de 146 días y MASE 0.347, son una reconstrucción retrospectiva de ambas tablas y no constituyen por sí solos una prueba confirmatoria de la receta desplegada. Las añadas reconstruidas y las servidas en vivo se etiquetan de forma distinta.

La coherencia documental se comprueba contra las exportaciones versionadas y el manifiesto del corte, y la aplicación y el asistente usan esas mismas fuentes. Esta verificación protege contra cifras obsoletas, pero no convierte la aceptación técnica en aceptación editorial ni en aval del asesor.

2.3 Robustez de la solución

La robustez se examinó desde varios límites. Las repeticiones con cinco semillas muestran una dispersión del MASE de 0.0006 para BiTCN en DFF y de 0.005 para AutoBiTCN en FAD. El CRPS acreditado del campeón es 41.5 días en FAD y 27.9 en DFF, calculado con muestras y semilla declaradas; su error Monte Carlo no se elimina por repetir el cálculo. Las cohortes ponen a prueba la heterogeneidad y los horizontes distinguen ventajas cortas y largas.

El enrutador por cohortes no supera el criterio en ninguna de sus 4 celdas. En DFF estable queda 0.0115 por encima del naïve-1 a tres meses y 0.135 por debajo a doce, sin significancia tras la corrección de Holm ($p = 0.154$ y 0.742, 28 pares); el veredicto de esa celda es pérdida material. Las mejoras a horizontes largos no satisfacen el corto, y la cohorte DFF inestable tiene pocos pares útiles. Estos hallazgos limitan cualquier afirmación de mejora general y justifican la decisión de no promover.

Se reconocen límites de cobertura: no todas las series tienen longitud suficiente, algunas configuraciones fallan por razones numéricas y la pseudo-replicación reduce la información efectiva de DFF. El resultado de cero descriptores relevantes depende del protocolo de selección y no demuestra ausencia de señal. Las bandas empíricas tampoco garantizan cobertura futura ante cambios de régimen.

La operación manual-automatizada conserva el PDF y su transformación hasta el panel y DuckDB, pero depende de la descarga humana. Cada corrida deja evidencia propia; esta modalidad no demuestra dos ciclos desatendidos ni elimina el bloqueo de la fuente.

3 Conclusiones

Se desarrolló una plataforma auditable para analizar y pronosticar fechas del Visa Bulletin, con preparación causal, comparación temporal y propagación verificada de artefactos. El objetivo general, desarrollar e implementar un sistema predictivo para las series del Visa Bulletin por país o área de cargabilidad, categoría y tabla, se cumple como sistema desplegado con gobierno de datos y resultados.

Respecto de los objetivos específicos: la base de datos (OE1) reúne 194 series y 27,911 observaciones en el corte evaluado; la caracterización (OE2) documenta censo, retrogresiones y meses congelados; la comparación de modelos lineales y no lineales (OE3) abarca 24 modelos bajo una interfaz común; la evaluación (OE4) usa validación temporal sin fuga, métricas escaladas e intervalos al 95 % con cobertura empírica de 0.92 en el registro por horizonte; y el demostrador (OE5) es la aplicación pública de consulta.

El hallazgo principal es que el naïve-1 constituye un piso difícil de superar a un mes: el conjunto de confianza de modelos retiene sólo al naïve-1 en FAD, y la optimización y las redes no lo vencen con significancia. La segmentación por estabilidad tampoco alcanzó la mejora exigida (0 de 4 celdas). El resultado negativo responde a la pregunta experimental y evita atribuir utilidad a un modelo sólo por su complejidad; el valor de la solución reside en la trazabilidad, los pronósticos multi-horizonte y la incertidumbre declarada.

El trabajo futuro requiere más evidencia prospectiva, tratamiento explícito de los cambios de régimen y ampliaciones con fuentes comparables. La integración de boletines posteriores no recalcula automáticamente la evidencia científica histórica; el sistema conserva una frontera verificable entre resultados publicados, observaciones nuevas y preguntas abiertas.

Referencias

[1] U.S. Department of State, Bureau of Consular Affairs, “Visa Bulletin,” [En línea]. Disponible en: travel.state.gov/content/travel/en/legal/visa-law0/visa-bulletin.html.

[2] R. J. Hyndman y A. B. Koehler, “Another look at measures of forecast accuracy,” International Journal of Forecasting, vol. 22, no. 4, pp. 679–688, 2006.

[3] T. Akiba, S. Sano, T. Yanase, T. Ohta y M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” en Proc. 25th ACM SIGKDD Int. Conf. Knowledge Discovery & Data Mining, 2019, pp. 2623–2631.

[4] T. Gneiting y A. E. Raftery, “Strictly proper scoring rules, prediction, and estimation,” Journal of the American Statistical Association, vol. 102, no. 477, pp. 359–378, 2007.

[5] F. X. Diebold y R. S. Mariano, “Comparing predictive accuracy,” Journal of Business & Economic Statistics, vol. 13, no. 3, pp. 253–263, 1995.

[6] J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” Journal of Machine Learning Research, vol. 7, pp. 1–30, 2006.

[7] P. R. Hansen, A. Lunde y J. M. Nason, “The model confidence set,” Econometrica, vol. 79, no. 2, pp. 453 –497, 2011.

Apéndice

A.1 Reproducibilidad. El código y los artefactos se versionan en el repositorio UACJ-MIAAD/VisaPredictAI; el documento académico principal, en UACJ-MIAAD/VisaPredictAI_LaTeX. Las cifras de este avance corresponden al corte de evaluación 2026-09-805d624d2ecf; el manifiesto del corte enumera cada archivo con su huella criptográfica.

A.2 Alcance de este avance. Este informe es un recorte acumulativo del documento principal, que contiene la versión extensa con figuras, tablas completas, glosario y bibliografía. Las secciones posteriores a la actividad indicada se incorporarán en las entregas siguientes.