UNIVERSIDAD AUTÓNOMA DE CIUDAD JUÁREZ

Instituto de Ingeniería y Tecnología

Departamento de Ingeniería Eléctrica y Computación

PREDICCIÓN DE FECHAS DE PRIORIDAD EN EL VISA BULLETIN DE ESTADOS UNIDOS CONSIDERANDO PAÍS O ÁREA DE CARGABILIDAD, CATEGORÍA MIGRATORIA Y TIPO DE TABLA

Avance del proyecto de titulación, documento acumulativo:
secciones 1.1, 1.2, 1.3 y 1.4.1 a 1.4.4
Actividad A13: 1.4.4 Optimización de parámetros y pruebas avanzadas
Proyecto de Innovación Tecnológica I

Proyecto de innovación presentado por:

Javier Augusto Rebull Saucedo

Matrícula: 263483

Requisito para la obtención del título de

MAESTRO EN INTELIGENCIA ARTIFICIAL
Y ANALÍTICA DE DATOS

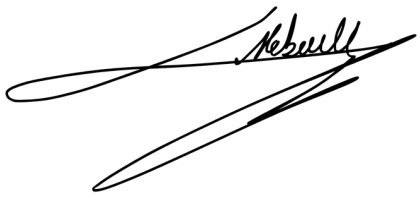
Asesor:

Dr. Vicente García Jiménez

Ciudad Juárez, Chihuahua Octubre 2026

Declaración de Originalidad

Yo, Javier Augusto Rebull Saucedo, declaro que el material contenido en esta publicación fue generado con la revisión de los documentos que se mencionan en la sección de Referencias y que no ha sido utilizado para obtener otro título o reconocimiento en otra Institución de Educación Superior.



Javier Augusto Rebull Saucedo

Índice general

Declaración de Originalidad **1**
Índice de figuras **3**
Índice de tablas **4**
Desarrollo de la propuesta de solución **6**
1.1 Recolección de datos 6
1.1.1 Identificación de fuentes de datos 6
1.1.2 Obtención de los datos y conversión al formato adecuado 10
1.2 Análisis de datos 18
1.2.1 Análisis exploratorio de datos (EDA) 18
1.2.2 Preprocesamiento de datos 45
1.3 Diseño del modelo 50
1.3.1 Definición de las técnicas de modelado a utilizar 50
1.3.2 Creación de la arquitectura general del sistema y definición del flujo de trabajo 55
1.4 Desarrollo 58
1.4.1 Implementación del modelo 58
1.4.2 Ajustes al modelo con diferentes configuraciones 72
1.4.3 Evaluación del modelo 74
1.4.4 Optimización de parámetros y pruebas avanzadas 75
Referencias **77**
Apéndice **82**
A.1 Diccionario de datos del panel 82
A.2 Catálogo de dimensiones observadas 83
A.3 Registro de limpieza del corte vigente 83
A.4 Pipeline reproducible y versionado de datos 84
A.5 Almacén dimensional en estrella 84
A.6 Entorno de ejecución y órdenes de reproducción 85
A.7 Repositorio del proyecto 86
A.8 Reproducción y trazabilidad del análisis exploratorio 87
A.9 Reproducción y trazabilidad del preprocesamiento 87
A.10 Guardarraíles automáticos y selección del modelo desplegado 88
A.11 Integración y entrega continua 90
Acerca del autor y del asesor **91**

Índice de figuras

Figura 1: Página oficial del Visa Bulletin 7
Figura 2: Estructura publicada y regímenes $C/F/U$ 8
Figura 3: Conversión de los datos 10
Figura 4: Panel largo ordenado resultante 11
Figura 5: Núcleo en estrella del almacén 11
Figura 6: Consulta al almacén gold 12
Figura 7: Clasificación y conversión de cada celda 16
Figura 8: El panel completo en una sola imagen 22
Figura 9: Radiografía de completitud de las 194 series 23
Figura 10: Frente de fecha de prioridad por área 24
Figura 11: Atraso de la cola F4 por área de cargabilidad 24
Figura 12: Trayectoria de las 25 series 25
Figura 13: Distribución del objetivo y los incrementos 25
Figura 14: Avance mensual por área (violín) 26
Figura 15: Avance mensual por categoría (violín) 26
Figura 16: Distribución del avance por categoría (ridgeline) 27
Figura 17: Composición de régimen por serie 28
Figura 18: Longitud y retrogresiones 29
Figura 19: Cronología de las retrogresiones del panel 29
Figura 20: Estacionalidad por mes calendario 30
Figura 21: Correlación entre series 31
Figura 22: Continuidad de las series 32
Figura 23: Distribución del avance mensual 32
Figura 24: Brecha FAD-DFF por serie 33
Figura 25: Descomposición STL 34
Figura 26: ACF y PACF 34
Figura 27: Rangos de corte del sorteo de diversidad 36
Figura 28: Espacio de características 39
Figura 29: Cambios de régimen y anomalías puntuales 39
Figura 30: Co-movimiento entre áreas 42
Figura 31: Correlación cruzada con retardos entre áreas 42
Figura 32: Ingeniería de características 45
Figura 33: Diferenciación de la serie 46
Figura 34: Huecos MNAR e imputación por Kalman 47
Figura 35: Política de huecos (MNAR) 48

Figura 36: Régimen administrativo y máscara de evaluación 49
Figura 37: Codificación cíclica del calendario 50
Figura 38: Importancia de características 51
Figura 39: Arquitectura general de VisaPredict AI 55
Figura 40: Cadena implementada para el modelado 59
Figura 41: Orquestación aislada y con fallo cerrado 64
Figura 42: Máquina de estados de la campaña 68

Figura 43: Veredicto campeón-retador registrado 89

Índice de tablas

Tabla 1: Inventario de fuentes de datos 8
Tabla 2: Herramientas, formatos y artefactos por etapa 14
Tabla 3: Conversión de celdas representativas 14
Tabla 4: Cantidad de datos obtenidos 15
Tabla 5: Calidad del conjunto obtenido 15
Tabla 6: Retos de acceso y extracción 17
Tabla 7: Retos de conversión y calidad 17
Tabla 8: Variables del panel en el análisis exploratorio 19
Tabla 9: Herramientas del análisis exploratorio 20
Tabla 10: Censo descriptivo del panel 21
Tabla 11: Censo de estacionariedad del piloto 35
Tabla 12: Características estructurales de las series 37
Tabla 13: Anomalías y forma de las series 38
Tabla 14: Síntesis del análisis exploratorio (1 de 2) 43
Tabla 15: Síntesis del análisis exploratorio (2 de 2) 44
Tabla 16: Síntesis del preprocesamiento 51
Tabla 17: Catálogo de modelos 52
Tabla 18: Flujo de trabajo del sistema 57
Tabla 19: Implementación por familia de modelos 60
Tabla 20: Parámetros principales de implementación 61
Tabla 21: Herramientas usadas en la implementación 62
Tabla 22: Registro canónico de la etapa 2 64
Tabla 23: Parámetros de integración de la etapa 2 66
Tabla 24: Módulos principales de la etapa 2 67
Tabla 25: Progresión de las tres etapas de implementación 67
Tabla 26: Taxonomía de fallos y recuperación 69
Tabla 27: Configuración consolidada de la implementación 71
Tabla 28: Pruebas y evidencia de la implementación 71

Tabla 29: Configuraciones ensayadas y efecto medido 73
Tabla 30: Evaluación en el conjunto reservado por tabla 75

Tabla 31: Diccionario de datos del panel 82
Tabla 32: Catálogo de dimensiones observadas 83
Tabla 33: Resultado de la consulta de resumen 85
Tabla 34: Entorno de ejecución 86
Tabla 35: Guardarraíles automáticos 88

Desarrollo de la propuesta de solución

La propuesta de solución es *VisaPredict AI*, un sistema predictivo que estima las fechas de prioridad del *Visa Bulletin* del Departamento de Estado de Estados Unidos, organizadas como un panel multiserie $y_{p,c,b,t}$ indexado por país o área de cargabilidad p, categoría migratoria c, tipo de tabla b y mes t. El presente documento reporta la construcción y la validación del modelo a partir del Anteproyecto, siguiendo las fases de la metodología *Cross-Industry Standard Process for Data Mining* (CRISP-DM) [1]: comprensión y preparación de los datos, modelado y evaluación.

El sistema opera como un regresor temporal único entrenado exclusivamente sobre las observaciones con fecha publicada (estado $e = F$). Las celdas con régimen *Current* (C) o *Unavailable* (U) se conservan como anotación descriptiva, pero no son objetivo predictivo: el sistema no promete anticipar los cambios de régimen. Las tablas *Final Action Dates* (FAD) y *Dates for Filing* (DFF) se modelan y se evalúan por separado.

Alcance de este documento. El presente documento es acumulativo: conserva el documento entregado en las actividades anteriores y le incorpora la sección nueva, como indica el formato de seguimiento. Reúne la **recolección de datos** (sección 1.1): la identificación y justificación de las fuentes (1.1.1) y la obtención, extracción y conversión de los datos al formato del sistema (1.1.2), con la cantidad y la calidad del conjunto y los retos enfrentados; el **análisis exploratorio de datos** (1.2.1): variables, técnicas, patrones, distribuciones, correlaciones y valores atípicos, cada hallazgo traducido en una decisión de modelado; el **preprocesamiento de datos** (1.2.2): valores ausentes, normalización, codificación de variables categóricas y selección de características, cada una con su salvaguarda contra la fuga de información; la **definición de las técnicas de modelado** (1.3.1): el catálogo de métodos y la justificación de cada familia; la **arquitectura general del sistema y el flujo de trabajo** (1.3.2); la **implementación del modelo** (1.4.1), finalizada en tres etapas; los **ajustes al modelo con diferentes configuraciones** (1.4.2); la **evaluación del modelo** (1.4.3). Este documento incorpora la **optimización de parámetros y las pruebas avanzadas** (1.4.4). Las secciones siguientes del formato se desarrollan en las versiones posteriores del documento.

1.1 Recolección de datos

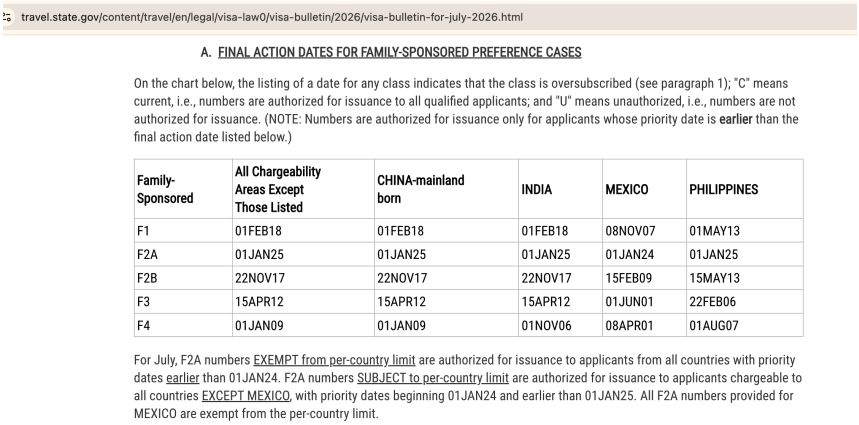
Esta sección recapitula la fase de comprensión y adquisición de los datos, construida como Objetivo 1 del proyecto. Se describen las fuentes y el proceso de obtención y conversión al formato de modelado.

1.1.1 Identificación de fuentes de datos

La fuente primaria es el *Visa Bulletin* mensual publicado por el Departamento de Estado de Estados Unidos en `travel.state.gov` [2]. Su elección obedece a tres criterios: es la

fuente oficial y autoritativa de las fechas de prioridad; cubre de forma homogénea las cinco áreas de cargabilidad de interés (México, India, China, Filipinas y *All Chargeability Areas Except Those Listed*); y publica de manera consistente las dos tablas relevantes, FAD y DFF. Para asegurar la reproducibilidad y la resiliencia ante la rotación de boletines viejos del portal oficial, cada boletín se congela como instantánea HTML en un respaldo versionado, del cual el procesamiento parte de forma reproducible.

La Figura 1 muestra un boletín real (julio de 2026) tal como se publica: un encabezado institucional y, para cada tabla, una matriz con las categorías migratorias en las filas y los países o áreas de cargabilidad en las columnas. Cada celda contiene uno de tres valores: una **fecha de prioridad** en formato `DDMMMYY` (p. ej., `01FEB18`), la marca ***Current*** (`C`, sin rezago ese mes) o ***Unavailable*** (`U`, sin números disponibles). La Figura 2 reproduce, con esa misma estructura, la tabla *Final Action Dates* de preferencia por empleo del mismo boletín, donde conviven los tres regímenes. Esta distinción $C/F/U$ es central: solo las celdas con fecha ($e = F$) constituyen el objetivo predictivo.


travel.state.gov/content/travel/en/legal/visa-law0/visa-bulletin/2026/visa-bulletin-for-july-2026.html

A. FINAL ACTION DATES FOR FAMILY-SPONSORED PREFERENCE CASES

On the chart below, the listing of a date for any class indicates that the class is oversubscribed (see paragraph 1); "C" means current, i.e., numbers are authorized for issuance to all qualified applicants; and "U" means unauthorized, i.e., numbers are not authorized for issuance. (NOTE: Numbers are authorized for issuance only for applicants whose priority date is **earlier** than the final action date listed below.)

Family-Sponsored	All Chargeability Areas Except Those Listed	CHINA-mainland born	INDIA	MEXICO	PHILIPPINES
F1	01FEB18	01FEB18	01FEB18	08NOV07	01MAY13
F2A	01JAN25	01JAN25	01JAN25	01JAN24	01JAN25
F2B	22NOV17	22NOV17	22NOV17	15FEB09	15MAY13
F3	15APR12	15APR12	15APR12	01JUN01	22FEB06
F4	01JAN09	01JAN09	01NOV06	08APR01	01AUG07

For July, F2A numbers EXEMPT from per-country limit are authorized for issuance to applicants from all countries with priority dates earlier than 01JAN24. F2A numbers SUBJECT to per-country limit are authorized for issuance to applicants chargeable to all countries EXCEPT MEXICO, with priority dates beginning 01JAN24 and earlier than 01JAN25. All F2A numbers provided for MEXICO are exempt from the per-country limit.

Figura 1: Boletín de visas de julio de 2026 publicado por el Departamento de Estado en `travel.state.gov`, con la tabla de preferencias familiares. Es la fuente primaria y autoritativa del proyecto.

Fuentes complementarias. Junto a la fuente primaria se identificaron tres fuentes que no aportan la variable a predecir, pero sí el contexto necesario para interpretarla y para validar las reglas de negocio del sistema. La primera es el marco normativo: la *Immigration and Nationality Act* (INA) y, en particular, el límite del siete por ciento anual de visas de preferencia por país codificado en 8 U.S.C. 1152 [3], que explica por qué México, India, China y Filipinas presentan filas mucho más largas que el resto y sustenta la decisión de modelar el área de cargabilidad como dimensión del panel y no como una covariable más. La segunda son los cuadros de presentación de solicitudes de ajuste de estatus del Servicio de Ciudadanía e Inmigración (USCIS) [4], que cada mes determinan cuál de las dos tablas rige la recepción de solicitudes y justifican que FAD y DFF se traten como series separadas y no comparables entre sí. La tercera son los informes estadísticos anuales de la Oficina de

Cat.	All Charg.	China	India	México	Filipinas
EB-1	C	01JUN23	15OCT22	C	C
EB-2	C	01SEP21	U	C	C
EB-3	01AUG24	22DEC21	01JAN14	01AUG24	01AUG23
EB-4	15SEP22	15SEP22	15SEP22	15SEP22	15SEP22
EB-5*	C	01DEC16	U	C	C

Fecha (F) Current (C) Unavailable (U)

Figura 2: Tabla *Final Action Dates* de preferencia por empleo (julio de 2026): categorías en las filas, áreas de cargabilidad en las columnas. Cada celda es una fecha (F), *Current* (C) o *Unavailable* (U); solo las celdas con fecha son objetivo predictivo.

Visas [5], empleados como contexto y como verificación cualitativa de los movimientos observados, además de ser la vía prevista para una eventual extensión del histórico hacia el periodo anterior a la serie mensual homogénea.

Conviene subrayar una restricción de acceso que condiciona todo el proceso descrito en la sección 1.1.2: el Departamento de Estado no ofrece una interfaz de programación de aplicaciones (*application programming interface*, API) ni un archivo descargable con el histórico consolidado. La publicación se realiza exclusivamente como páginas HTML independientes, una por mes, de modo que la obtención de la serie se resolvió mediante un proceso propio de extracción web y no mediante el consumo de un servicio. La Tabla 1 resume el inventario de fuentes con su tipo de acceso, formato, frecuencia y uso.

Tabla 1: Inventario de fuentes: tipo de acceso, formato de publicación, frecuencia de actualización y uso previsto en el proyecto.

Fuente	Acceso	Formato	Frecuencia	Uso en el proyecto
Visa Bulletin, Departamento de Estado [2]	Portal público, sin API; extracción web propia	HTML	Mensual	Fuente primaria: variable dependiente $y_{p,c,b,t}$
INA, 8 U.S.C. 1152 [3]	Texto legal público	HTML y PDF	Estable	Límite del 7 % anual por país; justifica el área de cargabilidad como dimensión
Cuadros de presentación de solicitudes, USCIS [4]	Portal público	HTML	Mensual	Define qué tabla rige cada mes; separa FAD de DFF
Informe anual de la Oficina de Visas [5]	Portal público	PDF y hoja de cálculo	Anual	Contexto y verificación cualitativa; vía de extensión histórica

Justificación de la elección. La selección del *Visa Bulletin* como fuente primaria responde a cinco criterios: es la fuente **oficial y única** del dato, pues la fecha de prioridad no es una estimación ni un agregado de terceros sino el valor administrativo que determina el avance real de cada solicitud; ofrece **cobertura longitudinal** suficiente para aplicar validación temporal con ventanas móviles; su **frecuencia mensual** define por sí misma la granularidad del problema y del producto; es de **acceso público y libre** y publica exclusivamente valores agregados de política migratoria, sin dato personal identificable de solicitantes; y presenta **estabilidad estructural** suficiente para un extractor automatizado y reproducible. Se evaluaron y se descartaron dos alternativas: los foros donde los solicitantes reportan el avance de sus casos, que no son autoritativos y presentan un fuerte sesgo de autoselección, y los registros de casos individuales, excluidos por contener datos personales y por ser innecesarios para un objetivo que opera sobre valores agregados de política pública.

1. **Autoridad.** Es la fuente oficial y única del dato. La fecha de prioridad no es una estimación ni un agregado de terceros, sino el valor administrativo que determina el avance real de cada solicitud.

2. **Cobertura longitudinal.** El archivo del portal permite reconstruir una serie mensual continua suficientemente larga para aplicar validación temporal con ventanas móviles, que es el esquema de evaluación adoptado por el proyecto.

3. **Frecuencia natural.** La publicación mensual define por sí misma la granularidad del problema y del producto: el sistema debe anticipar el boletín del mes siguiente y los horizontes posteriores.

4. **Disponibilidad legal y ausencia de datos personales.** Al ser obra de una dependencia del gobierno federal de Estados Unidos, el boletín es de acceso público y libre, y publica exclusivamente valores agregados de política migratoria, sin ningún dato personal identificable de solicitantes.

5. **Estabilidad estructural.** El formato de las tablas se ha mantenido consistente a lo largo del periodo utilizado, lo que hace viable un extractor automatizado y reproducible.

Fuentes consideradas y descartadas. Se evaluaron y se descartaron dos tipos de fuentes adicionales. Los foros y comunidades en línea donde los solicitantes reportan el avance de sus casos ofrecen volumen, pero no son autoritativos, presentan un fuerte sesgo de autoselección (solo reporta quien decide hacerlo) y carecen de garantías de continuidad. Los registros de casos individuales quedaron excluidos por contener datos personales y por no ser necesarios para el objetivo del proyecto, que opera enteramente sobre valores agregados de política pública. Esta decisión mantiene el proyecto libre de información personal identificable y simplifica su tratamiento ético y legal.

1.1.2 Obtención de los datos y conversión al formato adecuado

La extracción se realiza por *web scraping* de las instantáneas congeladas, con una detección de columnas robusta a veinte años de deriva de formato. El dato crudo de cada celda se conserva tal cual se publicó y se clasifica en el régimen $e \in \{F, C, U, \text{UNK}\}$. La variable dependiente $y_{p,c,b,t}$ se define como el número de días desde la época base $t_0 =$ 1-ene-1975, calculado solo para las celdas con fecha ($e = F$).

El flujo completo de adquisición y conversión se resume en la Figura 3. Primero, cada boletín se **congela** como una instantánea HTML en un respaldo versionado (política *skip-if-exists*), lo que aísla el proyecto de la rotación de boletines viejos en el portal oficial. Después, un **parser sin conexión** recorre las instantáneas con una detección de columnas robusta a veinte años de deriva de formato, clasifica el régimen de cada celda y, para las celdas con fecha, calcula $y_{p,c,b,t}$ como los días transcurridos desde la época base.

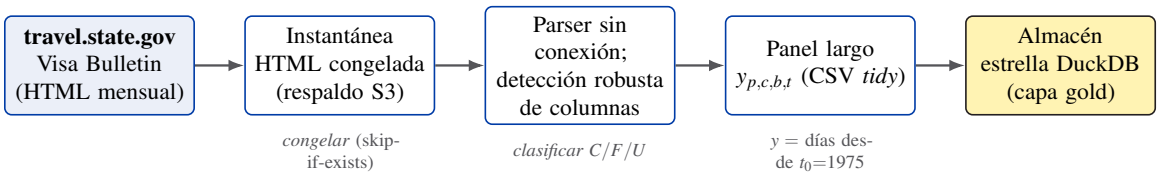


Figura 3: De la página oficial al almacén entrenable: congelado de la instantánea HTML, parseo sin conexión con clasificación de régimen, consolidación del panel $y_{p,c,b,t}$ y carga en el almacén dimensional en estrella.

Los datos se consolidan en un panel largo y se cargan en un almacén dimensional en estrella (DuckDB) cuyas restricciones de clave e integridad actúan como contrato de calidad. El conjunto resultante comprende **194 series** y **28,211 filas** en el rango **dic-2001 a 2026**, con una cobertura a nivel de boletín del 100 % (300 de 300 meses; los cinco boletines retirados de la fuente oficial se recuperaron manualmente del archivo histórico y se integraron a las instantáneas congeladas). Los principales retos enfrentados fueron: la heterogeneidad del formato HTML a lo largo de dos décadas; la distinción entre "sin dato" y "Unavailable" (resuelta con el centinela `UNK` en lugar de `NA`, que colisiona con la coerción de `pandas`); y la naturaleza dispersa de las series, pues los meses en régimen C o U no aportan fecha y se manifiestan como huecos.

La Figura 4 muestra el resultado de la conversión: el panel en formato *tidy* (largo), donde cada fila es una observación (país, categoría, tabla, mes) con su régimen, su fecha de prioridad y la variable objetivo `days_since_base`; las celdas C y U se conservan como anotación, sin fecha. Ese panel se materializa en el almacén dimensional cuyo núcleo en estrella muestra la Figura 5 (doce tablas: siete dimensiones, dos tablas de hechos y tres de gobernanza y procedencia, además de vistas/marts), sobre el que cualquier consulta es reproducible (Figura 6). La tabla de procedencia `source_artifact` conserva la identidad y la huella de los archivos fuente y se vincula con los hechos mediante la migración de procedencia del almacén.

Panel largo ordenado: visa_panel_long.csv (variable objetivo days_since_base)

país	categoría	tabla	mes (t)	estado	fecha prioridad	days_since_base	celda cruda
México	F2A	FAD	2001-12-01	F	1994-10-22	7234	22OCT94
México	F2A	FAD	2002-01-01	F	1994-10-22	7234	22OCT94
México	F2A	FAD	2002-02-01	F	1994-10-22	7234	22OCT94
México	F2A	FAD	2002-03-01	F	1994-10-22	7234	22OCT94
México	F2A	FAD	2013-08-01	C			C
México	F2A	FAD	2013-09-01	C			C
India	F1	FAD	2001-12-01	F	1999-03-01	8825	01MAR99
India	F1	FAD	2002-01-01	F	1999-03-01	8825	01MAR99
Resto del mundo	EB-1	FAD	2007-08-01	U			U

Figura 4: Muestra del panel largo `visa_panel_long.csv`: cada fila combina país, categoría, tabla y mes con su régimen, su fecha de prioridad y la variable objetivo `days_since_base`, definida solo cuando el estado es *F*.

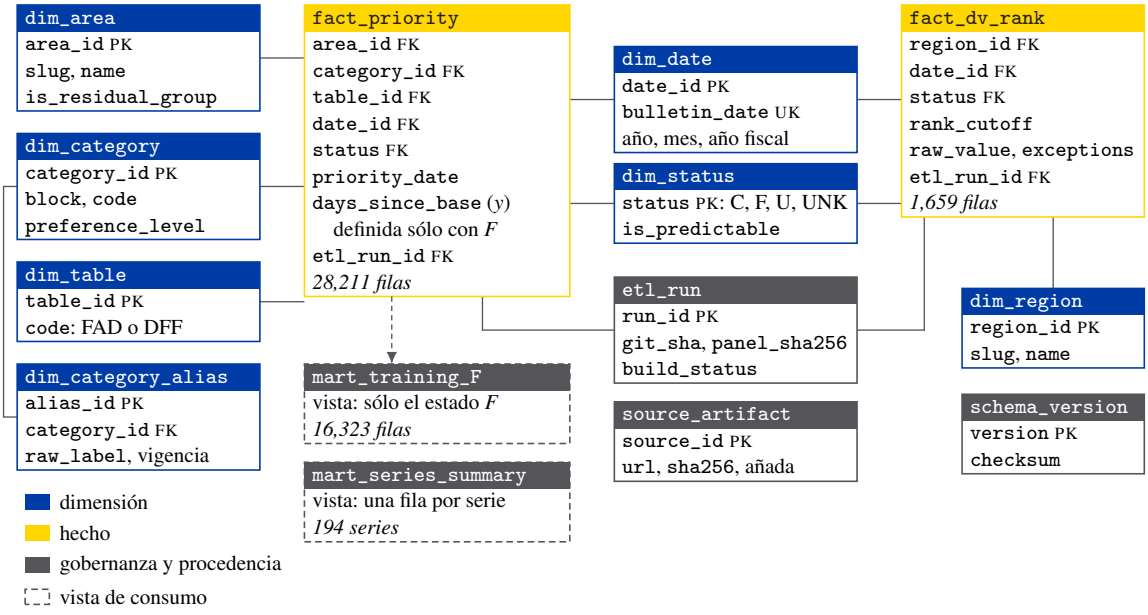


Figura 5: Esquema del almacén DuckDB (capa gold): siete dimensiones, dos tablas de hechos (prioridades y rangos de *Diversity Visa*), tres tablas de gobernanza y procedencia y las dos vistas de consumo. Las líneas continuas son claves foráneas; la flecha discontinua, la vista de entrenamiento que se deriva de los hechos.

Procedimiento detallado, etapa por etapa. El flujo de la Figura 3 se implementó como una cadena de siete pasos ejecutables, cada uno con su herramienta, su formato de salida y su artefacto verificable:

Almacén DuckDB (capa gold): SELECT ... FROM v_panel_long

pais	cat	tabla	mes	estado	fecha_prioridad	dias_base
México	F3	FAD	2026-11	F	2001-07-15	9692
México	F3	FAD	2026-10	F	2001-07-01	9678
México	F3	FAD	2026-09	F	2001-07-01	9678
México	F3	FAD	2026-08	F	2001-07-01	9678
México	F3	FAD	2026-07	F	2001-06-01	9648
México	F3	FAD	2026-06	F	2001-05-01	9617
México	F3	FAD	2026-05	F	2001-05-01	9617
México	F3	FAD	2026-04	F	2001-05-01	9617

Figura 6: Resultado de una consulta SQL a la vista `v_panel_long` del almacén: la serie entrenable (estado F) de México/F3/FAD con su fecha de prioridad y la variable objetivo `days_since_base`.

1. **Descubrimiento del índice.** Se solicita la página índice del portal con el cliente HTTP `requests` [6] y se analiza el documento con Beautiful Soup [7], extrayendo del acordeón que agrupa los boletines por año fiscal los enlaces de cada mes. La lista se contrasta contra un piso mínimo de 290 enlaces esperados: si el portal renombrara su maquetado, la lista quedaría vacía y el proceso se volvería un no-op silencioso, de modo que por debajo de ese piso el paso aborta con error.

2. **Descarga y congelado inmutable.** Cada boletín no descargado previamente se solicita una sola vez, con reintentos y espera creciente ante fallos transitorios y con tiempo límite por petición. Antes de escribir, el contenido debe presentar los marcadores propios de un boletín real, lo que evita momificar una página de mantenimiento devuelta con código 200. La escritura es atómica (archivo temporal y reemplazo), y la política es no sobrescribir jamás: una página ya congelada es un hecho fijo. El resultado es un respaldo local de instantáneas HTML replicado en almacenamiento de objetos en la nube.

3. **Extracción sin conexión.** El análisis sintáctico no toca la red: recorre las instantáneas congeladas y, en una sola lectura por archivo, extrae las tres secciones de interés (preferencia por empleo, preferencia familiar y visas por diversidad). La detección de secciones y de columnas tolera la deriva de dos décadas de maquetado, y las etiquetas de categoría se traducen a un catálogo canónico de códigos. Un fallo en la sección de visas por diversidad no invalida el mes, porque ese bloque no es objetivo predictivo.

4. **Consolidación y conversión.** Los archivos por país se unen con la biblioteca `pandas` [8] en un único panel largo en formato *tidy* [9], donde cada fila es una observación identificada por país, categoría, tabla y mes. Aquí se clasifica el régimen de cada celda, se calcula la variable dependiente como días transcurridos desde la época base y se aplican las guardas de limpieza que se describen más adelante en esta sección.

5. **Almacenamiento.** El panel se materializa en tres formatos complementarios: texto separado por comas para consulta y descarga abierta, formato columnar comprimido (Parquet [10]) para lectura eficiente y el almacén dimensional en estrella sobre DuckDB (Apéndice A.5), cuyas restricciones de clave, de integridad referencial y de verificación actúan como contrato de calidad.

6. **Registro, metadatos y trazabilidad.** Cada construcción escribe un registro de limpieza con el mes de la añada, el conteo de filas por régimen y las guardas evaluadas (Apéndice A.3); la carga al almacén deja constancia en una bitácora de ejecución, y el grafo de dependencias de datos versiona los artefactos por su huella digital (Apéndice A.4), de modo que cualquier tercero puede reconstruir la cadena completa y obtener los mismos archivos.

7. **Automatización mensual.** Una tarea programada verifica en días hábiles si el Departamento de Estado publicó un boletín nuevo; solo cuando aparece uno, congela la página, reconstruye el panel y el almacén, revalida la consistencia y publica los artefactos. Cada ejecución emite un aviso por correo, exitosa o fallida, para que la ausencia de noticias no se confunda con un proceso sano. En el corte que documenta este trabajo el portal oficial rechaza a los clientes automatizados; la tarea registra ese estado en el feed de ingesta y la página del mes se obtiene a mano por la misma orden gobernada.

La Tabla 2 resume las herramientas, los formatos y los artefactos producidos en cada etapa.

Conversión de cada celda al formato de modelado. La conversión no es un simple cambio de extensión de archivo: el boletín no publica solo fechas, y cada valor posible significa algo distinto. La Figura 7 muestra la lógica que normaliza cada celda publicada, la clasifica en uno de los cuatro regímenes y la convierte en la variable objetivo únicamente cuando corresponde, sin inventar valores; la Tabla 3 ilustra el resultado sobre celdas representativas. El registro de limpieza del corte vigente se resume en el Apéndice A.3.

Cantidad de datos obtenidos. El proceso descrito produjo un panel de 28,211 registros distribuidos en 194 series y 300 meses consecutivos, sin meses faltantes, con nueve variables por registro que documenta el Apéndice A.1. La Tabla 4 desglosa el volumen obtenido por artefacto y por bloque; el censo de las observaciones con fecha por bloque y tabla se detalla más adelante, en la Tabla 10.

Calidad de los datos. La calidad se evalúa con dos criterios: qué proporción de las celdas obtenidas quedó correctamente interpretada y cuántas violaciones de las invariantes del conjunto se detectaron. El primero es alto: 16,323 registros (58 %) traen una fecha de

Tabla 2: Herramientas, conversión de formato y artefacto verificable de cada etapa del proceso de obtención y conversión.

Etapa	Herramienta	Conversión de formato	Artefacto resultante
Descubrimiento	Python: `requests` y `beautifulsoup4`	Índice HTML a lista de enlaces	Lista de enlaces mensuales, contrastada con un piso de 290
Congelado	`requests` o captura asistida, con escritura atómica	Página o PDF oficial a instantánea inmutable	`data/snapshots/`: 302 archivos HTML, incluidos octubre y noviembre de 2026 con su PDF de origen
Extracción	`beautifulsoup4` y `pandas`	HTML congelado a tablas por bloque	11 archivos CSV crudos en `data/raw/`
Conversión	`pandas`	CSV por país a panel largo *tidy*	`visa_panel_long.csv`: 28,211 filas por 9 variables (1.6 MB)
Almacenamiento	DuckDB y Parquet	Panel *tidy* a almacén dimensional	`visapredict.duckdb` (12 tablas y 6 vistas, 13 MB) y el archivo columnar equivalente (98 KB)
Trazabilidad	Git, control de versiones de datos y almacenamiento de objetos	Artefactos a versiones con huella digital	Registro de limpieza, bitácora de ejecución y archivo de bloqueo del grafo de datos
Automatización	Tarea programada de integración continua	Boletín nuevo a publicación	Reconstrucción condicional, aviso por correo y verificación del despliegue

Tabla 3: De la celda cruda al registro del panel. Solo el régimen *F* produce `days_since_base`; los regímenes *C*, *U* y UNK quedan sin fecha.

Celda cruda	Estado	Fecha de prioridad	`days_since_base`
`01MAY16`	F	2016-05-01	15,096
`15FEB09`	F	2009-02-15	12,464
`C`	C	- *(mes del boletín, global)*	-
`U`	U	-	-
(vacía)	UNK	-	-
`15JUL99`	F	1999-07-15 *(guard de siglo)*	8,961

prioridad y constituyen el objetivo entrenable, mientras que el resto corresponde a regímenes sin fecha que se conservan como anotación descriptiva; una sola celda de las 28,211 quedó sin poder interpretarse. El segundo es igualmente favorable, pero por construcción: las guardas del proceso no reportan incidencias porque *abortan* la construcción del panel cuando se violan, de modo que un valor distinto de cero en esas filas es inalcanzable y su presencia documenta la invariante vigente. La Tabla 5 presenta ambos grupos de indicadores.

Conviene precisar dos lecturas de estos indicadores. La primera es que la proporción de celdas sin fecha no es un defecto de la extracción, sino una propiedad de la fuente: muchas combinaciones de país y categoría permanecen al corriente durante todo el periodo y, por

Tabla 4: Volumen del conjunto obtenido tras la extracción y la conversión, por artefacto y por bloque del panel.

Indicador	Valor	Nota
Instantáneas HTML congeladas	302	300 meses únicos, más una ruta alterna y un anuncio especial de julio de 2007
Meses cubiertos por el panel	300	De diciembre de 2001 a noviembre de 2026, sin meses faltantes
Series estructurales	194	Combinaciones observadas de 5 áreas de cargabilidad, 21 categorías y 2 tablas
Registros del panel largo	28,211	Nueve variables por registro
Registros de la tabla FAD	18,963	300 meses (diciembre de 2001 a noviembre de 2026)
Registros de la tabla DFF	9,248	134 meses (la tabla existe desde octubre de 2015)
Bloque de preferencia por empleo	17,646	16 categorías (EB-1 a EB-5 con subcategorías)
Bloque de preferencia familiar	10,565	5 categorías (F1, F2A, F2B, F3 y F4)
Rangos de *Diversity Visa*	1,659	Hecho separado del almacén; no es objetivo predictivo

Tabla 5: Indicadores de calidad del panel: interpretación de las celdas publicadas, invariantes verificadas y cobertura efectiva de las series.

Indicador	Valor	Interpretación
Celdas con régimen asignado	> 99.99 %	28,210 de 28,211: solo una celda quedó sin dato interpretable
Observaciones con fecha ($e = F$)	16,323	57.9 % del panel; único objetivo predictivo
Observaciones *Current* ($e = C$)	11,262	39.9 %; categoría al corriente, sin fecha que pronosticar
Observaciones *Unavailable* ($e = U$)	625	2.2 %; sin números disponibles ese mes
Observaciones sin dato (UNK)	1	Menos del 0.01 %; se conserva el valor crudo
Fechas de prioridad imparseables	0	Guarda que detiene la construcción del panel
Fechas de boletín imparseables	0	Guarda que detiene la construcción del panel
Fechas anteriores a la época base t_0	0	Guarda de época: delataría un error de siglo
Filas duplicadas colapsadas	0	Deduplicación por preferencia de régimen
Meses faltantes	0	Cobertura del 100 % a nivel de boletín
Saltos superiores a ocho años	14	Eventos administrativos reales; se conservan, no se recortan
Series con al menos una fecha	136	De 194; el resto permanece en C o U todo el periodo
Series con longitud y variabilidad suficientes	74	Conjunto efectivamente evaluable por el sistema

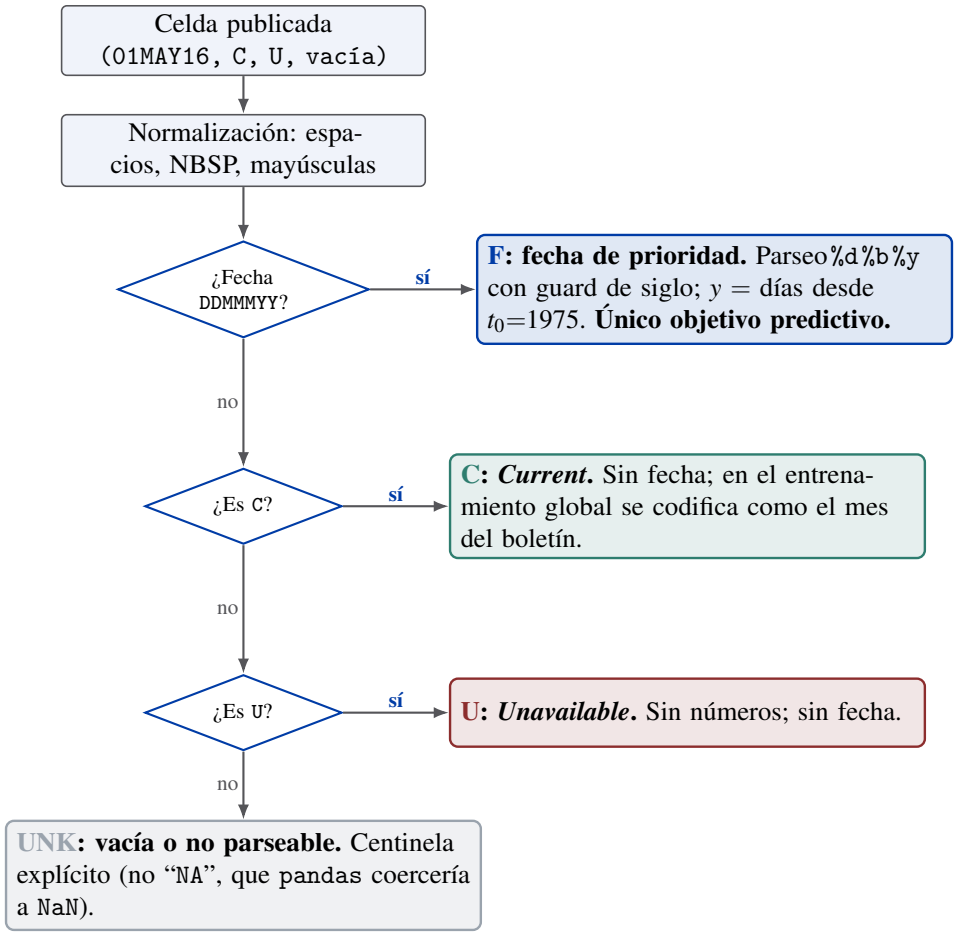


Figura 7: Lógica de limpieza: cada celda publicada se normaliza y se clasifica en uno de cuatro regímenes. Solo las celdas con fecha (**F**) producen la variable objetivo `days_since_base`; **C** y **U** se conservan como anotación descriptiva y **UNK** distingue "sin dato" de *Unavailable*.

definición, no tienen fecha que publicar. La segunda es que los catorce saltos superiores a ocho años no se tratan como valores atípicos a corregir, sino como eventos administrativos verdaderos (agotamiento de cuotas y cambios de régimen) que el sistema debe tolerar; por eso ninguna etapa del proceso recorta ni suaviza valores extremos.

Retos enfrentados y cómo se resolvieron. La obtención de una serie de veinticinco años a partir de páginas HTML publicadas una por una planteó retos de acceso, de formato y de calidad. Las Tablas 6 y 7 los enumeran junto con su impacto potencial y la solución adoptada.

El conjunto obtenido no se da por bueno por inspección visual: además de las guardas que abortan la construcción, la integración continua ejecuta en cada cambio la batería de pruebas de la capa de datos (Apéndice A.11), una verificación automática recorre el panel completo y reporta cobertura, duplicados, saltos y huecos, y un verificador de consistencia compara las cifras publicadas en el documento, en el repositorio y en el portal de divulgación

Tabla 6: Retos enfrentados en el acceso a la fuente y en la extracción, con su impacto potencial y la solución adoptada.

Reto	Impacto potencial	Solución adoptada
Ausencia de interfaz de programación y de histórico descargable	Sin descarga directa no existe serie ni variable dependiente	Extractor propio que recorre el archivo mensual del portal y lo convierte en panel
Retiro de boletines antiguos del portal	Cinco boletines dejaron de publicarse en vivo; la serie quedaba con huecos irrecuperables	Congelado inmutable de cada página y recuperación manual de esos cinco meses desde el archivo histórico, integrados a las instantáneas; cobertura final de 300 de 300 meses
Deriva del maquetado HTML a lo largo de dos décadas	Una columna no reconocida elimina un país entero de la serie sin aviso	Detección de secciones y de columnas tolerante a la deriva, catálogo canónico de 21 categorías y verificación de cobertura por país y mes que aborta si el boletín más reciente pierde una columna
Respuestas de mantenimiento devueltas con código 200	Una página falsa quedaría congelada para siempre por la política de no sobrescribir	Validación de los marcadores propios del boletín antes de escribir, y escritura atómica
Cambio de estructura del índice de boletines	El proceso se volvería un no-op silencioso, con todos los controles en verde	Piso mínimo de enlaces esperados que aborta de forma ruidosa

Tabla 7: Retos enfrentados en la conversión al formato de modelado y en el aseguramiento de la calidad, con su impacto potencial y la solución adoptada.

Reto	Impacto potencial	Solución adoptada
Erratas tipográficas acumuladas en la fuente	Celdas válidas se descartarían por una etiqueta mal escrita	Normalización explícita y documentada de las erratas conocidas; lo imparseable se conserva como UNK con el valor crudo intacto
Ambigüedad de siglo del formato `DDMMMYY`	Un año de dos dígitos puede leerse un siglo antes o después del real	Pivote de siglo y guarda de época: toda fecha anterior a t_0 detiene el proceso en lugar de truncar en silencio
Coerción automática del literal `NA` al leer los archivos	La anotación de ausencia se convertía en valor nulo y borraba el régimen	Centinela explícito `UNK` y lectura con la coerción desactivada
Un mismo mes publicado en dos rutas del portal	Una observación entrenable podía perderse al azar al eliminar el duplicado	Deduplicación por preferencia de régimen; si dos fechas publicadas discrepan, el proceso se detiene para revisión humana
Naturaleza dispersa de las series	Las celdas en régimen C o U no aportan fecha y se manifiestan como huecos	El régimen se conserva como anotación, solo las celdas con fecha son objetivo, y el censo identifica 136 series con fecha y 74 evaluables
Reproducibilidad y volumen de los artefactos	51 MB entre instantáneas, archivos crudos y derivados que deben poder reconstruirse	Versionado con Git y con control de versiones de datos, respaldo en la nube y grafo de dependencias que reconstruye solo lo que cambió

para que una misma cifra no discrepe entre artefactos. Este conjunto de controles es lo que permite afirmar que la cobertura es del 100 % a nivel de boletín y que el proceso es reproducible por un tercero a partir de las instantáneas congeladas.

El material de respaldo de esta sección se recoge en el Apéndice: el diccionario de las nueve variables del panel (A.1), el catálogo de las áreas y categorías observadas con su número de observaciones (A.2), el registro de limpieza del corte vigente (A.3), la cadena reproducible y el versionado de los artefactos (A.4), una consulta de verificación sobre el almacén que reproduce las 16,323 observaciones entrenables (A.5), el entorno con versiones fijadas y los comandos exactos de reproducción (A.6) y el repositorio público del proyecto (A.7).

1.2 Análisis de datos

Con el panel ya construido y verificado, esta sección lo somete a un análisis exploratorio antes de ajustar cualquier modelo (1.2.1): se caracterizan las series, se documentan los patrones encontrados y se deja constancia de las decisiones de modelado que cada hallazgo induce. Después, con esa evidencia como fundamento, construye la matriz de características que alimentará a los modelos (1.2.2): cada transformación del preprocesamiento responde a un hallazgo concreto del análisis exploratorio.

1.2.1 Análisis exploratorio de datos (EDA)

Propósito y preguntas guía. El análisis exploratorio de datos (*exploratory data analysis*, EDA) es la etapa de descubrimiento que antecede al modelado. Su propósito aquí no es ajustar nada todavía, sino comprender la estructura, la distribución, las relaciones y la calidad del panel obtenido en la sección 1.1, de modo que cada decisión posterior (qué familias de modelos son admisibles, qué transformaciones hacen falta, qué esquema de validación es adecuado) quede fundamentada en evidencia y no en supuestos. El análisis se organizó alrededor de seis preguntas:

1. ¿Qué contiene realmente el panel: cuántas series, de qué longitud y con qué proporción de observaciones utilizables para entrenar?
2. ¿Cómo se distribuye la variable dependiente y, sobre todo, su primera diferencia, que es el objeto que un modelo de series de tiempo debe reproducir?
3. ¿Hay tendencia, estacionalidad o ambas, y con qué fuerza relativa?
4. ¿Las series son estacionarias o exigen diferenciación, y de qué orden?
5. ¿Existen valores atípicos y, de existir, son ruido aislado o desplazamientos estructurales de régimen?
6. ¿Las series se mueven juntas? ¿Alguna anticipa a otra?

Las respuestas se desarrollan a lo largo de la sección y se recapitulan, junto con la decisión de modelado que cada una induce, en las Tablas 14 y 15.

Variables analizadas y su papel en el análisis. El EDA opera sobre las nueve variables del panel largo documentadas en el diccionario de datos (Apéndice A.1). Distinguir su papel es indispensable, porque una de ellas es la variable dependiente, cuatro son dimensiones de corte o de agregación, una es el índice temporal y las tres restantes son equivalencia, régimen y trazabilidad: gobiernan qué observación es utilizable, pero no son insumo predictivo. Confundir una anotación con un insumo es precisamente el tipo de error que el análisis exploratorio busca evitar. La Tabla 8 precisa qué mide cada variable, con qué papel entra en el análisis y qué se hace con ella.

Tabla 8: Papel de cada una de las nueve variables del panel en el análisis exploratorio: una variable dependiente, cuatro dimensiones de corte o de agregación, un índice temporal y tres variables de equivalencia, régimen y trazabilidad. El dominio completo de cada una se documenta en el Apéndice A.1.

Variable	Papel en el EDA	Tratamiento y razón
`days_since_base`	Variable dependiente $y_{p,c,b,t}$ (entero, días)	Objeto central del análisis: se estudian su nivel, su primera diferencia (el avance mensual) y su estructura temporal. Es entero y monótono por construcción salvo en las retrogresiones
`priority_date`	Equivalente en fecha de la dependiente	Se usa solo para las figuras y para expresar los atrasos en años; no se analiza por separado para no duplicar la misma información
`country`	Dimensión de corte (5 áreas)	Define las series y estratifica toda comparación. *All Chargeability* se trata como agrupación residual, no como un país
`category`	Dimensión de corte (21 categorías)	Define las series junto con el área; separa el bloque familiar del bloque de empleo
`table`	Dimensión de corte (FAD, DFF)	FAD y DFF se analizan y se modelan por separado; solo se comparan para dimensionar su brecha
`block`	Dimensión de agregación	Permite censar por bloque y explica la asimetría de cobertura entre familiar y empleo
`bulletin_date`	Índice temporal (mensual)	Ordena cada serie y define la malla; su continuidad es objeto de verificación explícita
`status`	Anotación de régimen (F, C, U, UNK)	Determina qué observación es entrenable. Se analiza su composición, pero los regímenes C y U no son objetivo predictivo y quedan fuera del entrenamiento
`raw_value`	Trazabilidad de la fuente	No entra al análisis cuantitativo: se conserva para poder verificar cualquier celda contra el boletín publicado

Técnicas y herramientas. El análisis combina estadística descriptiva, inspección gráfica y pruebas formales de hipótesis, en ese orden. Primero se observa la estructura; después se

contrasta lo observado con pruebas cuya hipótesis nula está declarada. El censo descriptivo y de completitud dimensiona el panel. Histogramas, diagramas de violín y diagramas de cumbres describen la forma de las distribuciones, mientras que los mapas de calor con agrupamiento jerárquico y la correlación cruzada con retardos estudian las relaciones entre series. La estructura temporal se examina mediante descomposición estacional y funciones de autocorrelación; las pruebas de raíz unitaria, estacionariedad, ruido blanco e independencia formalizan esos diagnósticos. Finalmente, la detección de cambios de régimen y el filtrado robusto separan los desplazamientos estructurales de los atípicos puntuales, y un catálogo de características permite analizar el panel como una tabla en lugar de serie por serie. Todo se ejecuta con software libre, con las versiones fijadas de la Tabla 9, sobre el mismo entorno reproducible descrito en el Apéndice A.6.

Tabla 9: Entorno del análisis exploratorio con las versiones fijadas en el archivo de proyecto del repositorio, y la función que cumple cada componente. El intérprete es el mismo de la fase de obtención (Apéndice A.6) y las versiones se declaran en el mismo archivo de proyecto, de modo que un solo entorno reproduce datos y análisis.

Componente	Versión	Función en el análisis
Python	3.14	Intérprete de todo el análisis
`pandas` [8]	3.0.0	Carga del panel, censo por serie y agregaciones
`numpy`	*fijada por perfil*	Álgebra numérica y estadística de base
`matplotlib` [11]	3.10.8	Motor de todas las figuras, con paleta institucional única
`seaborn` [12]	0.13.2	Diagramas de violín y de caja, y mapas de calor con agrupamiento jerárquico
`statsmodels` [13]	0.14.6	Descomposición estacional, pruebas de raíz unitaria y de estacionariedad, autocorrelaciones, pruebas de ruido blanco y de independencia
`scipy` [14]	1.17.1	Periodograma para la entropía espectral, estimación de densidad de los diagramas de cumbres, asimetría y curtosis
`ruptures` [15]	1.1.9	Detección de cambios de régimen
`pycatch22` [16]	0.4.5	Conjunto canónico de características de series de tiempo
`antropy`	0.2.2	Entropías de permutación y de muestra
`duckdb` [17]	1.5.3	Acceso al panel y consultas de verificación del censo contra el almacén

Cada figura y cada estadístico de esta sección se genera por programa a partir del panel versionado, nunca a mano; el Apéndice A.8 documenta las órdenes exactas, los artefactos que producen y el mecanismo que los mantiene sincronizados con el corte vigente de los datos.

Panorama del panel completo. Antes de profundizar en el piloto, el EDA censa el panel íntegro: las 28,211 observaciones de las 194 series estructurales a lo largo de los 300 boletines se condensan en la Figura 8, donde cada fila es una serie y cada celda un mes clasificado por su comportamiento. Dos rasgos dominan: el 58 % de las celdas tiene fecha

publicada (estado F, las 16,323 observaciones entrenables) y, dentro de ellas, en el 45 % de los meses la fecha **no se movió**. El congelamiento es el comportamiento típico del sistema y la vara natural de cualquier pronóstico. La Tabla 10 resume el censo por bloque y tabla, y la Figura 9 muestra la radiografía de completitud serie por serie. La cobertura es escalonada: 194 series estructurales → 136 con al menos una fecha → 74 plenamente evaluables → 25 piloto (familiar FAD), y es sobre este último nivel donde el EDA profundiza.

Tabla 10: Censo descriptivo del panel por bloque y tabla: series estructurales, observaciones con fecha (estado F) y su proporción, avance mensual mediano, porcentaje de meses congelados (sin movimiento) y número total de retrogresiones. Derivado del censo automático del EDA.

Bloque	Tabla	Series	Obs. F	% F	Avance med. (d)	% congelado	Retros
Familiar	FAD	25	6 964	97 %	21	28 %	126
Familiar	DFF	25	3 225	96 %	0	66 %	2
Empleo	FAD	80	3 859	33 %	0	38 %	203
Empleo	DFF	64	2 275	39 %	0	77 %	58

El EDA cubre las 25 series FAD de preferencia familiar de las cinco áreas piloto. La Figura 10 muestra la categoría F3 a través de las cinco áreas: *All Chargeability* avanza de forma suave y casi monótona, mientras que México y Filipinas exhiben retrocesos pronunciados (retrogresiones) concentrados entre 2002 y 2008, evidencia directa de la heterogeneidad por país-categoría.

Antes de la dinámica temporal conviene dimensionar la *escala* del fenómeno. La Figura 11 ordena, en el boletín de julio de 2026, el atraso vigente de la cola F4 (hermanos de ciudadanos) por área de cargabilidad: una petición presentada en México acumula más de veinticinco años de espera y ninguna de las cinco áreas baja de diecisiete, lo que ilustra tanto la magnitud del rezago como su marcada heterogeneidad entre países.

Vista panorámica. La Figura 12 traza las 25 series familiares de ambas tablas a la vez: todas comparten una **tendencia creciente fuerte** (la fecha de prioridad avanza con los años), pero con pendientes muy distintas por área (México se estanca en varias categorías mientras India y Filipinas escalan con rapidez) y con **retrocesos abruptos** (retrogresiones) visibles como caídas. Estas tres propiedades (tendencia dominante, heterogeneidad por serie y saltos ocasionales) gobiernan el modelado.

Distribución del objetivo y de sus incrementos. La Figura 13 caracteriza la variable dependiente y su primera diferencia: la fecha de prioridad se extiende a lo largo de cuatro décadas, y el **avance mensual** se concentra en valores pequeños y positivos (mediana cercana a un mes) con una cola derecha de saltos grandes y una cola izquierda de retrogresiones (1.8 % en el bloque familiar FAD).

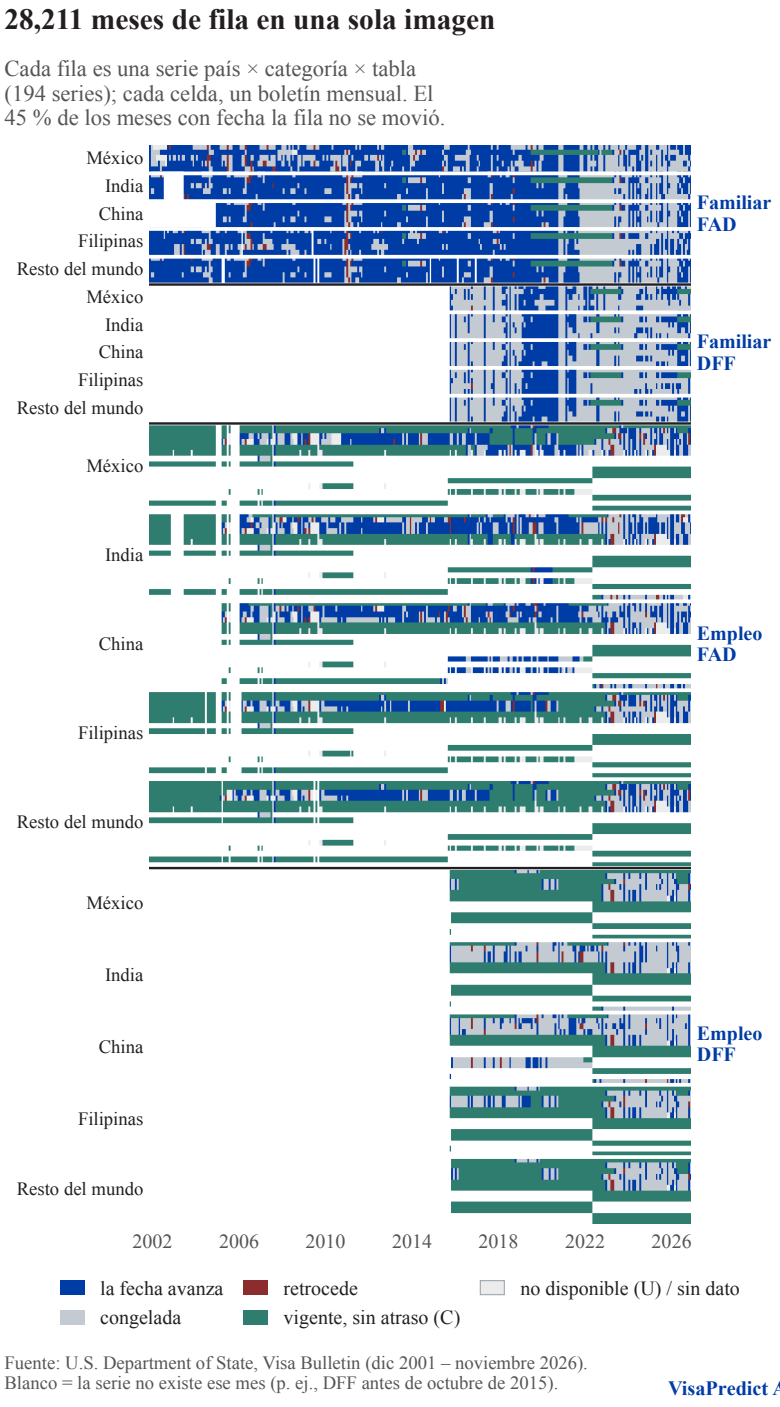


Figura 8: Las 28,211 observaciones del panel en una sola imagen: cada fila es una serie país × categoría × tabla y cada celda un boletín mensual, clasificado según si la fecha avanza, se congela, retrocede, está vigente (*C*) o no se publica. El blanco indica que la serie no existe ese mes (por ejemplo, DFF antes de octubre de 2015).

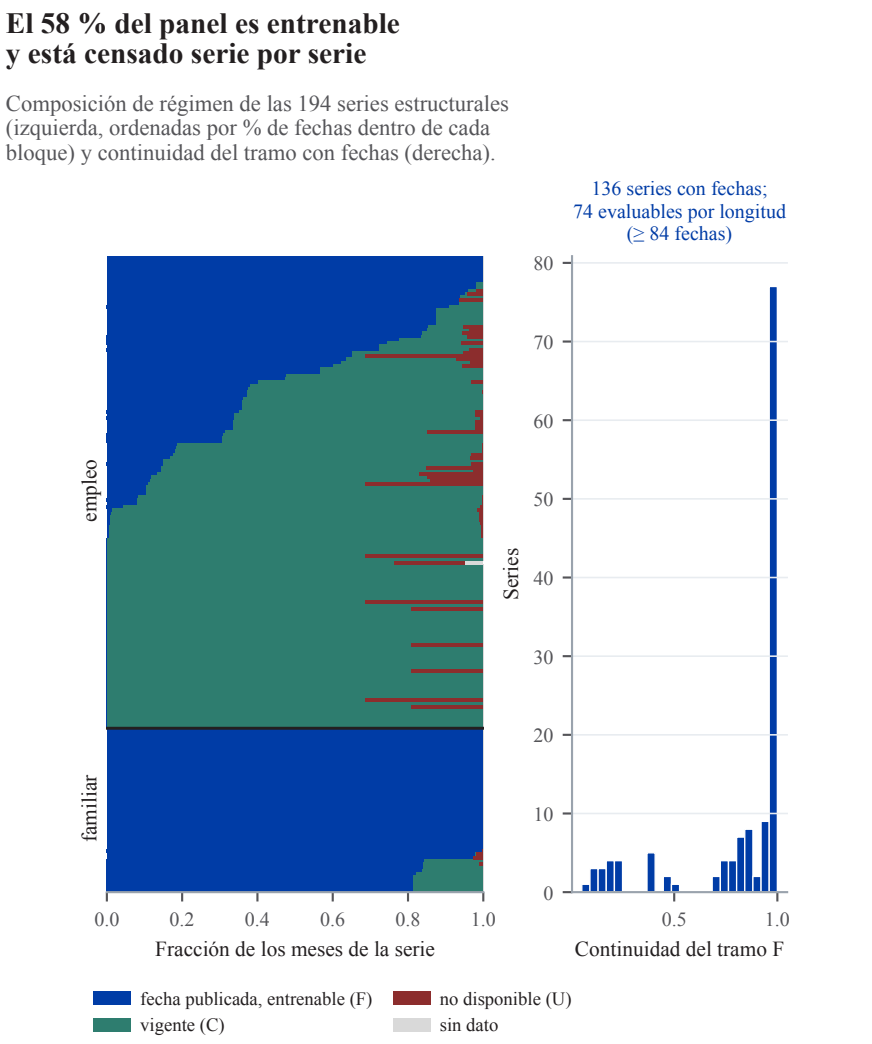


Figura 9: Composición de régimen ($F/C/U$/sin dato) de las 194 series estructurales, ordenadas por proporción de fechas dentro de cada bloque (izquierda), y distribución de la continuidad del tramo con fechas (derecha). El bloque de empleo concentra los periodos vigentes (C) y no disponibles (U); el familiar es casi íntegramente entrenable.

Forma de la distribución por grupo. Los violines de las Figuras 14 y 15, junto con el diagrama de cumbres (*ridgeline*) de la Figura 16, muestran que el avance es marcadamente **asimétrico y de cola pesada** en todas las áreas y categorías: una moda cercana a cero (meses sin movimiento) y una cola derecha que recoge los avances grandes; las categorías de mayor demanda exhiben las colas más largas.

Estructura de régimen y retrogresiones. La Figura 17 descompone cada serie en sus regímenes $C/F/U$: las series familiares son mayoritariamente entrenables (estado F, $\geq$

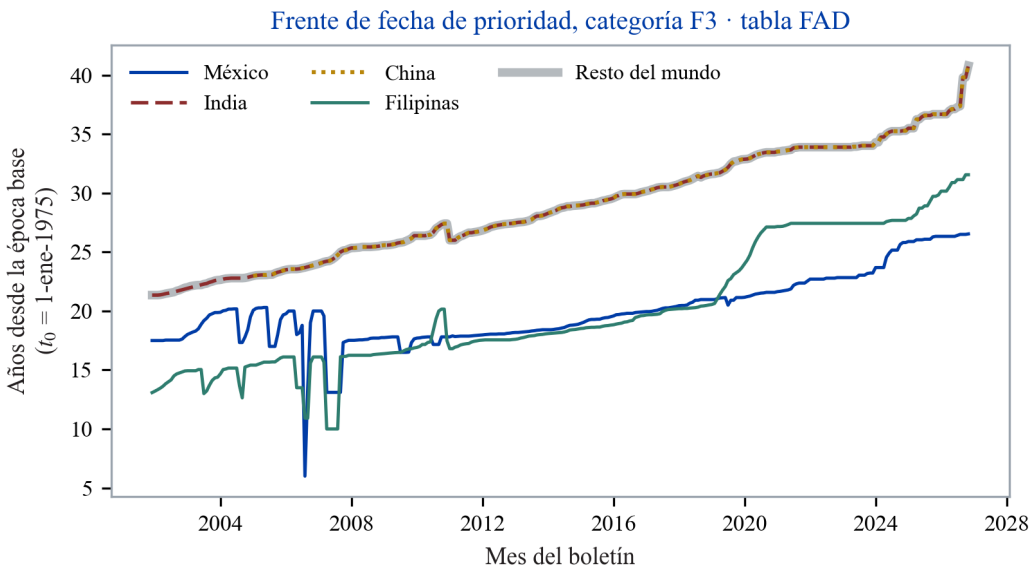


Figura 10: Categoría F3, tabla FAD, a través de las cinco áreas piloto. México y Filipinas siguen trayectorias propias; India, China y el resto del mundo comparten la misma fecha y sus líneas se superponen.

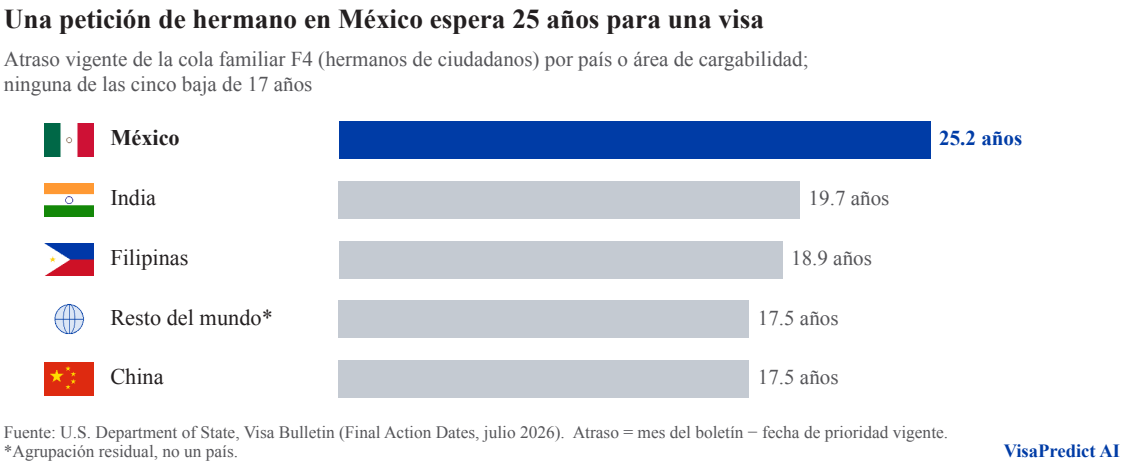


Figura 11: Atraso vigente de la cola familiar F4 (hermanos de ciudadanos de EE. UU.) por país o área de cargabilidad, en el boletín de julio de 2026, ordenado de mayor a menor. El atraso se calcula como la diferencia entre el mes del boletín y la fecha de prioridad vigente. *Resto del mundo* es la agrupación residual *All Chargeability*, no un país.

80 %), salvo la categoría F2A, que pasa con frecuencia a *Current* y reduce su continuidad. La Figura 18 resume la longitud de las series y la incidencia de retrogresiones, concentradas en pocas series (México y Filipinas) pero de gran magnitud (hasta varios años de retroceso).

A escala del panel completo, el censo registra 389 episodios de retrogresión (el 2.4 % de los avances observados, frente al 1.8 % del bloque familiar FAD). La Figura 19 los sitúa

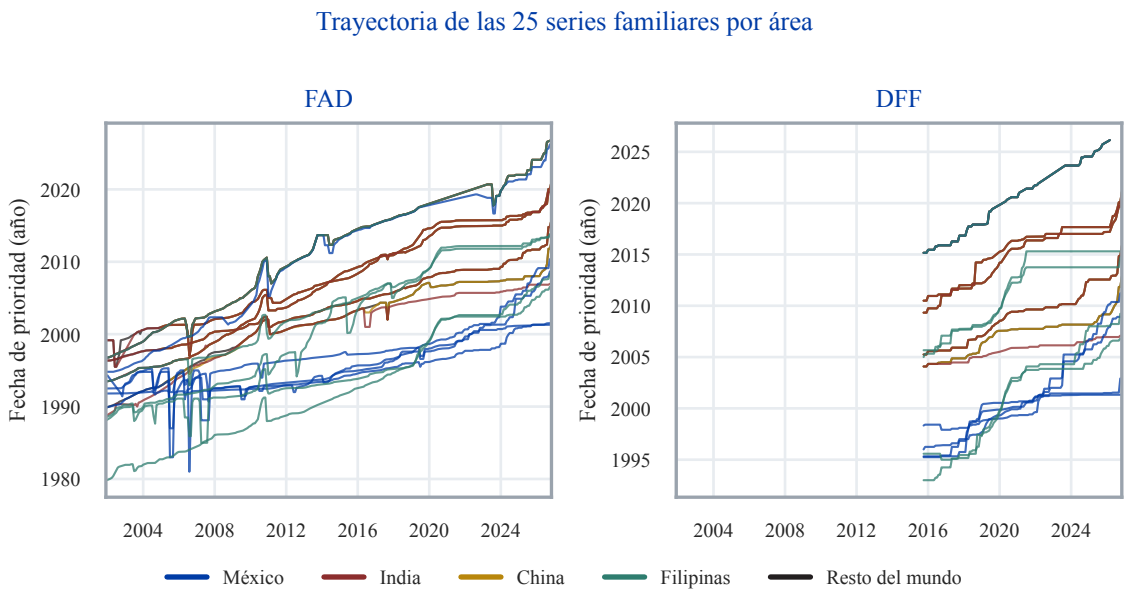


Figura 12: Fecha de prioridad de las 25 series de preferencia familiar a lo largo del tiempo, por área de cargabilidad (FAD y DFF). Predomina una tendencia creciente con pendientes heterogéneas y retrocesos ocasionales.

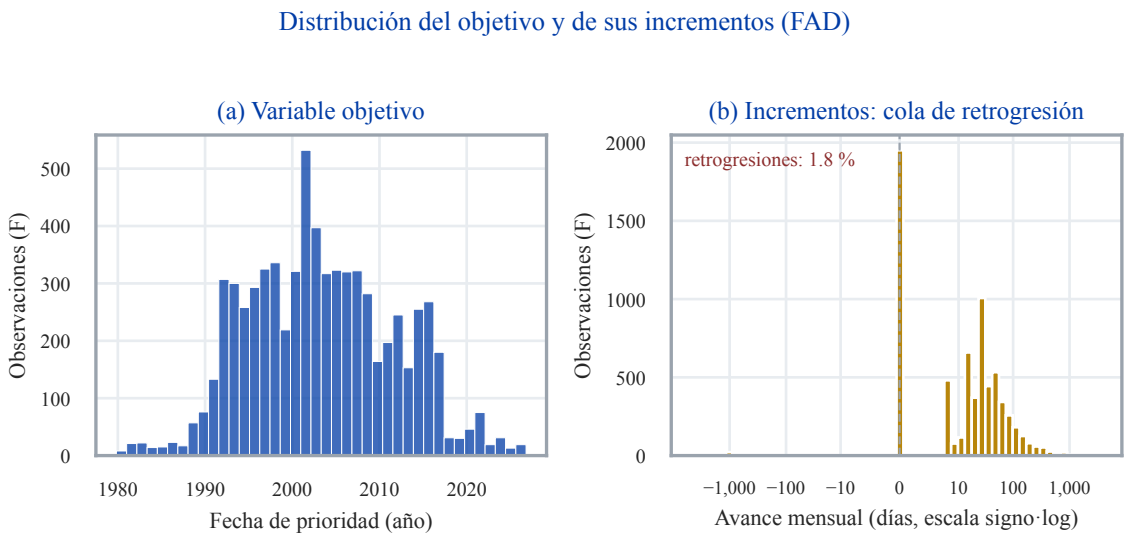


Figura 13: (a) Histograma de la variable objetivo (fecha de prioridad, en años). (b) Histograma del avance mensual en escala signo·log, que revela la cola de retrogresión.

todos en el tiempo: la mayoría son correcciones menores, pero unos pocos son abruptos, con retrocesos de hasta 12.8 años en un solo mes. Esta cola extrema es precisamente lo que el sistema **no** promete predecir (los cambios de régimen quedan fuera del objetivo), pero sí debe tolerar sin degradarse.

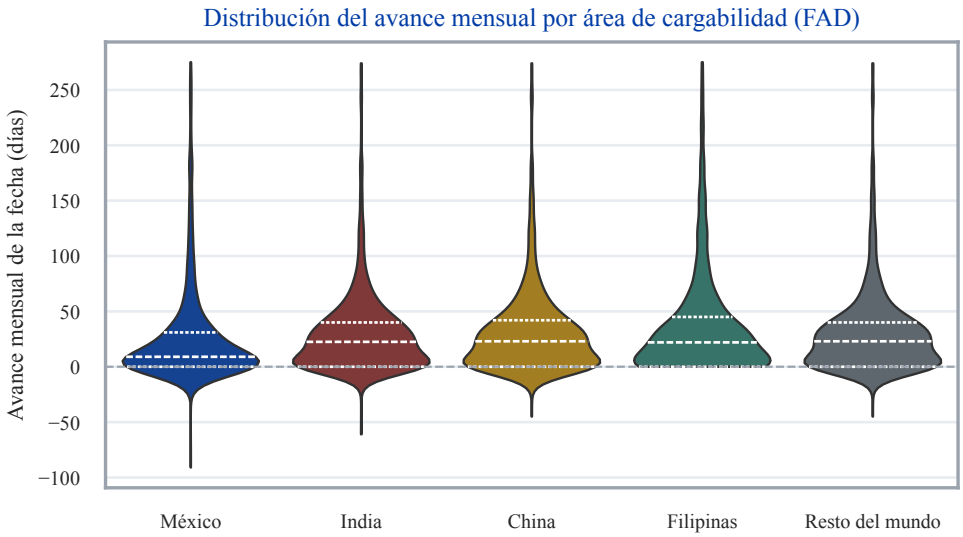


Figura 14: Distribución del avance mensual de la fecha por área de cargabilidad (FAD); las líneas internas marcan los cuartiles. Avance recortado para apreciar la forma.

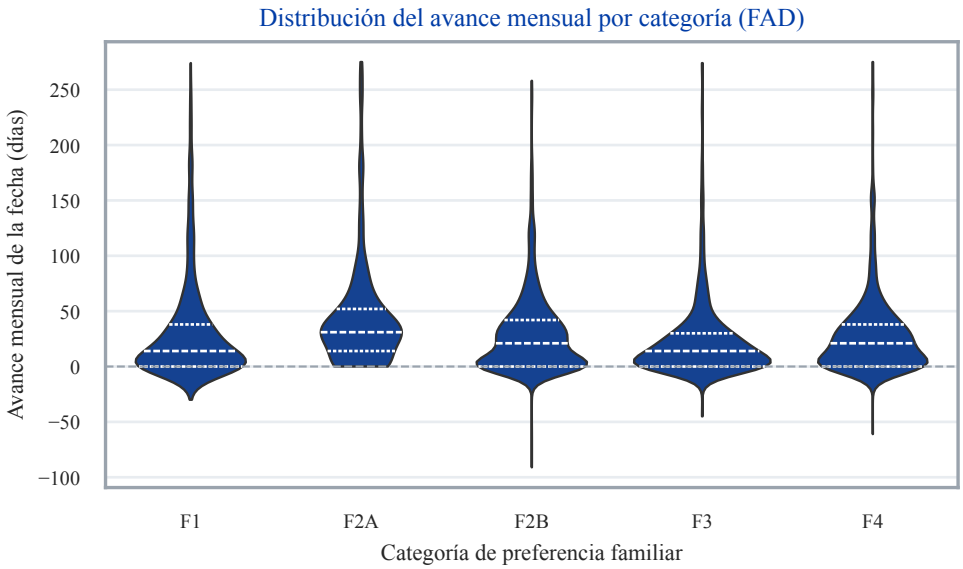


Figura 15: Distribución del avance mensual por categoría de preferencia familiar (FAD); las líneas internas marcan los cuartiles. Avance recortado para apreciar la forma.

Estacionalidad y dependencia entre series. La Figura 20 contrasta el avance por mes calendario: la estacionalidad anual es débil, con un ligero efecto del inicio del año fiscal (octubre). La Figura 21 muestra la correlación entre los incrementos de las 25 series; los bloques de alta correlación agrupan categorías que comparten la fecha mundial, lo que motiva el **entrenamiento global** explotado en la sección 1.4.2.

La Figura 22 resume la continuidad de las series (fracción de meses con fecha publicada).

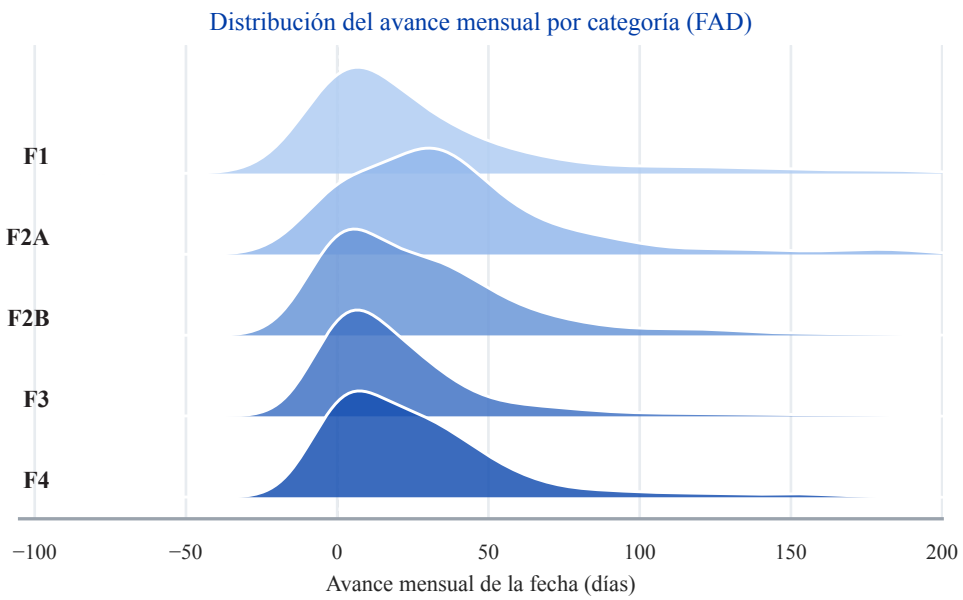


Figura 16: Densidad del avance mensual por categoría (*ridgeline*, normalizada por su pico): todas las categorías comparten la asimetría a la derecha, con colas más largas en las de mayor demanda.

La categoría F2A presenta la menor continuidad (≈80 %) porque transita con frecuencia al régimen *Current*. La Figura 23 muestra la distribución del avance mensual: la masa se concentra en avances pequeños y positivos, con una cola izquierda que corresponde a las retrogresiones que el modelo debe tolerar.

La brecha entre las dos tablas. Como FAD y DFF se modelan por separado, conviene dimensionar su distancia. La Figura 24 compara, serie por serie, el atraso vigente según cada tabla en el boletín más reciente: el calendario de presentación (DFF) antecede sistemáticamente a la acción final (FAD), con una brecha mediana cercana a un año y un máximo de 4.2 años (China, EB-5 no reservada). La brecha no es constante entre series, lo que confirma que las dos tablas son procesos relacionados pero no intercambiables.

La descomposición STL (*Seasonal-Trend decomposition using Loess*)[18] de una serie representativa (Figura 25) confirma una tendencia creciente dominante. La componente estacional es prácticamente nula desde 2012; sus picos anteriores no son estacionalidad, sino las retrogresiones de 2002 a 2010, que la STL reparte entre esa componente y unos residuos volátiles concentrados en el periodo temprano. Las pruebas de estacionariedad lo formalizan: para la serie México/F3/FAD, la prueba de *Augmented Dickey-Fuller* (ADF) no rechaza la raíz unitaria ($p = 0.99$) y la de *Kwiatkowski-Phillips-Schmidt-Shin* (KPSS)[19] rechaza la estacionariedad en nivel ($p < 0.01$); ambas concuerdan en que la serie requiere una diferenciación. Como la prueba ADF pierde potencia precisamente bajo tendencia fuerte y muestras cortas (el escenario de este panel), se añade la prueba DF-GLS de Elliott-Rothenberg-Stock [20], que aplica un *detrending* por mínimos cuadrados generalizados y

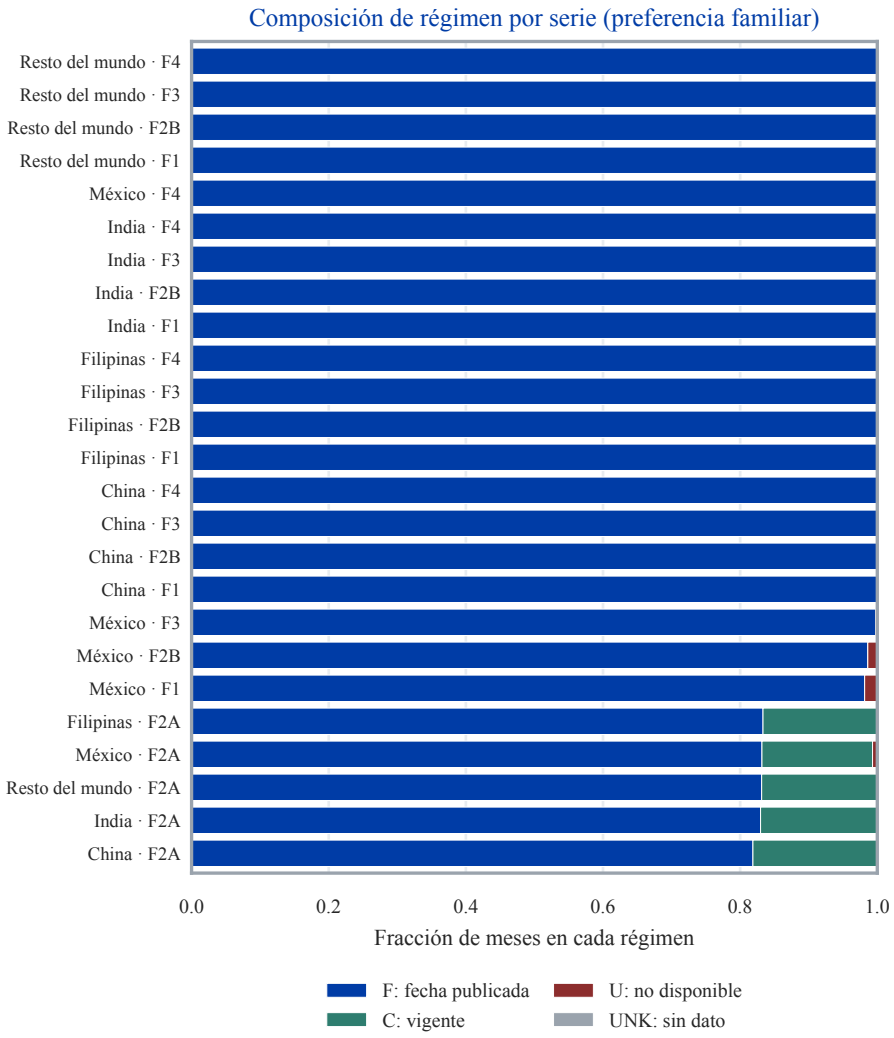


Figura 17: Fracción de meses en cada régimen (*F*/*C*/*U*/UNK) por serie de preferencia familiar, ordenada por proporción entrenable. La categoría F2A concentra los periodos *Current*.

alcanza la envolvente de potencia óptima; también confirma la no estacionariedad en nivel ($p = 0.78$), reforzando de forma más robusta la elección $d = 1$. La Figura 26 muestra la autocorrelación de la serie diferenciada, que orienta el orden de los modelos ARIMA y SARIMA.

El diagnóstico anterior no descansa en una sola serie: el censo automático del EDA aplica la misma batería (ADF, KPSS, DF-GLS, más Ljung-Box sobre los incrementos) a las **74 series plenamente evaluables** del panel. El veredicto es unánime en lo esencial: 71 series exigen diferenciación, 3 presentan señales mixtas (ADF y KPSS discrepan) y **ninguna** es estacionaria en nivel: el panel es integrado de orden 1 sin excepciones. La Tabla 11 reporta el censo para las 25 series piloto; la prueba de Ljung-Box rechaza además el ruido blanco en la mayoría de los incrementos, confirmando estructura temporal aprovechable tras la

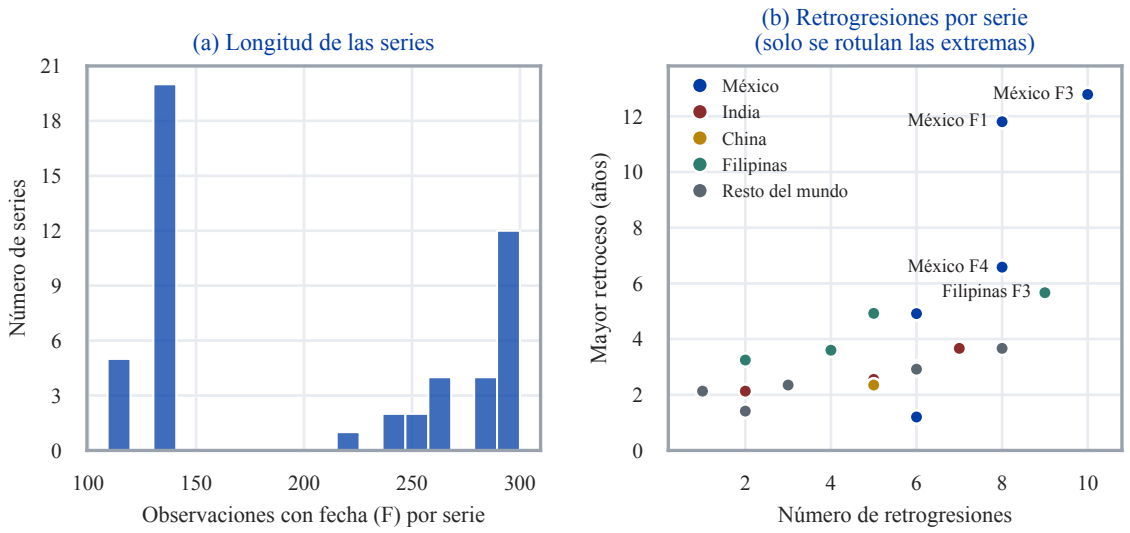


Figura 18: (a) Distribución de la longitud de las series (meses con fecha). (b) Número y magnitud (en años) de las retrogresiones por serie; se concentran en México y Filipinas.

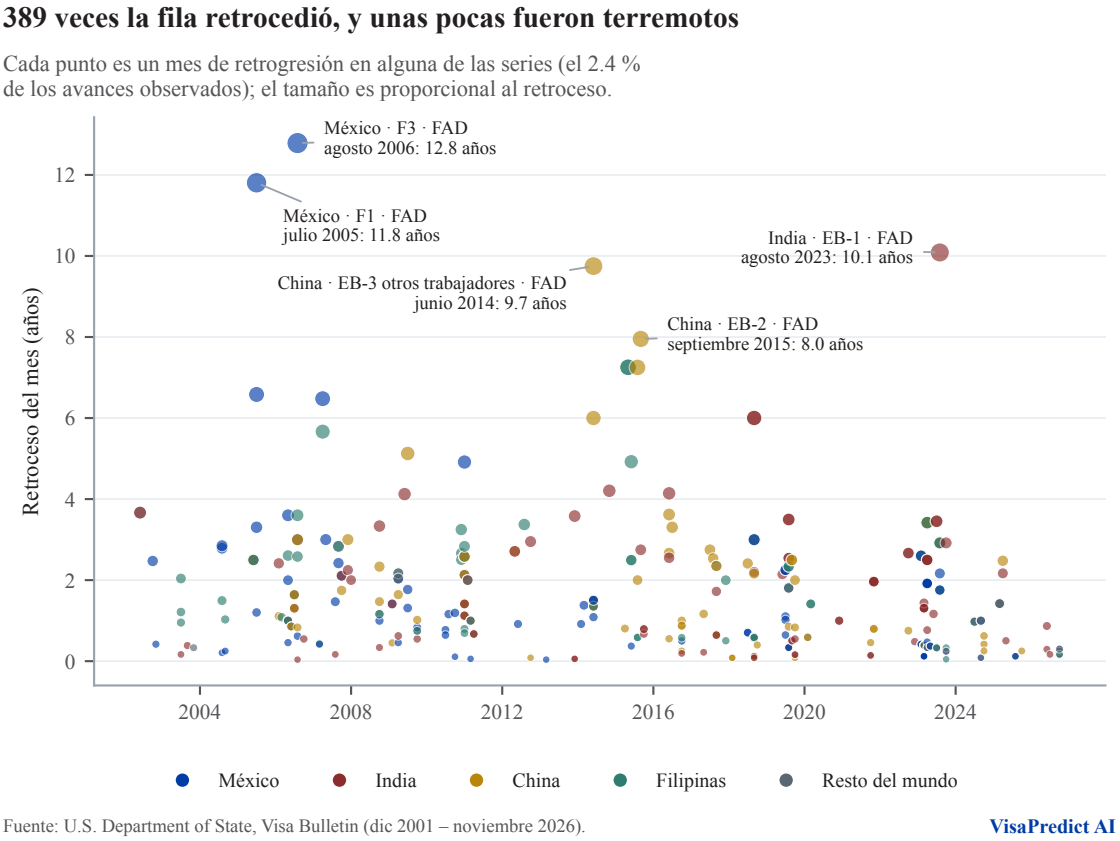


Figura 19: Las 389 retrogresiones del panel completo (2001–2026): cada punto es un mes en que la fecha de una serie retrocedió; el tamaño es proporcional a la magnitud. Se anotan los cinco episodios mayores.

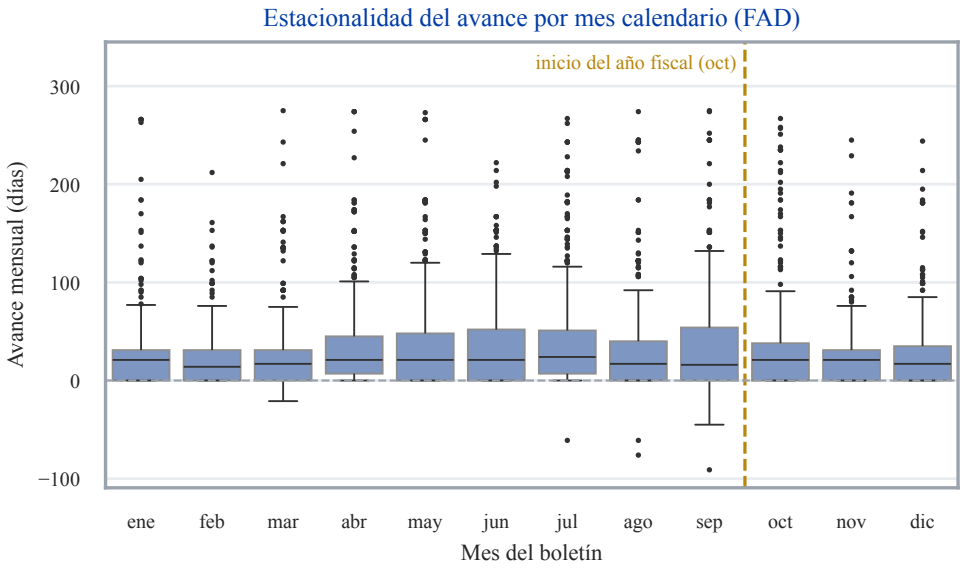


Figura 20: Avance mensual de la fecha por mes del boletín (FAD). La estacionalidad es débil; la línea marca el inicio del año fiscal estadounidense.

diferenciación. (El censo aplica Ljung-Box a rezago 12 sobre los incrementos observados, sin regularizar la malla mensual; el catálogo de características de más adelante en esta sección usa 24 rezagos sobre la serie regularizada, donde el rechazo es unánime; las dos lecturas son complementarias, no contradictorias.)

Bloque de empleo y sorteo de diversidad

El censo panorámico (Tabla 10 y Figura 9) revela por qué el bloque de empleo requiere un tratamiento distinto: solo el 33–39 % de sus celdas tiene fecha publicada (las categorías EB transitan con frecuencia a *Current* o *Unavailable*) y, cuando la hay, el congelamiento domina (38–77 % de los meses sin movimiento, con avance mediano de cero días). Sus retrogresiones son además más frecuentes que las familiares (261 episodios contra 128) y de gran magnitud (Figura 19). Estas propiedades justifican la cobertura escalonada: el bloque EB participa del almacén y del censo desde el primer día, y su evaluación predictiva se restringe a las series que superan el umbral de elegibilidad.

Por último, el sorteo de diversidad (*Diversity Visa*, DV) se explora como hecho descriptivo separado: su valor es un **número de rango** regional, no una fecha, por lo que queda fuera del objetivo predictivo. La Figura 27 muestra las 1,659 observaciones del sorteo: el corte sube dentro de cada año fiscal y se reinicia en octubre (diente de sierra), con África sistemáticamente en los cortes más altos.

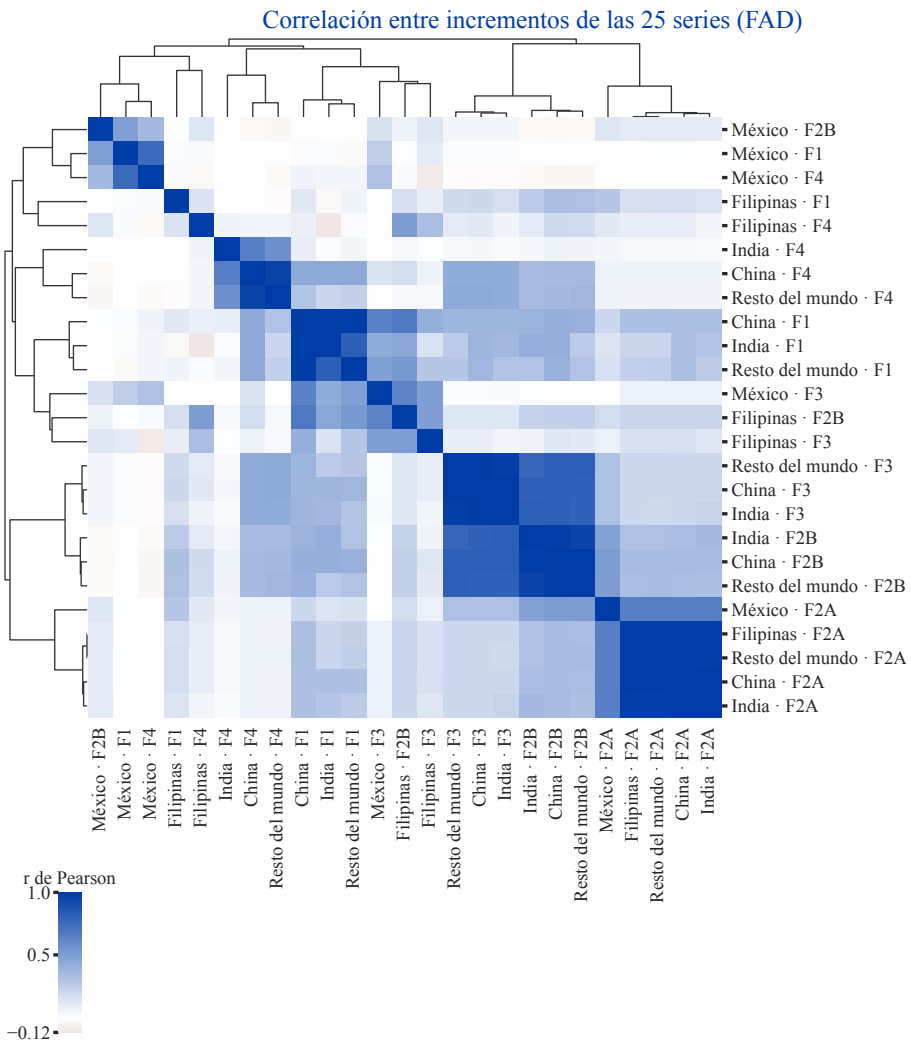


Figura 21: Matriz de correlación (con agrupamiento jerárquico) entre los incrementos mensuales de las 25 series familiares (FAD). Los bloques revelan series que se mueven de forma conjunta.

Catálogo de características por serie

Examinar 25 series una por una no escala. Por ello se adopta el enfoque de análisis basado en características (*feature-based*) [21]: se resume cada serie en un vector de descriptores numéricos comparables, de modo que el panel completo se analiza como una tabla. A continuación se define cada característica, su rango y su lectura operativa para el modelado.

Fuerza de tendencia y de estacionalidad (F_T, F_S). A partir de la descomposición STL $Y_t = T_t + S_t + R_t$ (tendencia, estacionalidad, residuo) se miden, según la formulación de

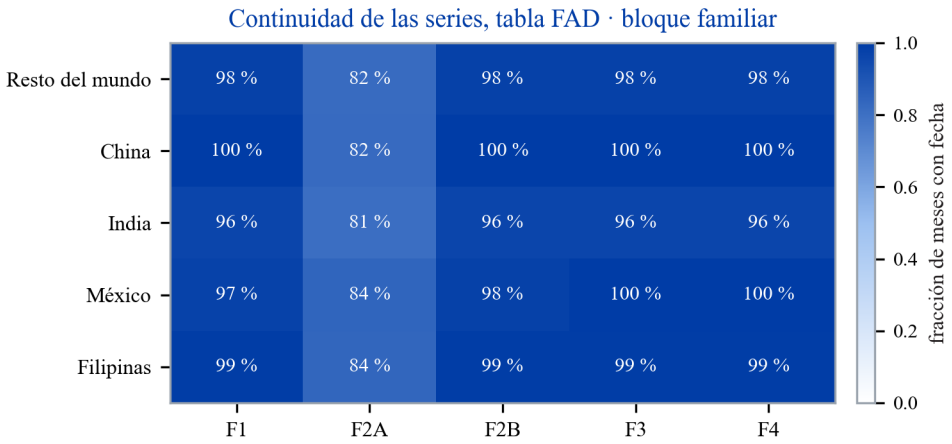


Figura 22: Fracción de meses con fecha publicada por área y categoría (tabla FAD, preferencia familiar).

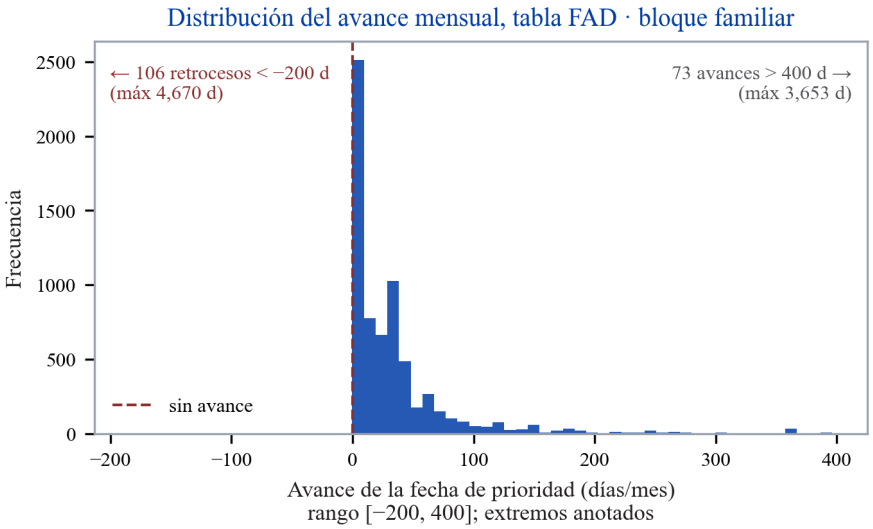


Figura 23: Avance mensual de la fecha de prioridad; la cola izquierda corresponde a las retrogresiones.

descomposición de FPP3 [22],

$$F_T = \max\left(0,\ 1 - \frac{\mathrm{Var}(R_t)}{\mathrm{Var}(T_t + R_t)}\right), \qquad F_S = \max\left(0,\ 1 - \frac{\mathrm{Var}(R_t)}{\mathrm{Var}(S_t + R_t)}\right). \tag{1}$$

Ambas viven en $[0,1]$: un valor cercano a 1 indica que la tendencia (resp. la estacionalidad) explica casi toda la variación más allá del ruido; cercano a 0, que es despreciable.

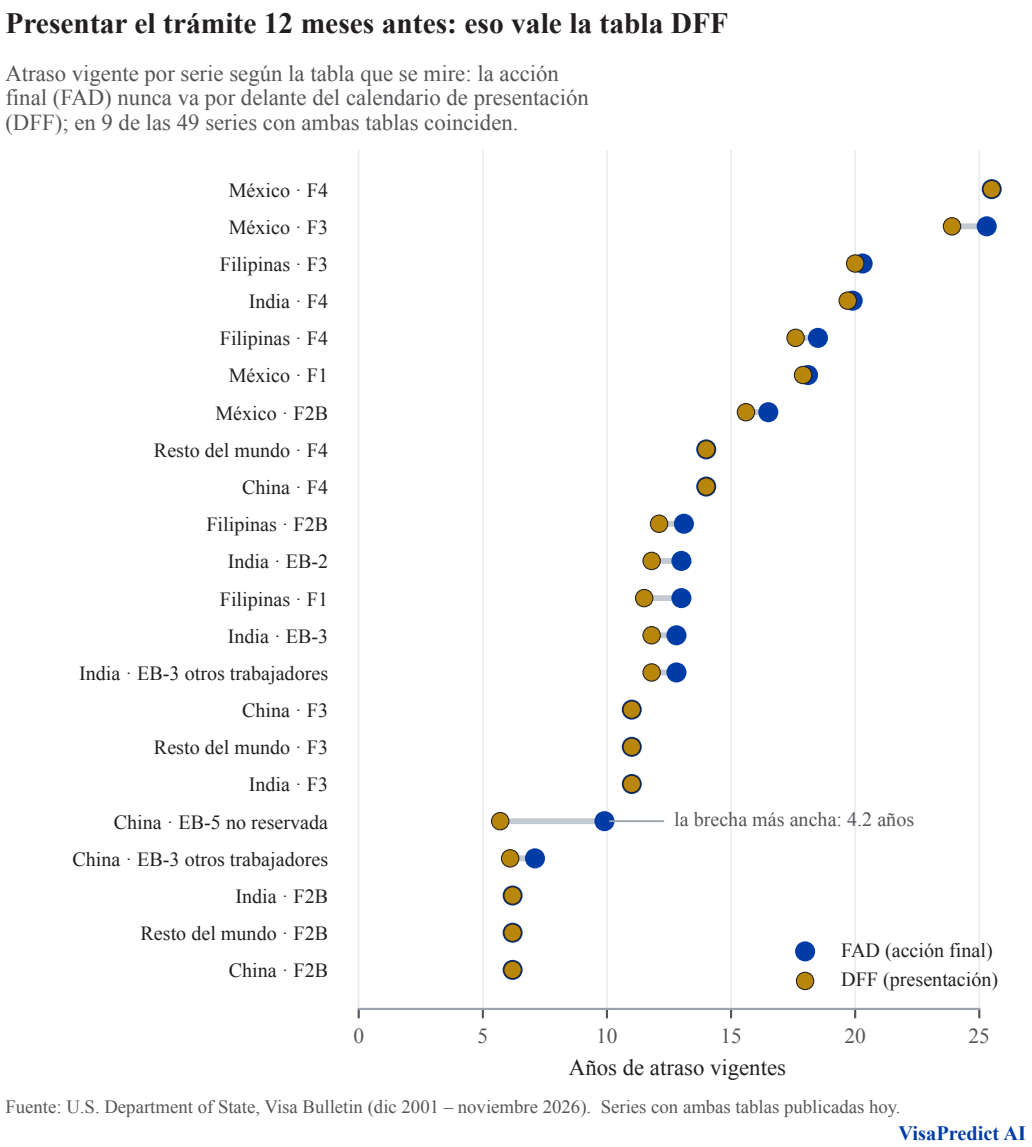


Figura 24: Atraso vigente por serie según la tabla que se mire, en el boletín más reciente: cada segmento une el atraso bajo DFF (presentación) con el atraso bajo FAD (acción final), para las series con ambas tablas publicadas.

Entropía espectral (H). Mide qué tan concentrado está el espectro de la serie. Sobre el periodograma normalizado $\{p_k\}$ (densidad espectral que suma 1),

$$H = \frac{-\sum_k p_k \log p_k}{\log K}, \tag{2}$$

con K el número de frecuencias. $H \to 0$ señala una señal muy estructurada y predecible; $H \to 1$, ruido blanco sin estructura aprovechable.

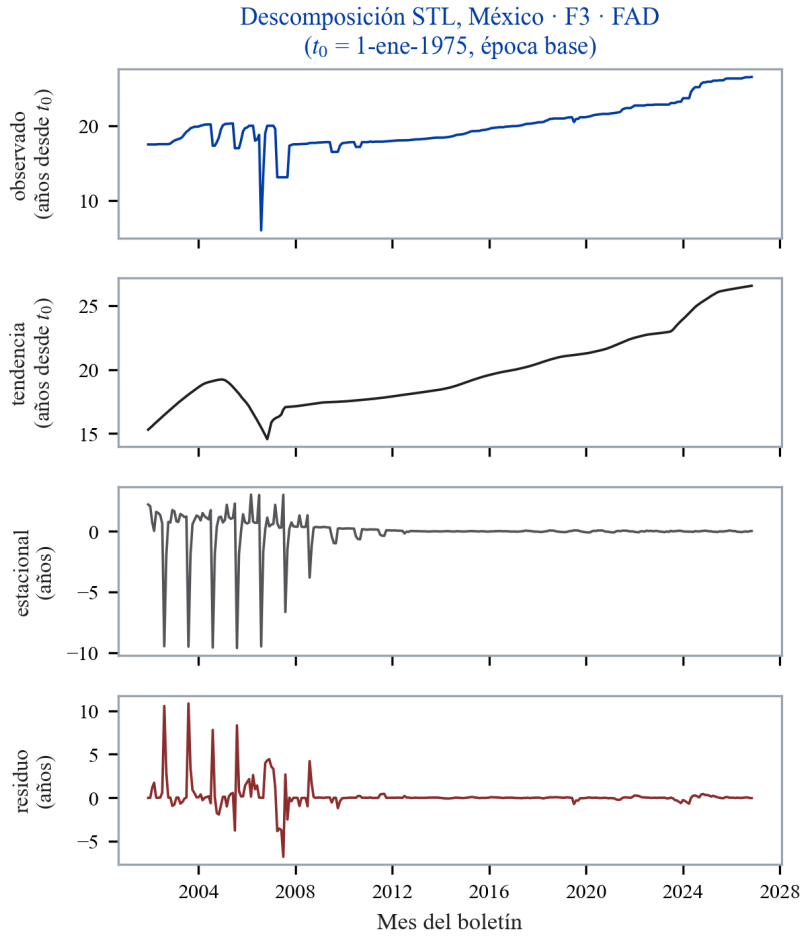


Figura 25: Descomposición STL de México/F3/FAD en tendencia, componente estacional y residuo (en años).

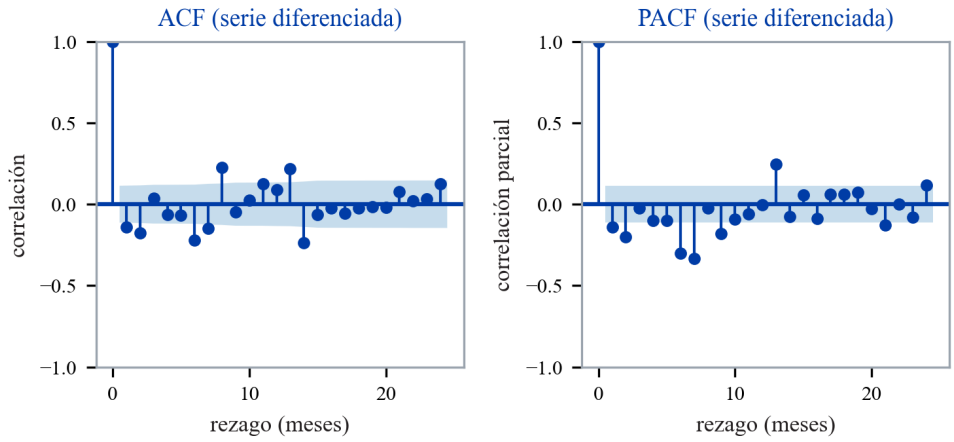


Figura 26: Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie diferenciada México/F3/FAD.

Tabla 11: Censo de estacionariedad de las 25 series piloto (familiar, FAD): p-values de ADF (H_0: raíz unitaria), KPSS (H_0: estacionaria), DF-GLS y Ljung-Box (rezago 12, sobre incrementos), con el veredicto del acuerdo ADF+KPSS. Las 49 series evaluables restantes comparten el veredicto dominante.

Serie	ADF	KPSS	DF-GLS	Ljung-Box	Veredicto
México F1	1.00	<0.01	1.00	<0.001	diferenciar
México F2A	0.98	<0.01	0.01	0.028	diferenciar
México F2B	1.00	<0.01	1.00	0.025	diferenciar
México F3	0.98	<0.01	0.78	<0.001	diferenciar
México F4	0.53	<0.01	0.02	0.002	diferenciar
India F1	0.99	<0.01	0.13	<0.001	diferenciar
India F2A	0.99	<0.01	0.03	0.003	diferenciar
India F2B	0.91	<0.01	0.24	<0.001	diferenciar
India F3	1.00	<0.01	0.56	0.024	diferenciar
India F4	0.00	<0.01	0.98	0.021	mixto
China F1	1.00	<0.01	0.35	<0.001	diferenciar
China F2A	0.99	<0.01	0.10	0.007	diferenciar
China F2B	0.89	<0.01	0.36	<0.001	diferenciar
China F3	1.00	<0.01	0.67	0.030	diferenciar
China F4	0.91	<0.01	0.43	0.613	diferenciar
Filipinas F1	0.87	<0.01	0.09	0.199	diferenciar
Filipinas F2A	0.99	<0.01	0.08	0.002	diferenciar
Filipinas F2B	0.90	<0.01	0.13	0.002	diferenciar
Filipinas F3	0.99	<0.01	0.56	<0.001	diferenciar
Filipinas F4	0.99	<0.01	0.38	0.004	diferenciar
Resto del mundo F1	0.99	<0.01	0.13	0.002	diferenciar
Resto del mundo F2A	0.99	<0.01	0.07	0.002	diferenciar
Resto del mundo F2B	0.95	<0.01	0.30	<0.001	diferenciar
Resto del mundo F3	1.00	<0.01	0.70	0.012	diferenciar
Resto del mundo F4	0.90	<0.01	0.40	0.445	diferenciar

Autocorrelación (ACF1, $ACF1_{\Delta}$). ACF1 es la autocorrelación de rezago 1 del nivel; $ACF1_{\Delta}$, la de la serie diferenciada. Un ACF1 cercano a 1 confirma alta persistencia (memoria larga); el signo de $ACF1_{\Delta}$ orienta el término de media móvil de un ARIMA.

Orden de diferenciación (d). Número de diferencias necesarias para estacionariedad, determinado de forma iterativa con la prueba KPSS (FPP3 §9.1): mientras KPSS rechace la estacionariedad, se diferencia y se reintenta. Alimenta directamente el parámetro d de ARIMA.

Atípicos. Número de residuos de la STL cuyo z-score robusto (basado en la mediana y la desviación absoluta mediana, criterio de Iglewicz-Hoaglin) supera 3 en valor absoluto. Cuantifica la carga de anomalías (en este dominio, las retrogresiones).

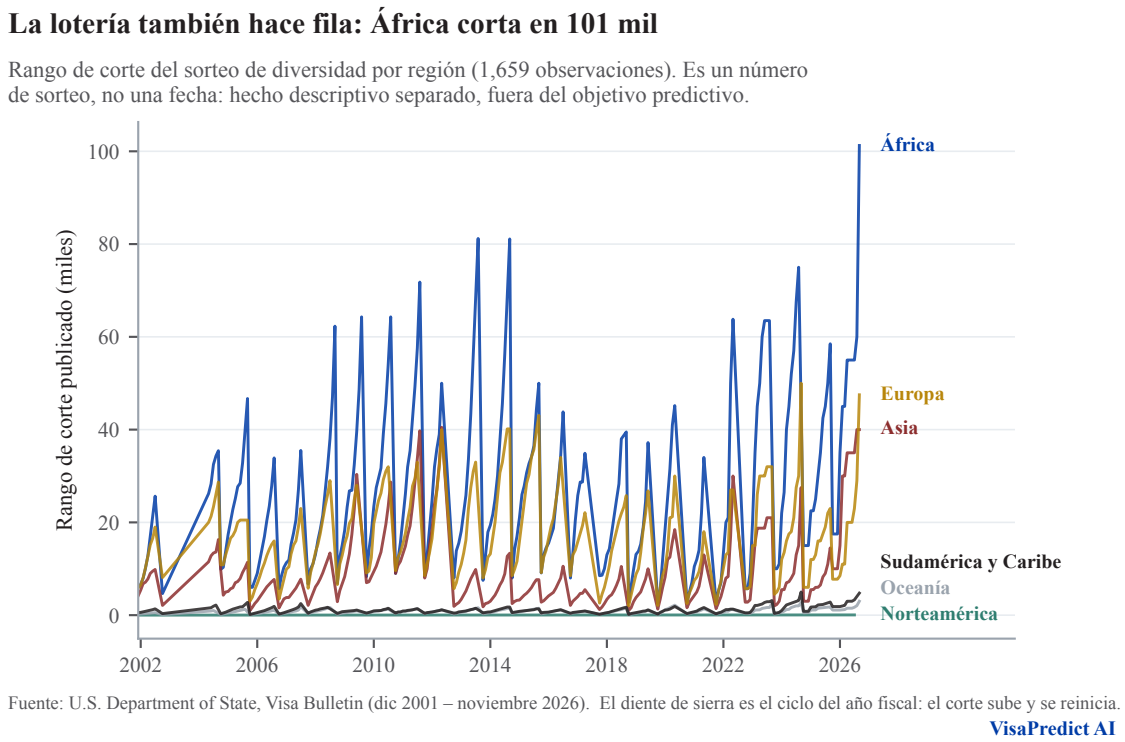


Figura 27: Rango de corte del sorteo de diversidad por región (2001–2026). El patrón de diente de sierra corresponde al ciclo del año fiscal; el valor es un número de sorteo, no una fecha, y queda fuera del objetivo predictivo del sistema.

Ruido blanco (Ljung-Box, LB p). P-valor de la prueba de Ljung-Box sobre $2m = 24$ rezagos (FPP3 §2.9); la hipótesis nula es que la serie es ruido blanco. Un p pequeño confirma que queda estructura temporal modelable.

Asimetría y curtosis. Sobre la distribución de los avances mensuales: la asimetría capta el sesgo (las retrogresiones producen colas izquierdas) y la curtosis, el peso de las colas (eventos extremos).

Las Tablas 12 y 13 reportan estos descriptores para las 25 series, rederivados hasta noviembre de 2026. Las medidas de estabilidad y *lumpiness* (varianza de medias y de varianzas por bloque) se calculan en el módulo pero se omiten de las tablas por ser dependientes de la escala en días; quedan en el registro reproducible.

Lectura de la Tabla 12 (estructura). El panel presenta tendencia fuerte: la fuerza F_T supera 0.99 en la mayoría de las series; entre las menores se encuentran MX/F3 con $F_T = 0.776$, MX/F1 con 0.936 y PH/F3 con 0.967. La fuerza de estacionalidad F_S es prácticamente nula en todo el panel ($F_S < 0.23$, con muchas series exactamente en 0). Esta descripción no demuestra ausencia de estacionalidad ni explica por sí sola las diferencias

Tabla 12: Estructura temporal de las 25 series FAD de preferencia familiar. F_T/F_S: fuerza de tendencia y estacionalidad; H: entropía espectral; d: orden de diferenciación. Códigos de área: CN China, IN India, MX México, PH Filipinas, RoW *Resto del mundo* (*All Chargeability*).

Área	Cat.	F_T	F_S	H	ACF1	$ACF1_\Delta$	d
CN	F1	0.992	0.000	0.315	0.985	+0.285	1
CN	F2A	0.991	0.000	0.352	0.986	+0.145	1
CN	F2B	0.997	0.028	0.313	0.987	+0.175	1
CN	F3	0.991	0.000	0.374	0.980	+0.027	1
CN	F4	0.987	0.000	0.387	0.979	−0.124	1
IN	F1	0.988	0.000	0.319	0.987	+0.218	1
IN	F2A	0.994	0.000	0.331	0.988	+0.146	1
IN	F2B	0.998	0.027	0.282	0.990	+0.166	1
IN	F3	0.992	0.000	0.356	0.984	+0.030	1
IN	F4	0.993	0.000	0.336	0.988	−0.062	1
MX	F1	0.936	0.227	0.403	0.959	+0.043	2
MX	F2A	0.993	0.000	0.318	0.988	+0.133	1
MX	F2B	0.997	0.066	0.355	0.984	+0.081	2
MX	F3	0.776	0.000	0.432	0.923	−0.142	1
MX	F4	0.947	0.000	0.405	0.973	−0.019	1
PH	F1	0.991	0.000	0.250	0.991	+0.116	1
PH	F2A	0.994	0.000	0.331	0.988	+0.146	1
PH	F2B	0.995	0.021	0.276	0.990	+0.156	1
PH	F3	0.967	0.058	0.331	0.982	+0.075	1
PH	F4	0.997	0.000	0.323	0.989	+0.220	1
RoW	F1	0.990	0.004	0.313	0.986	+0.212	1
RoW	F2A	0.994	0.000	0.331	0.988	+0.146	1
RoW	F2B	0.998	0.025	0.282	0.990	+0.182	1
RoW	F3	0.992	0.000	0.356	0.984	+0.031	1
RoW	F4	0.993	0.000	0.353	0.985	−0.130	1

predictivas entre SARIMA y ARIMA. La autocorrelación de nivel ACF1 ronda 0.98 a 0.99 (persistencia alta, coherente con la tendencia), y el orden de diferenciación es $d = 1$ salvo dos series mexicanas que requieren $d = 2$. La Figura 28 visualiza las diferencias entre series en estos dos descriptores, con predominio de tendencia frente a estacionalidad.

Lectura de la Tabla 13 (anomalías y forma). La prueba de Ljung-Box rechaza el ruido blanco en las 25 series ($p < 0.001$ en todas): hay estructura temporal que un modelo puede aprovechar. La distribución de los avances es marcadamente no gaussiana: la asimetría es mayoritariamente negativa (las retrogresiones generan colas izquierdas) y la curtosis es extrema (entre 20.5 y 103.9), lo que señala eventos atípicos frecuentes.

Cambios de régimen frente a anomalías puntuales

El conteo de la columna "Atípicos" (28–84) proviene de un z-score robusto por punto y, por sí solo, confunde dos fenómenos distintos. Un diagnóstico de mayor nivel los separa:

Tabla 13: Anomalías y forma de la distribución de los avances. Atípicos: residuos STL con $|z| > 3$; LB p: p-valor de Ljung-Box (H0 ruido blanco); asimetría y curtosis de los avances mensuales.

Área	Cat.	Atípicos	LB p	Asim.	Curt.
CN	F1	64	0.000	−2.25	46.1
CN	F2A	72	0.000	−3.18	28.7
CN	F2B	28	0.000	−2.32	61.8
CN	F3	49	0.000	+5.49	88.3
CN	F4	46	0.000	−0.36	40.9
IN	F1	76	0.000	−4.61	54.0
IN	F2A	64	0.000	−3.39	33.0
IN	F2B	30	0.000	−2.27	66.4
IN	F3	54	0.000	+5.87	100.6
IN	F4	56	0.000	−3.11	49.4
MX	F1	75	0.000	−2.62	100.1
MX	F2A	73	0.000	−5.34	71.7
MX	F2B	65	0.000	+1.15	20.5
MX	F3	84	0.000	−4.83	80.3
MX	F4	66	0.000	−3.41	79.9
PH	F1	83	0.000	−6.25	57.7
PH	F2A	62	0.000	−3.38	33.0
PH	F2B	65	0.000	−4.05	66.9
PH	F3	79	0.000	+0.89	48.8
PH	F4	62	0.000	−7.41	103.9
RoW	F1	64	0.000	−3.61	46.2
RoW	F2A	66	0.000	−3.39	33.0
RoW	F2B	31	0.000	−2.37	69.3
RoW	F3	54	0.000	+5.87	100.6
RoW	F4	45	0.000	−0.29	53.5

por un lado, los **cambios de régimen** (desplazamientos estructurales duraderos) se detectan con el algoritmo PELT (*Pruned Exact Linear Time*) [23] sobre la serie estandarizada; por otro, las **anomalías puntuales** (observaciones aisladas) con un filtro de Hampel sobre el residuo de la STL (mediana y MAD locales). Aplicado a México/F3/FAD, el método identifica **solo 3 cambios de régimen**, una medida distinta de los 84 residuos atípicos. Las anomalías puntuales aparecen tanto en 2002–2008 como en fechas posteriores (Figura 29). Los diagnósticos distinguen fenómenos, pero no atribuyen por sí solos los residuos atípicos a cambios de régimen. Su efecto predictivo debe contrastarse mediante validación temporal y métricas robustas.

Diagnósticos avanzados de complejidad y memoria. Para completar la caracterización se calcula, por serie, el exponente de Hurst (mediante análisis de fluctuación sin tendencia), la entropía de permutación y de muestra, la λ óptima de Box-Cox y la prueba de Zivot-Andrews (raíz unitaria con un quiebre endógeno), además del conjunto canónico de 22 características *catch22* [16], un subconjunto de alto rendimiento seleccionado entre más de siete mil descriptores. En México/F3/FAD el exponente de Hurst supera 1 (fuera del

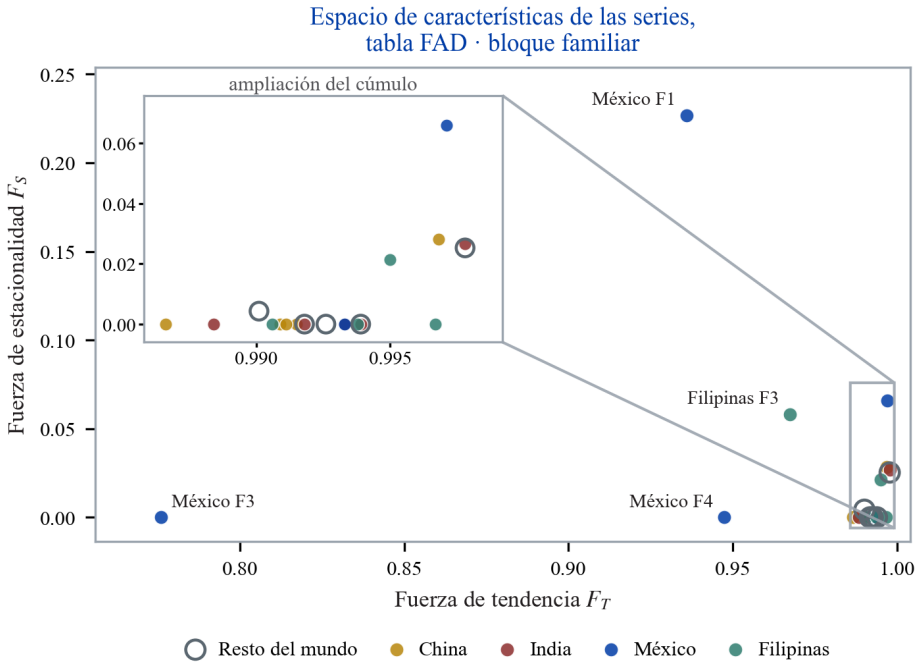


Figura 28: Cada serie como un punto en el plano fuerza de tendencia-fuerza de estacionalidad. En esta representación predomina la tendencia frente a la estacionalidad.

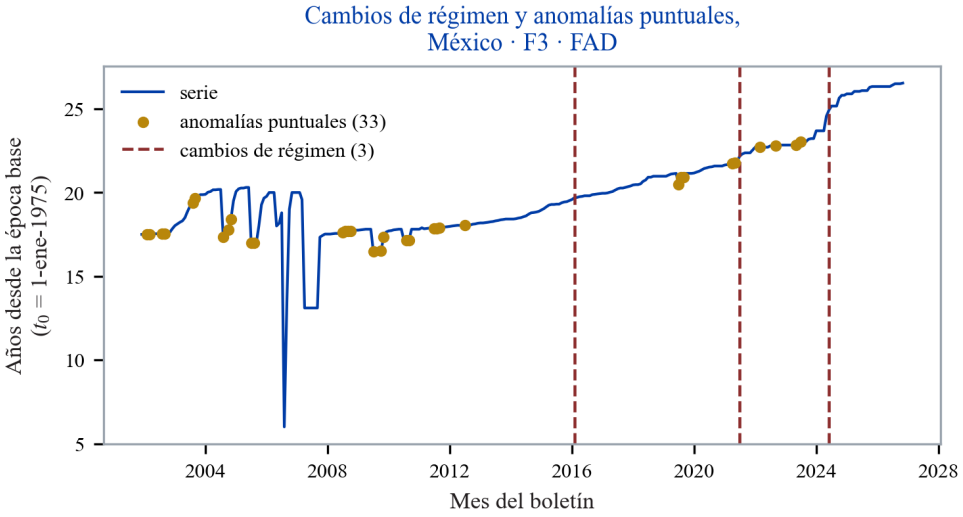


Figura 29: Cambios de régimen (PELT, líneas verticales) frente a anomalías puntuales (filtro de Hampel, marcadores) en México/F3/FAD. PELT ubica tres cambios de régimen en el tramo reciente; la retrogresión de 2006, que se revierte en pocos meses, no queda marcada como cambio de régimen, lo que ilustra el límite del detector ante episodios breves y extremos.

rango canónico $[0,1]$), por lo que se reporta como diagnóstico descriptivo y no como prueba de memoria larga; véase la lectura de este diagnóstico más adelante en esta sección. Las entropías de permutación y de muestra son bajas (≈ 0.13–0.17, señal de regularidad descriptiva, sin garantizar precisión fuera de muestra); la λ de Box-Cox queda cerca de 1, sin que ese valor por sí solo demuestre varianza constante; y Zivot-Andrews rechaza la raíz unitaria tras una diferencia ($p < 0.001$), reforzando la elección $d = 1$. Finalmente, la prueba BDS de Brock-Dechert-Scheinkman-LeBaron [24] (cuya hipótesis nula es que la serie diferenciada es independiente e idénticamente distribuida) se rechaza con fuerza ($p < 0.001$). El rechazo de independencia e idéntica distribución no identifica por sí solo una dependencia no lineal ni demuestra superioridad de LSTM, DeepAR o XGBoost. Su comparación predictiva se decide con el protocolo temporal de evaluación.

Caracterización retrospectiva de la dificultad por serie

Con muestras de 134–300 observaciones por serie, cada grado de libertad cuenta, por lo que el conjunto unido de características de caracterización (catch22 y descriptores de pronóstico y de diagnóstico) se somete a un análisis formal de relevancia en dos pasos. Primero, un filtro de relevancia univariada con corrección de multiplicidad de Benjamini-Yekutieli (el patrón del algoritmo FRESH [25]) que controla la tasa de falso descubrimiento. Segundo, una des-redundancia por correlación de Spearman, en el espíritu de la selección de mínima redundancia y máxima relevancia (mRMR) [26], que conserva una sola característica representativa de cada grupo colineal. Es importante acotar qué es este análisis: una **caracterización retrospectiva de la dificultad**, que relaciona descriptores calculados sobre la serie completa con el error absoluto medio escalado (*Mean Absolute Scaled Error*, MASE) del conjunto reservado del modelo campeón para describir *qué* series resultan difíciles de pronosticar. No es una selección predictiva de insumos (los modelos consumen los rezagos, el calendario y las máscaras de ausencia a través del motor de características, no estos descriptores) ni una prueba libre de filtración (los descriptores ven la serie completa). Sobre 50 series con campaña y 44 descriptores candidatos, con este protocolo y el control de falso descubrimiento establecido no se detectaron asociaciones que superaran el umbral entre los descriptores evaluados y la dificultad de pronóstico. Este resultado no demuestra ausencia de señal ni permite comparar el rendimiento predictivo de conjuntos de características, porque los modelos no consumen estos descriptores. La des-redundancia previa responde a que las bibliotecas de características de series de tiempo comparten buena parte de su información [27].

Nota sobre la ingeniería de características viva. Igual que el EDA, la ingeniería de características y la limpieza mantienen un catálogo versionado. Este reúne las 12 decisiones de limpieza y 9 de características, cada una con el módulo que la implementa y la falla que previene, además del registro de limpieza de cada consolidación y del resultado vigente de

la selección. El catálogo se regenera de forma automática con cada boletín nuevo junto con su galería de figuras y un reporte ejecutivo en PDF. Ambos son consultables públicamente desde la aplicación de demostración (Apéndice A).

Métodos del estado del arte evaluados y descartados por diagnóstico

Una revisión amplia de la literatura confirmó que varias familias de técnicas en boga *no aplican* a este problema, y descartarlas con criterio es parte del análisis. La descomposición estacional múltiple (MSTL) y las pruebas de raíz unitaria estacional (HEGY, OCSB) son innecesarias porque la estacionalidad es prácticamente nula ($F_S < 0.23$). El exponente de Hurst mayor que 1 indica no estacionariedad pura, no memoria larga fraccional, por lo que los modelos ARFIMA y los estimadores de tipo GPH son inapropiados. La familia de descomposición empírica (EMD, EEMD, CEEMDAN) y de *wavelets* usada como "descomponer y luego pronosticar" es notoria por inflar la exactitud mediante fuga de información hacia el futuro, incompatible con la validación walk-forward de este trabajo. Las representaciones modernas por convoluciones aleatorias (ROCKET y variantes), *shapelets* y diccionarios simbólicos (BOSS, WEASEL) están diseñadas para la *clasificación* de series como objetos, no para la regresión temporal autorregresiva de un panel; y las firmas de camino (*path signatures*) aportan sobre todo en escenarios multivariados, mientras que aquí el objetivo es univariado. Documentar estas exclusiones evita la falsa impresión de carencia: son decisiones fundamentadas, no omisiones.

Estructura cruzada del panel. Como el objetivo es un panel multiserie, se examina además el co-movimiento entre áreas. La Figura 30 muestra la correlación de los avances mensuales entre las cinco áreas para la categoría F3: India, China y *All Chargeability* se mueven casi al unísono (correlación ≈ 1), pues comparten el frente mundial cuando no están rezagadas, mientras que México y Filipinas evolucionan de forma independiente por sus rezagos propios. Esta separación entre un grupo "mundial" y series país-específicas respalda la heterogeneidad por país-categoría y orienta posibles modelos globales que compartan información dentro del grupo mundial.

El censo extiende este análisis con correlación cruzada a retardos de ± 6 meses sobre el bloque familiar FAD completo (Figura 31): en **todas** las parejas de áreas la mejor correlación ocurre en el retardo cero: el co-movimiento, donde existe, es contemporáneo y ningún área anticipa a otra. Esto descarta usar un país como indicador adelantado de otro y refuerza la decisión de modelar cada serie con su propia dinámica.

Síntesis: hallazgos del análisis y decisiones que inducen

Un análisis exploratorio no termina en la descripción: termina cuando cada hallazgo se traduce en una decisión verificable sobre el modelado. Las Tablas 14 y 15 recapitulan

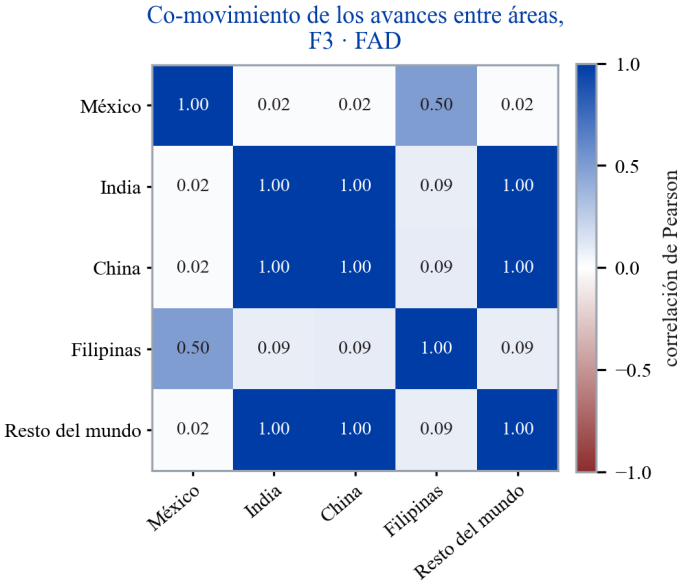


Figura 30: Correlación de los avances mensuales entre áreas para la categoría F3. India, China y el resto del mundo (*All Chargeability*) se mueven al unísono; México y Filipinas se apartan de ese grupo (entre ellas, $r = 0.50$).

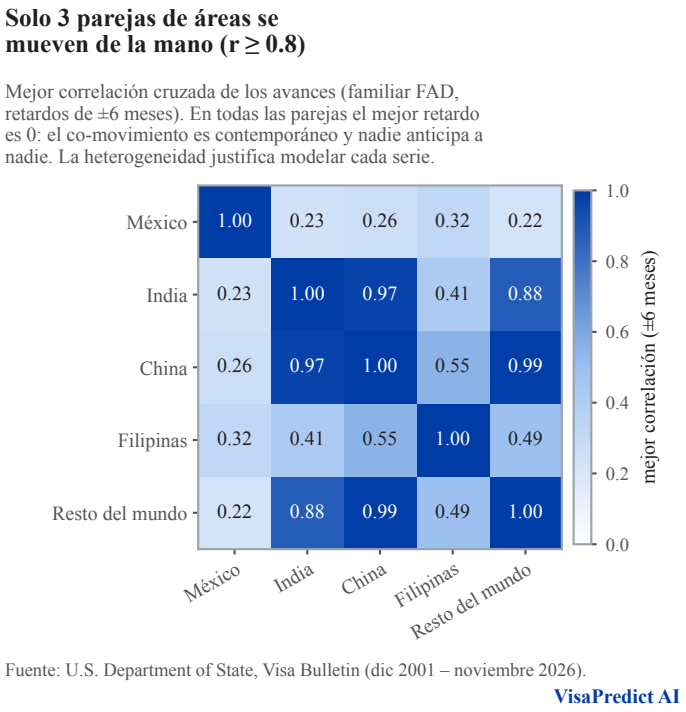


Figura 31: Mejor correlación cruzada de los avances entre áreas (familiar FAD, retardos de ± 6 meses). En todas las parejas el máximo ocurre en el retardo cero: el co-movimiento es contemporáneo.

los doce hallazgos principales, la evidencia concreta que los sostiene y la consecuencia de cada uno para la fase siguiente. La primera reúne los hallazgos sobre estructura, cobertura y forma de los datos. La segunda presenta los relativos a anomalías, dependencias entre series y alcance de lo que el sistema puede prometer. Leídas en conjunto, describen un panel de series fuertemente tendenciales, sin ciclo anual, integradas de orden uno, con distribuciones de avance asimétricas y de cola pesada, con anomalías mayoritariamente estructurales y con un co-movimiento contemporáneo que no permite usar un área como indicador adelantado de otra.

Tabla 14: Síntesis del análisis exploratorio (1 de 2): hallazgos sobre la estructura, la cobertura y la forma de los datos, con la evidencia que los sostiene y la consecuencia que cada uno induce sobre el diseño del modelo y de su validación.

Hallazgo	Evidencia	Consecuencia para el modelado
El congelamiento es el comportamiento típico: el 45 % de los meses del panel no registra movimiento (28 % en familiar FAD, 66 % en familiar DFF)	Tabla 10, Figura 8	Un pronóstico ingenuo de un paso es un piso exigente, no un adorno: toda comparación de modelos debe incluirlo y ningún modelo puede declararse útil sin superarlo
Los faltantes no son ruido de captura sino régimen: solo el 58 % de las celdas tiene fecha, y en el bloque de empleo la proporción cae a 33–39 %	Tabla 10, Figura 9	Se entrena exclusivamente sobre las observaciones con estado F; C y U se conservan como anotación. La cobertura evaluable es escalonada y se declara de antemano
Tendencia dominante y estacionalidad prácticamente nula ($F_T > 0.99$ en la mayoría de las series, $F_S < 0.23$ en todas)	Tabla 12, Figura 28	Los términos estacionales no tienen materia prima que explotar: no se espera que SARIMA mejore a ARIMA, y las pruebas de raíz unitaria estacional resultan innecesarias
Ninguna serie es estacionaria en nivel: 71 de las 74 evaluables exigen diferenciación y 3 dan señales mixtas	Tabla 11	El panel es integrado de orden uno: se modela sobre la primera diferencia con $d = 1$, salvo dos series mexicanas que requieren $d = 2$
Queda estructura temporal aprovechable tras diferenciar: Ljung-Box rechaza el ruido blanco en las 25 series piloto	Tabla 13, Figura 26	Los modelos autorregresivos tienen señal que capturar; el orden se orienta con las funciones de autocorrelación de la serie diferenciada
La distribución de los avances es asimétrica y de cola pesada (asimetría negativa en 20 de las 25 series, curtosis de hasta 104)	Figuras 13, 14 y 16	Se descarta el supuesto gaussiano: la evaluación usa métricas robustas y los intervalos de predicción se construyen por cuantiles empíricos, no por desviación estándar

Tabla 15: Síntesis del análisis exploratorio (2 de 2): hallazgos sobre las anomalías, las dependencias entre series y el alcance de lo que el sistema puede prometer, con la evidencia que los sostiene y su consecuencia sobre el diseño del modelo y de su validación.

Hallazgo	Evidencia	Consecuencia para el modelado
Las retrogresiones son raras pero extremas: 389 episodios (2.4 % de los movimientos), con retrocesos de hasta 12.8 años en un mes	Figuras 19 y 18	Los cambios de régimen quedan fuera de lo que el sistema promete predecir, pero la validación debe demostrar que el modelo los tolera sin degradarse
Los atípicos son mayoritariamente estructurales: en México/F3 hay 3 cambios de régimen frente a 84 observaciones marcadas como atípicas	Figura 29	No se recortan ni se imputan como si fueran ruido; se conservan y se emplea validación progresiva con ventanas móviles, que respeta el orden temporal
La prueba BDS rechaza que la serie diferenciada sea independiente e idénticamente distribuida ($p < 0.001$); por sí sola no prueba no linealidad	Diagnósticos avanzados de esta sección	Se incluyen modelos no lineales para contrastar esa posibilidad de forma empírica, con el mismo protocolo temporal que los lineales
El co-movimiento entre áreas es contemporáneo: en todas las parejas la mejor correlación cruzada ocurre en el retardo cero	Figuras 30 y 31	Ningún área sirve como indicador adelantado de otra; se descarta esa clase de regresor y se conserva la opción de modelos globales que compartan información dentro del grupo mundial
Las dos tablas no son intercambiables: la brecha entre DFF y FAD tiene mediana cercana a un año y llega a 4.2 años	Figura 24	FAD y DFF se entrenan y se evalúan por separado, y sus resultados nunca se comparan entre sí como si midieran lo mismo
Con este protocolo, de 44 descriptores candidatos ninguno supera el control de falso descubrimiento como asociación con la dificultad (resultado descriptivo, no comparación predictiva)	Selección FRESH y mRMR de esta sección	Los descriptores quedan como caracterización retrospectiva; los modelos siguen consumiendo rezagos, calendario y máscaras de ausencia

Limitaciones del análisis. Tres advertencias acotan lo anterior. Primera, los descriptores por serie se calculan sobre la muestra completa, de modo que describen la dificultad de cada serie de forma retrospectiva y no constituyen insumos libres de filtración para el pronóstico; los modelos consumen rezagos y calendario, no estos descriptores. Segunda, el bloque de empleo se censa pero no se explora con la misma profundidad que el piloto familiar, porque su baja proporción de fechas publicadas limita lo que cualquier diagnóstico puede afirmar sobre él. Tercera, el sorteo de diversidad se describe por completitud del panel, pero su valor

es un número de rango y no una fecha, por lo que no participa del objetivo predictivo ni de las conclusiones de esta sección.

Nota sobre el EDA vivo. Todo el análisis de esta sección (censo estadístico, figuras y un reporte ejecutivo en PDF) se regenera de forma automática con cada boletín nuevo (llegue por el congelado automático o por la carga manual del Apéndice A.6) dentro del mismo proceso continuo que actualiza la base de datos, con verificaciones que impiden publicar un análisis incompleto o inconsistente con la fuente única de cifras del proyecto. El reporte y el censo son consultables públicamente desde la aplicación de demostración (Apéndice A).

1.2.2 Preprocesamiento de datos

Propósito y alcance. El preprocesamiento es la etapa que convierte el panel verificado de la sección 1.1 en la matriz numérica que los modelos pueden consumir, y aplica las familias clásicas de la fase: manejo de valores ausentes, transformación y escalado de variables numéricas, codificación de variables categóricas y selección de características. Aquí ninguna transformación es genérica: cada una responde a un hallazgo concreto del análisis exploratorio (sección 1.2.1) y queda registrada en un catálogo versionado de decisiones (9 decisiones de ingeniería de características, además de las 12 decisiones de limpieza estructural cuyo registro por corte se documenta en el Apéndice A.3), cada una con el módulo de código responsable y su justificación. La restricción que gobierna toda la etapa es temporal: ningún paso puede usar información posterior al origen del pronóstico, porque hacerlo inflaría artificialmente el desempeño medido.

El preprocesamiento construye, a partir de cada serie con fecha, la **matriz de características** que alimenta a los modelos (Figura 32). Aplica cinco transformaciones, todas diseñadas para evitar la fuga de información (*leakage*):

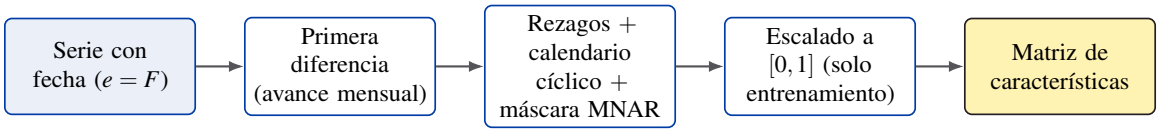


Figura 32: Construcción de la matriz de características: la serie con fecha se diferencia (avance mensual), se le agregan rezagos, codificación cíclica del calendario y una máscara de ausencia, y se escala al rango $[0, 1]$ con el mínimo y el máximo del tramo de entrenamiento.

- **Diferenciación.** La serie de fechas tiene una tendencia fuerte y no estacionaria, y los árboles y las redes *no extrapolan tendencias sobre niveles*: se saturan en el máximo observado. Por ello el objetivo se modela sobre la **primera diferencia** (el avance mensual) y se reintegra a un paso. La transformación vuelve la serie estacionaria y extrapolable (Figura 33); es la palanca que rescata a los modelos de alta capacidad.

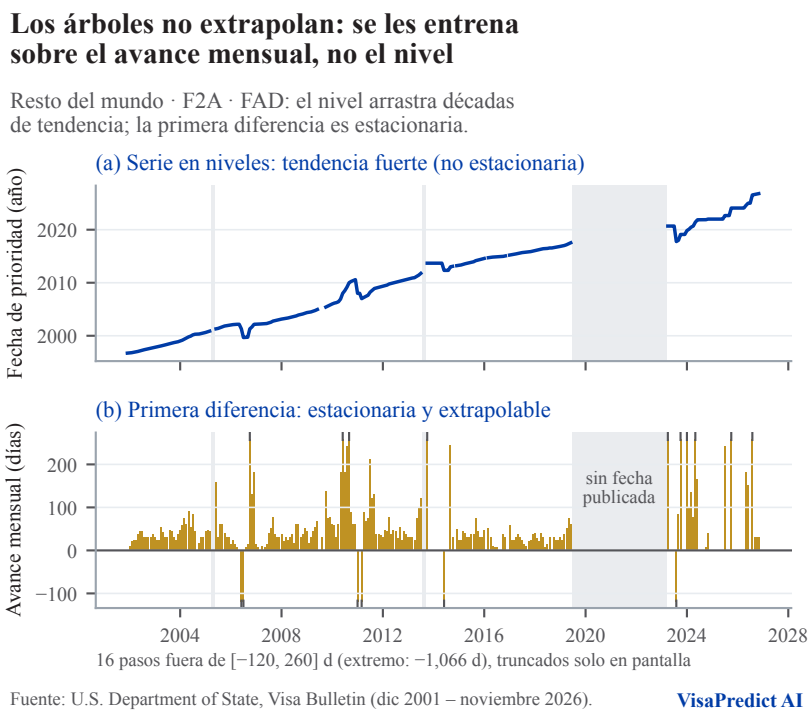


Figura 33: (a) Serie en niveles con tendencia fuerte (no estacionaria). (b) Su primera diferencia (el avance mensual), estacionaria alrededor de una media positiva y por tanto extrapolable por los modelos.

- **Huecos como mecanismo MNAR.** Los meses sin fecha no faltan al azar: corresponden a regímenes *Current*/*Unavailable*, donde estructuralmente no hay fecha que predecir. Es un mecanismo *Missing Not At Random* (MNAR): la ausencia misma es información. Por ello el tratamiento es doble. Para **caracterizar y visualizar** se imputa con suavizado de Kalman sobre un modelo de espacio de estados, el método de referencia de `imputeTS` [28], superior a la interpolación lineal (Figura 34). Para **modelar**, la rejilla mensual de entrenamiento se construye con relleno estrictamente causal. Cada mes sin fecha publicada (*C*/*U*) arrastra la última observación anterior (*last observation carried forward*, LOCF), de modo que el valor de un mes depende solo de observaciones anteriores o iguales a ese mes. Mutar cualquier valor posterior a un origen de pronóstico no altera ningún insumo en ese origen ni antes de él; esta propiedad se verifica mediante pruebas metamórficas automatizadas. La política sustituye a la interpolación lineal bidireccional de las campañas previas, que usaba el extremo futuro de cada hueco. Los valores de relleno jamás se puntúan (solo se califican los meses con fecha publicada, máscara $e = F$).

  Los árboles de gradiente sobre la serie diferenciada reciben además dos máscaras de ausencia MNAR: el indicador de observación y los meses transcurridos desde la última observación. Ambas se incorporan con un retardo de un mes, correspondiente al último mes cerrado y conocido en el origen, para que el modelo pueda descontar los tramos

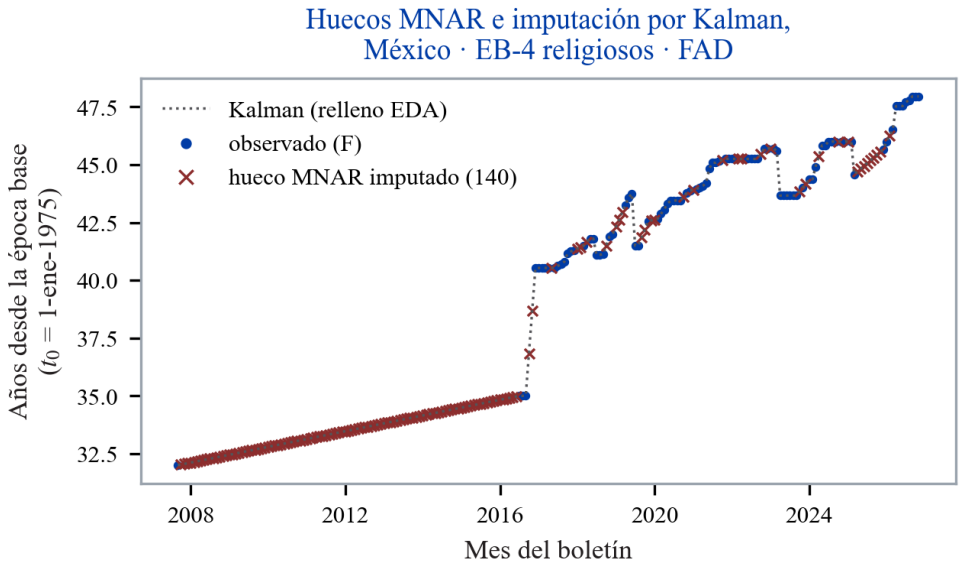


Figura 34: Observaciones con fecha (puntos) y huecos MNAR imputados por suavizado de Kalman (marcadores) en México/EB-4 religiosos/FAD, la serie con las corridas de ausencia más largas del panel. El modelado no usa estos valores imputados: su rejilla se rellena de forma causal con la última observación publicada y los árboles de gradiente reciben las máscaras de ausencia como covariables.

arrastrados. El resto del catálogo usa la política causal hacia adelante explícita, sin covariables de máscara.

- **Regularización mensual.** Para los modelos que exigen frecuencia fija, la rejilla se completa con el mismo relleno causal hacia adelante: todo mes sin fecha arrastra la última observación publicada, sin usar jamás el extremo futuro del hueco (el tope de interpolación de tres meses gobierna hoy solo la rejilla descriptiva del EDA, no la de modelado). La Figura 35 ilustra la política sobre la serie con las corridas de ausencia más largas del panel, y la Figura 36 muestra su contraparte de evaluación: los meses en régimen *Current*/*Unavailable* son anotación descriptiva y solo las fechas efectivamente publicadas se puntúan.

- **Escalado.** Los modelos de redes neuronales requieren entradas escaladas. El escalador normaliza cada serie al rango $[0, 1]$ por mínimo y máximo, y ajusta esos extremos *solo* sobre la ventana inicial de entrenamiento; calcularlos sobre el conjunto completo filtraría el futuro al pasado.

- **Regresores de calendario.** Para los modelos tabulares se construyen variables del mes y de la posición dentro del año fiscal estadounidense (que inicia en octubre, cuando se reinician las cuotas), codificadas de forma cíclica con seno y coseno (Figura 37) para no imponer un orden falso entre diciembre y enero.

Para verificar qué información usan efectivamente los modelos tabulares, la Figura 38 re-

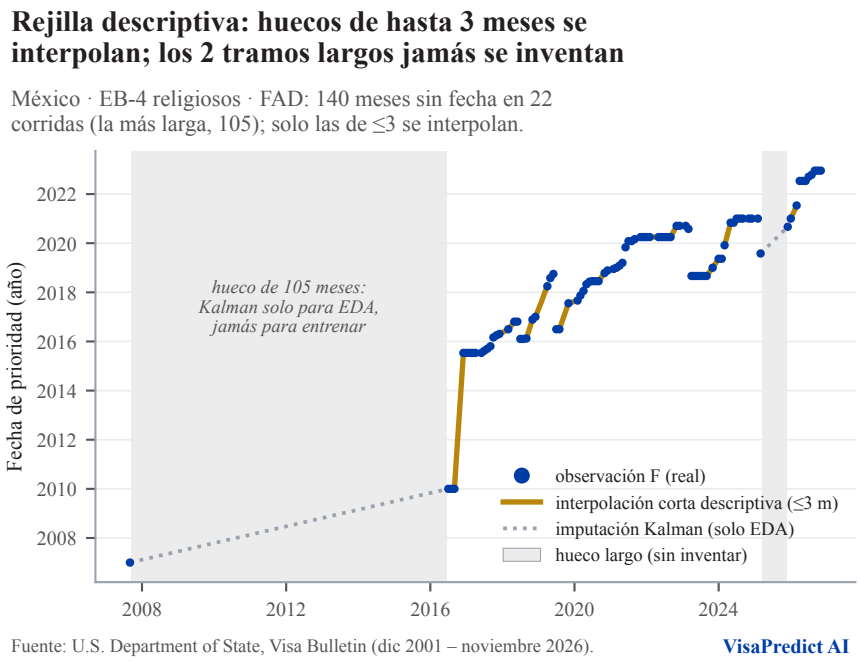


Figura 35: Ausencias de México/EB-4 religiosos/FAD, la serie con las corridas sin fecha más largas: interpolación descriptiva de los huecos de hasta tres meses e imputación de Kalman, solo descriptiva, en los dos tramos largos, que para el modelado quedan sin rellenar. Ningún relleno entra al entrenamiento, cuya rejilla arrastra la última observación publicada.

porta la importancia de características de un árbol de potenciación de gradiente (LightGBM) entrenado sobre el avance mensual, medida por el número de divisiones en que interviene cada variable: los avances de los meses $t-1$ y $t-3$ encabezan el orden casi empatados, seguidos de los demás rezagos cortos y del rezago anual ($t-12$), mientras que los regresores de calendario aportan una señal menor pero no nula, coherente con la débil estacionalidad observada en el EDA.

Codificación de variables categóricas. El panel contiene dos clases de variables categóricas y cada una recibe el tratamiento que su papel exige. Las dimensiones que identifican a la serie (país o área de cargabilidad, categoría y tabla) no se codifican como insumo: los modelos del sistema operan serie por serie, de modo que esas dimensiones actúan como llaves de partición, y convertirlas en columnas numéricas no aportaría información dentro de una serie donde son constantes. Las variables categóricas que sí entran al modelo son temporales: el mes calendario y la posición dentro del año fiscal se codifican de forma cíclica con seno y coseno (Figura 37), y el estado administrativo de cada mes se convierte en las dos máscaras numéricas de ausencia ya descritas (indicador de observación y meses desde la última observación), que entran con retardo de un mes para respetar la causalidad.



Figura 36: Régimen administrativo de cada mes (fondos) y máscara de evaluación (franja inferior) sobre una serie de empleo con episodios vigentes (*C*) y no disponibles (*U*): la línea existe solo donde hay fecha publicada y la evaluación puntúa únicamente esos meses; los rellenos de continuidad del entrenamiento nunca se califican.

Selección de características. La selección se resolvió con la evidencia de la sección 1.2.1: del catálogo de 44 descriptores candidatos por serie, el control de falso descubrimiento de la selección FRESH [25] dejó 0 como relevantes sobre 50 series y la des-redundancia mRMR [26] no rescató ninguno. La consecuencia adoptada en la matriz es una entrada deliberadamente austera (rezagos del propio avance, calendario cíclico y máscaras de ausencia) en lugar de cientos de descriptores mutuamente redundantes, y la importancia por número de divisiones de la Figura 38 confirma que esa poda no sacrifica señal.

La Tabla 16 recapitula las técnicas de preprocesamiento aplicadas, la decisión concreta que cada una tomó en este proyecto y la salvaguarda que impide que la transformación filtre información del futuro hacia el pasado.

Nota sobre el preprocesamiento vivo. Igual que el análisis exploratorio, el preprocesamiento no es un guion ejecutado una sola vez: el catálogo de decisiones, las figuras de esta sección y un reporte ejecutivo en PDF se regeneran de forma automática con cada boletín nuevo, y la construcción de la matriz de características está protegida por pruebas que detectan cualquier cambio no deliberado en su salida. Las órdenes exactas y los mecanismos de trazabilidad se documentan en el Apéndice A.9.

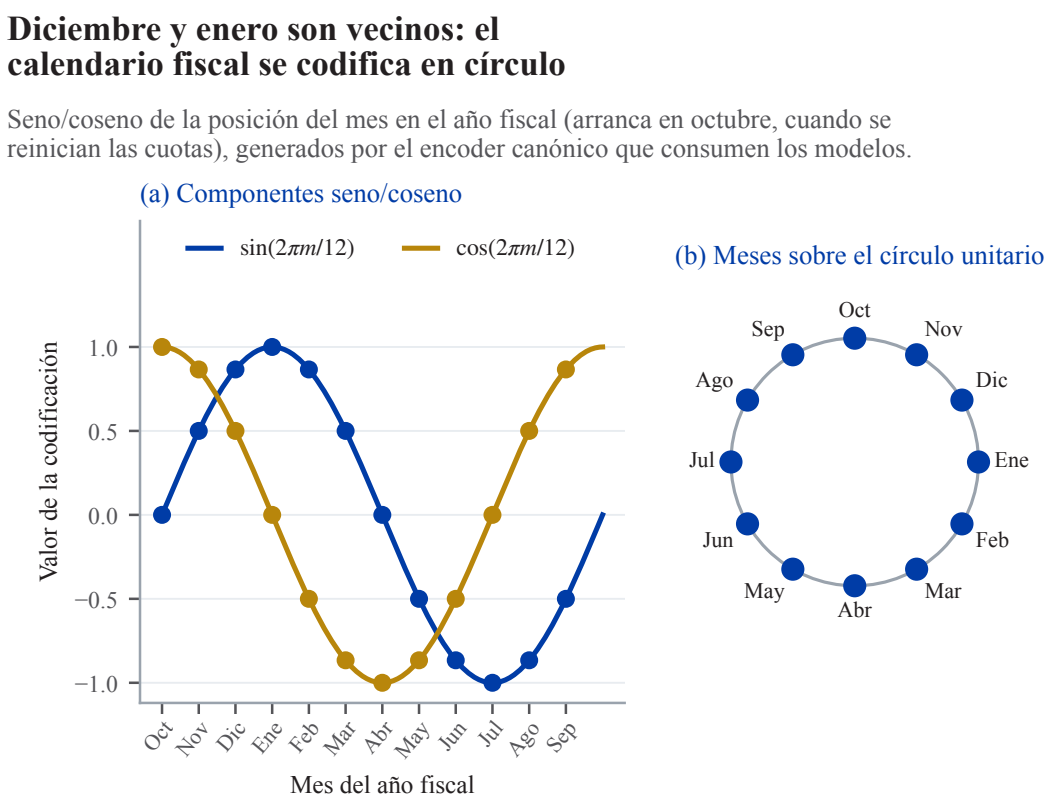


Figura 37: Codificación del mes en el año fiscal estadounidense (inicia en octubre) mediante seno y coseno. (a) Componentes. (b) Sobre el círculo unitario diciembre y enero quedan adyacentes, evitando un orden falso entre meses.

1.3 Diseño del modelo

El diseño del modelo traduce los hallazgos del análisis y las transformaciones de la sección anterior en una comparación predictiva reproducible. Primero se define el tipo de problema y después se seleccionan técnicas con supuestos y capacidades complementarios. Esta separación evita elegir un algoritmo por popularidad: cada familia debe responder a una característica observada del panel y competir bajo el mismo protocolo temporal.

1.3.1 Definición de las técnicas de modelado a utilizar

Formulación del problema. VisaPredict AI aborda una regresión temporal en panel: para cada combinación de país o área de cargabilidad, categoría migratoria y tipo de tabla, pronostica una fecha de prioridad futura. No es una tarea de clasificación, porque la variable de interés es ordenada y cuantificable; tampoco es agrupamiento, pues las series y sus identificadores ya están definidos. FAD y DFF se modelan por separado, y el entrenamiento usa únicamente las celdas con fecha publicada (estado *F*). Los estados *Current* (*C*) y *Unavailable* (*U*) se conservan como información de régimen, sin convertirlos en fechas ni en etiquetas objetivo.

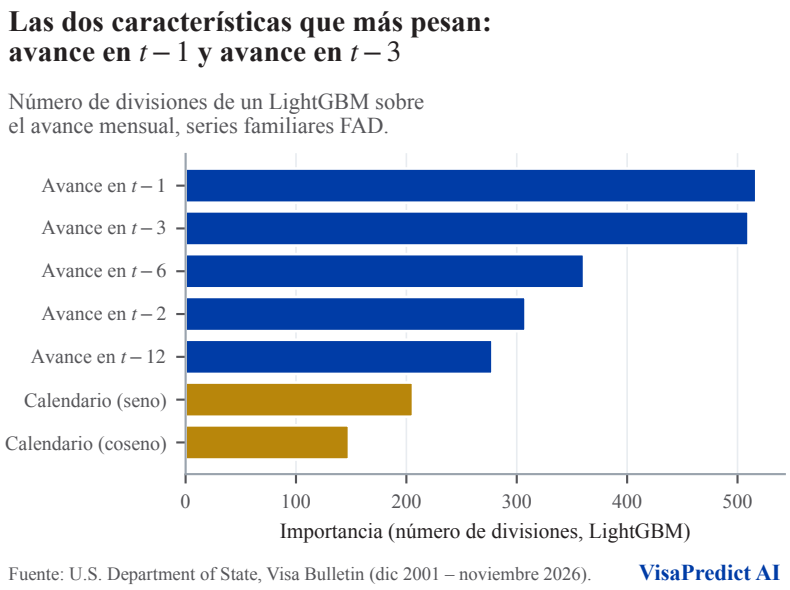


Figura 38: Importancia (por número de divisiones) de las características de un modelo de potenciación de gradiente para predecir el avance mensual de la fecha (FAD): los rezagos del propio avance dominan; el calendario cíclico aporta una señal secundaria.

Tabla 16: Síntesis del preprocesamiento: técnica aplicada, decisión adoptada en el proyecto y salvaguarda contra la fuga de información que la acompaña.

Técnica	Decisión adoptada	Salvaguarda anti-fuga
Manejo de valores ausentes	Los huecos *C*/*U* son régimen (MNAR), no ruido: la rejilla de entrenamiento arrastra la última observación publicada (LOCF); la imputación por Kalman se usa solo para caracterizar y visualizar	El relleno es estrictamente causal, jamás se puntúa, y las máscaras de ausencia entran con retardo de un mes
Transformación de la variable dependiente	Se modela la primera diferencia (el avance mensual) y se reintegra a un paso	La estacionariedad de la serie diferenciada se verificó en la sección 1.2.1 sobre las series evaluables
Normalización	Escalado por serie al rango $[0, 1]$ por mínimo y máximo, requerido por las redes neuronales	Los extremos se ajustan solo sobre la ventana inicial de entrenamiento
Codificación de variables categóricas	Mes y posición en el año fiscal en seno y coseno; estado administrativo como máscaras numéricas; las dimensiones de la serie actúan como llaves de partición, no como insumo	El calendario es determinista y conocido de antemano; las máscaras entran solo a mes cerrado
Selección de características	Matriz austera (rezagos, calendario, máscaras): de 44 descriptores candidatos, 0 superan el control de falso descubrimiento	Los descriptores del catálogo son retrospectivos y no entran como insumo del pronóstico
Limpieza estructural	12 decisiones registradas con módulo responsable y justificación en el registro de limpieza por corte (Apéndice A.3)	El registro se regenera con cada corte y queda versionado junto a los datos

Criterios de selección. Se comparan los **24 modelos** de la Tabla 17: tres líneas base de referencia y seis familias complementarias. El catálogo se evalúa por su adecuación al carácter temporal de los datos, su capacidad para generalizar fuera de la muestra, la diversidad de sus supuestos y un costo computacional compatible con la actualización mensual. El naïve estacional es el denominador de la métrica MASE ($m = 12$); el **naïve-1** (repetir el último valor publicado, es decir, un paseo aleatorio) es el piso operativo que cualquier modelo debe justificar; y la deriva (*drift*) le añade el avance medio histórico. Incluir estas líneas base no es un formalismo: en un panel donde el 45 % de los avances mensuales es nulo, "no moverse" es una predicción formidable a un paso, y omitirla dejaría a toda la comparación sin su referencia mínima. Como las series distan de ser estacionales, se reporta en paralelo la MASE escalada por el naïve-1 ($m = 1$); se conserva $m = 12$ como métrica principal por comparabilidad con la práctica estándar y con las campañas previas del proyecto (la definición y su referencia se dan en la sección 1.4.3).

La elección del resto del catálogo responde al problema. Las series son fechas que avanzan con tendencia fuerte, estacionalidad anual casi nula y retrogresiones ocasionales. Por ello conviene contrastar el espectro completo, desde modelos lineales parsimoniosos (ARIMA, SARIMA, ETS, Theta, tendencia lineal local) hasta modelos de alta capacidad (árboles de potenciación de gradiente sobre deltas, redes profundas), y verificar empíricamente cuál conviene a este régimen de datos. Los árboles se formulan sobre la *primera diferencia* (predicen el incremento mensual y lo reintegran), condición necesaria para que puedan extrapolar la tendencia en lugar de saturarse en el máximo observado. Se incluye además un *foundation model* preentrenado (Chronos) evaluado en modo zero-shot, sin ajustarse a estos datos. La Tabla 17 resume las líneas base y las familias del catálogo.

Tabla 17: Las líneas base de referencia y las seis familias del catálogo de 24 modelos, con su justificación. Los árboles operan sobre la primera diferencia; Chronos es zero-shot.

Familia	Modelos	Rol
Referencia	Naïve-1 (paseo aleatorio), deriva, naïve estacional	Piso operativo; denominador de MASE ($m = 1$ y $m = 12$)
Estadísticos [29]	ARIMA, SARIMA	Tendencia/estacionalidad lineal
Suavizamiento y estado [30]–[33]	ETS amortiguado, Theta, Kalman, tendencia lineal local (LLT)	Tendencia parsimoniosa
Aditivo [34]	Prophet	Tendencia con cambios de régimen
Árboles sobre deltas [35]–[37]	XGBoost, LightGBM, CatBoost	Rezagos + regresores, extrapolación
Lineales/profundos [38]–[45]	DLinear, NLinear, RLinear, TiDE, LSTM, DeepAR, ARIMA-LSTM, N-BEATS, N-HiTS, TFT	No linealidad y capacidad alta
Foundation *(zero-shot)* [46]	Chronos	Transferencia sin entrenamiento

Cada familia aporta un *sesgo inductivo* distinto; explicarlo permite anticipar (y luego

contrastar empíricamente) cuál encaja con este régimen de tendencia fuerte, estacionalidad casi nula y retrogresiones ocasionales.

Referencia: naïve-1, deriva y naïve estacional. El naïve estacional repite el valor de doce meses atrás; es el denominador de la MASE, y todos los modelos serios lo baten por amplio margen (MASE del conjunto reservado 1.304), lo que confirma que las series son predecibles. La línea base que de verdad exige es el **naïve-1**: repetir el último corte publicado, la predicción óptima de un paseo aleatorio. Ninguno de los tres aprende nada; el naïve-1, sin embargo, resulta el rival a vencer de toda la evaluación (MASE del conjunto reservado 0.157 en FAD y 0.125 en DFF), porque en estas colas familiares, del 28 % de meses congelados en FAD al 66 % en DFF (Tabla 10), la fecha se repite con frecuencia. La deriva, que añade el avance medio, apenas lo matiza.

Estadísticos lineales: ARIMA y SARIMA [29]. Modelan la serie como una combinación lineal de sus valores y errores pasados; SARIMA añade términos estacionales. Se eligen porque las series son fuertemente autorregresivas. SARIMA ocupa la zona media de la selección en FAD (0.142), mientras ARIMA cae a la parte baja (0.591) por unas pocas series en las que su ajuste se vuelve inestable, y ambos revelan una fragilidad clave: con las series cortas de DFF, SARIMA solo converge en 17 de 25 series y ARIMA en 23 (falla numérica *LinAlgError*), un sesgo de supervivencia que desmiente cualquier ventaja aparente.

Suavizamiento parsimonioso y espacio de estados: ETS amortiguado, Theta, Kalman y tendencia lineal local. El suavizamiento exponencial con tendencia amortiguada[30][31], la descomposición de Theta[32], el filtro de Kalman[33] y el modelo estructural de tendencia lineal local (LLT, nivel más pendiente en espacio de estados) comparten una virtud decisiva: **pocos parámetros**. Se eligen justo para el régimen observado, donde un modelo simple y bien regularizado es difícil de batir. El resultado lo confirma: Theta y ETS son los mejores modelos *entrenados* de la familia clásica en el conjunto reservado de FAD (0.171 y 0.167), y el LLT (0.115 de selección, a la par de Theta) valida que la física de estas series es nivel más pendiente. Pero ninguno bate al naïve-1 en el conjunto reservado: el hallazgo contraintuitivo del proyecto es que aquí menos es más, hasta el extremo de que *no aprender nada* (repetir el último valor) es lo más difícil de superar a un paso.

Aditivo: Prophet [34]. Descompone la serie en tendencia, estacionalidad y puntos de cambio. Se elige por su manejo explícito de cambios de régimen, atractivo ante las retrogresiones. Sin embargo, su estructura aditiva y suave *subajusta* (MASE 0.561): no reproduce ni la trayectoria escalonada ni los saltos abruptos de las colas migratorias.

Árboles de potenciación de gradiente sobre deltas: XGBoost, LightGBM y CatBoost [35]–[37]. Aprenden relaciones no lineales entre rezagos y regresores de calendario. Su limitación (no extrapolan más allá del máximo visto en el entrenamiento) se resuelve formulándolos sobre la **primera diferencia**: predicen el avance mensual y lo reintegran. Con sus hiperparámetros optimizados (sección 1.4.4) encabezan incluso la métrica de selección en FAD (LightGBM, CatBoost y XGBoost, 0.107), pero su error en el conjunto reservado (0.172–0.176) queda por encima del piso del naïve-1 (0.157): la capacidad bien regulada acerca, no destrona.

Lineales y redes profundas: DLinear, NLinear, RLinear, TiDE, LSTM, DeepAR, ARIMA-LSTM, N-BEATS, N-HiTS y TFT [38]–[45]. Abarcan desde proyecciones lineales hasta arquitecturas de altísima capacidad. Se incluyen para responder *empíricamente* si la capacidad ayuda, y la respuesta exigió una autocorrección de especificación que se documenta con transparencia. En las campañas iniciales, entrenadas por serie sobre el nivel crudo, caían por debajo del naïve estacional; el diagnóstico reveló que parte de ese fracaso era autoinfligido: el escalado se congelaba en la ventana inicial de entrenamiento y obligaba a predecir fuera del rango aprendido durante años. Reformuladas sobre la **primera diferencia** (como los árboles) y, en los modelos probabilísticos, promediando 500 muestras de la distribución predictiva en lugar de una, se vuelven plenamente competitivas (TFT alcanza 0.114 de selección en FAD; la cascada ARIMA-LSTM sigue sin converger en las series cortas de DFF). Aun corregidas, **ninguna supera con significancia el piso del naïve-1**; el entrenamiento global sobre el panel les presta señal adicional entre series.

Foundation model: Chronos en modo zero-shot. Un modelo preentrenado[46] sobre millones de series, evaluado *sin ajuste alguno* a estos datos. Se incluye para medir cuánto vale la transferencia de conocimiento frente a la escasez. Con MASE de selección 0.188 ocupa la zona media-baja de la tabla: la transferencia aporta un pronóstico razonable sin entrenar, pero ya no supera a las redes locales correctamente especificadas ni se acerca a los parsimoniosos o al piso ingenuo.

Técnicas no seleccionadas. Los algoritmos evolutivos, los métodos de enjambre y la optimización multiobjetivo no se usan como predictores principales. Son técnicas apropiadas para buscar soluciones en espacios de decisión, mientras que este proyecto estima una variable temporal futura y no asigna recursos ni optimiza varios objetivos operativos. La optimización de hiperparámetros forma parte del ajuste de algunos modelos, pero no sustituye a la técnica predictiva ni constituye por sí misma una familia de pronóstico.

En conjunto, esta comparación de sesgos inductivos anticipa el resultado central de la evaluación: en un panel dominado por meses congelados, el piso del paseo aleatorio a un paso no lo supera con significancia ningún modelo puntual (ni parsimonioso, ni de árboles,

ni profundo, local o global). La capacidad, bien especificada y bien entrenada, *acerca*; el valor diferencial del sistema se juega en el horizonte múltiple, la incertidumbre calibrada y la coherencia transversal, que se validan en las etapas siguientes del proyecto.

1.3.2 Creación de la arquitectura general del sistema y definición del flujo de trabajo

Propósito arquitectónico. VisaPredict AI se diseñó como un sistema modular de procesamiento por lotes, adecuado a la periodicidad mensual del *Visa Bulletin*. No es un servicio que pronostica en línea después de cada consulta: una nueva fuente entra al flujo, se valida, produce una versión trazable de datos y modelos, y sólo entonces genera artefactos estáticos para consulta. Esta decisión reduce la complejidad operativa, evita que un cálculo parcial llegue al usuario y permite reproducir cada resultado a partir del código, los datos y la configuración que lo originaron.

Vista general. La arquitectura de la Figura 39 separa ocho componentes con responsabilidades explícitas. El portal oficial es la fuente; la instantánea congelada es la evidencia primaria; el panel y el almacén son las capas de datos procesados; la matriz de características alimenta al catálogo de modelos; la evaluación temporal decide qué resultados son admisibles; y la capa de publicación expone únicamente artefactos versionados. El seguimiento, las pruebas y los controles de procedencia atraviesan todo el flujo.

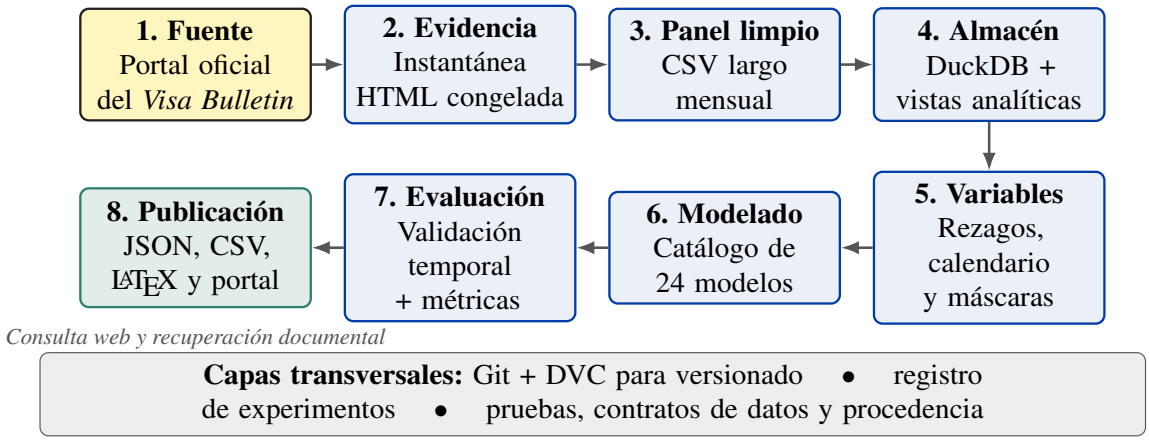


Figura 39: Arquitectura extremo a extremo por componentes: la fuente oficial se transforma en evidencia congelada, panel, almacén, características, modelos y resultados evaluados antes de la publicación. El versionado, la trazabilidad y las pruebas son responsabilidades transversales.

Adquisición y evidencia de origen. El primer componente incorpora cada boletín mensual desde el sitio del Departamento de Estado. La descarga utiliza `requests` y el análisis del documento emplea `BeautifulSoup` [6][7]. Sin embargo, la fuente puede rechazar clientes automatizados; por ello la arquitectura admite una captura manual controlada cuando la automatización no está disponible. En ambos casos, el límite es el mismo: se conserva

primero una instantánea inmutable y se verifica su suma de comprobación. El resto del procesamiento se ejecuta sin red sobre esa evidencia. Así, la restricción de acceso amenaza la oportunidad de la actualización, pero no autoriza a omitir controles de integridad.

Preparación y almacenamiento. El segundo bloque convierte las tablas del boletín en un panel largo con frecuencia mensual. `pandas` realiza la normalización y las transformaciones tabulares [8]; las reglas de calidad verifican claves, dominio, fechas, duplicados y continuidad antes de aceptar el panel. El archivo CSV constituye la interfaz abierta, mientras DuckDB organiza la misma información en un esquema dimensional con vistas para análisis y modelado [17]. DVC registra las dependencias y los productos de cada etapa, y Git conserva el código y los punteros de versión [47]. Esta separación permite reconstruir un resultado sin confundir el dato fuente, la transformación y el producto derivado.

Construcción de características. El módulo de preprocesamiento recibe una serie mensual y produce exclusivamente información disponible en cada origen de pronóstico: rezagos del nivel y del avance, variables cíclicas del calendario, máscaras de régimen y características descriptivas seleccionadas. `NumPy`, `SciPy` y `statsmodels` apoyan los cálculos numéricos y estadísticos [13][14]. Los parámetros de escalamiento se estiman sólo con el tramo de entrenamiento y las pruebas de causalidad impiden que una observación futura modifique una fila anterior.

Capa de modelado. Los 24 modelos se exponen tras una interfaz común (`fit`/`predict`) mediante la biblioteca *Darts* [48], lo que permite una comparación justa y reúsa el motor de validación temporal y la generación de bandas probabilísticas sin reimplementarlos. PyTorch sustenta las redes neuronales [49], y `scikit-learn` aporta interfaces y utilidades para aprendizaje automático [50]. XGBoost, LightGBM y CatBoost implementan los regresores sobre avances [35]–[37]. Los modelos locales se ajustan por serie y los globales aprenden de varias series, pero ambos consumen la misma representación causal. Las piezas de código propio son la cascada ARIMA-LSTM (un envoltorio que ajusta un ARIMA, calcula sus residuales y entrena un LSTM sobre ellos), el envoltorio que diferencia las series para los árboles de potenciación de gradiente y el adaptador que evalúa Chronos en modo zero-shot.

Evaluación, selección e incertidumbre. La salida de un modelo no pasa directamente a publicación. El motor de evaluación recorre orígenes cronológicos con ventana expansible y reserva una cola final independiente. En cada origen calcula las mismas métricas y conserva la identidad de la tabla, la serie, el modelo y la configuración. Cuando una técnica produce distribuciones o bandas, también se mide la cobertura. Las líneas base de la sección 1.3.1 permanecen dentro de la comparación; por tanto, un modelo complejo no se promueve sólo porque converja, sino porque demuestra una mejora verificable sobre una referencia

pertinente.

Artefactos, consulta y retroalimentación. Los resultados aceptados se materializan en archivos CSV y JSON para consumo programático y en macros LaTeX para los documentos académicos. El portal bilingüe lee estos artefactos versionados; no vuelve a entrenar modelos durante una consulta. La recuperación documental usa la misma versión publicada, lo que evita que el sitio y sus respuestas describan cortes distintos. Cuando llega un boletín posterior, sus valores reales se incorporan a un registro prospectivo y alimentan una nueva evaluación. El flujo es, por tanto, cíclico: publicar no concluye el proceso, sino que abre la siguiente oportunidad de contrastar los pronósticos.

Flujo de trabajo operativo. La Tabla 18 resume la interacción entre componentes. Cada paso recibe una entrada identificable, genera una salida verificable y posee una condición que impide avanzar cuando el resultado no es confiable.

Tabla 18: Secuencia operativa, productos y puertas de aceptación de VisaPredict AI.

Paso	Componente	Producto	Condición para continuar
1	Captura	Instantánea del boletín	Archivo identificable, íntegro y asociado al mes esperado.
2	Extracción	Tablas normalizadas	Estructura reconocida y valores dentro del dominio permitido.
3	Consolidación	Panel mensual largo	Claves únicas, continuidad temporal y registro de limpieza aceptado.
4	Almacenamiento	DuckDB, vistas y conjunto entrenable	Restricciones de integridad y dependencias DVC coherentes.
5	Preprocesamiento	Matriz de características causal	Ningún dato posterior altera una fila construida en un origen anterior.
6	Modelado	Pronósticos por modelo y serie	Configuración, semilla, código y datos quedan identificados.
7	Evaluación	Métricas, intervalos y comparación	Cobertura completa, línea base presente y conjunto reservado intacto.
8	Publicación	Artefactos académicos y portal	Consistencia entre superficies y procedencia verificable.

Seguimiento, calidad y reproducibilidad. Cada ejecución registra sus parámetros y métricas en un formato ligero que puede sincronizarse con MLflow [51]. Las pruebas automatizadas cubren código, contratos de datos, causalidad, coherencia entre artefactos y compilación documental. Ruff verifica estilo, mypy comprueba tipos y pytest ejecuta la batería funcional; GitHub Actions reproduce estas verificaciones antes de integrar cambios [52]. Ningún paso de publicación se interpreta como exitoso por la sola existencia de un archivo: su procedencia y su cobertura deben corresponder a la misma versión.

Escalabilidad, seguridad y disponibilidad. La escala actual permite ejecutar el almacén de forma embebida y distribuir las campañas de modelado por tabla, familia o serie. La modularidad permite ampliar el catálogo sin modificar la adquisición ni la publicación.

En seguridad, el sistema procesa exclusivamente datos públicos y agregados; no recibe expedientes ni información personal de solicitantes. Las sumas de comprobación, los artefactos inmutables y las puertas de calidad reducen el riesgo de sustitución accidental. En disponibilidad, la captura contempla la intervención humana cuando la fuente bloquea la automatización, mientras todas las etapas posteriores continúan siendo reproducibles sin conexión.

Síntesis arquitectónica. La arquitectura vincula cada decisión técnica con una responsabilidad: la evidencia se congela antes de transformarla; los datos se validan antes de modelarlos; las técnicas compiten antes de seleccionarse; y los resultados se acreditan antes de publicarse. Esta secuencia hace que VisaPredict AI sea mantenible y verificable, y permite incorporar nuevos boletines, modelos o superficies de consulta sin romper la trazabilidad de las versiones anteriores.

1.4 Desarrollo

1.4.1 Implementación del modelo

Alcance de la primera etapa. Esta etapa convierte el diseño de las secciones 1.3.1 y 1.3.2 en una cadena ejecutable de preparación, ajuste, pronóstico, evaluación y persistencia. El objetivo de la etapa no es declarar un modelo definitivo, sino demostrar que las familias seleccionadas comparten un protocolo temporal, que sus parámetros quedan gobernados y que ningún resultado parcial puede confundirse con una ejecución completa. Al cierre de esta primera etapa, la capa de modelado, sus pruebas iniciales y las puertas de aceptación quedaron implementadas; la regeneración integral de resultados se mantuvo separada y sólo se ejecutó después de acreditar los insumos, el código y los entornos.

Del diseño al código. La implementación toma como entrada el panel mensual validado y el almacén DuckDB descritos en la sección 1.3.2 [17]. Una capa de acceso recupera cada serie por tabla, país o área de cargabilidad y categoría; otra construye una representación mensual causal; un registro canónico asigna a cada identificador lógico su familia, fuente de pronóstico y política de persistencia; y un motor de recorrido temporal aplica la misma partición y las mismas métricas a todos los candidatos. Esta separación evita que cada modelo introduzca, de manera accidental, su propia definición del conjunto de entrenamiento o del periodo evaluado.

La Figura 40 resume la ruta implementada. Las flechas representan productos explícitos, no llamadas informales entre cuadernos: cada etapa recibe una entrada validada y produce una salida verificable antes de habilitar la siguiente.

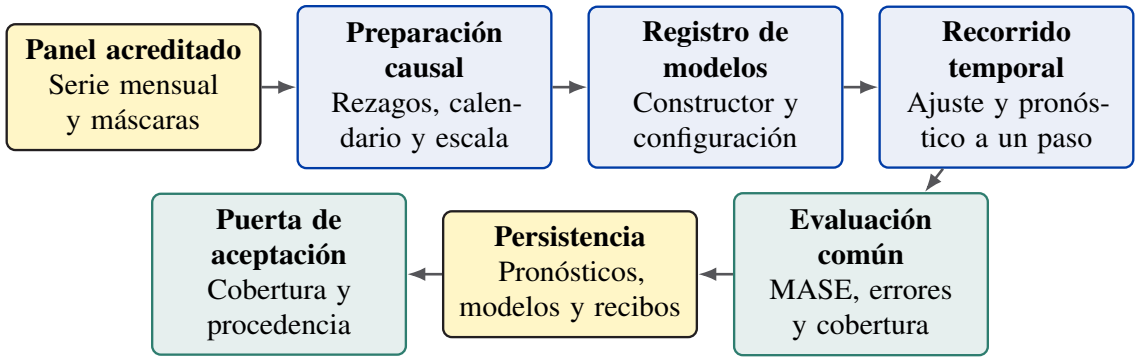


Figura 40: Cadena implementada para transformar una serie acreditada en pronósticos evaluados. La preparación sólo usa información disponible en el origen; el registro separa la identidad lógica del modelo de su biblioteca; y la puerta final rechaza artefactos con cobertura o procedencia incompletas.

Representación causal de cada serie. La variable dependiente es el número de días transcurridos desde una época fija hasta la fecha de prioridad publicada. Los meses sin fecha numérica conservan su régimen y su máscara de observación; no se convierten en ceros. Para cada origen, los huecos admitidos se tratan sólo con datos anteriores, la escala se estima con el tramo de entrenamiento y las covariables de calendario se calculan sin observar el futuro. En los árboles de potenciación, el objetivo es el avance mensual y no el nivel, porque esta representación permite extrapolar cambios sin presentar como predicción futura el máximo histórico aprendido. XGBoost, LightGBM y CatBoost implementan esta familia [35][36][37].

Familias implementadas. La interfaz común de Darts [48] coordina el ajuste y el pronóstico de las técnicas estadísticas y de varias redes; PyTorch sustenta los modelos profundos [49]; y `scikit-learn` aporta transformadores y contratos de estimación [50]. El catálogo mantiene cuatro funciones complementarias: líneas base ingenuas y con deriva para fijar un piso; modelos estadísticos como ARIMA, SARIMA, ETS, Theta y Kalman; regresores de árboles sobre diferencias; y redes locales o globales para representar patrones no lineales. Chronos se incorpora como modelo fundacional en modo de transferencia sin ajuste sobre el panel [46]. La identidad se define por el nombre lógico, pues dos candidatos pueden compartir una clase de biblioteca y, aun así, representar protocolos diferentes.

La Tabla 19 muestra cómo esas familias se materializan en el código. La persistencia no se equipara automáticamente con evaluación: un modelo puede producir un pronóstico obligatorio aunque su envoltorio no exponga un estado reutilizable. En ese caso se conserva el pronóstico generado por el recorrido temporal, junto con su contexto, en lugar de inventar un modelo serializado.

Pseudocódigo principal. El Algoritmo 1 expresa el recorrido implementado. La rejilla esperada se deriva del panel y del registro antes de entrenar; por eso un archivo con menos

Tabla 19: Decisiones de implementación por familia. Todas se someten a la misma partición temporal y a la misma puerta de cobertura.

Familia	Representación	Ajuste	Producto conservado
Líneas base	Nivel o deriva mensual	Determinista por origen	Pronóstico y métricas
Estadísticos	Nivel, tendencia y estacionalidad	Ventana expansible	Modelo reutilizable cuando existe; pronóstico siempre
Árboles	Primera diferencia y covariables causales	Reajuste por origen	Modelo, pronóstico y configuración
Redes locales	Nivel escalado o diferencia	Reajuste periódico	Estado entrenado y pronóstico
Redes globales	Panel de múltiples series	Una configuración, varias semillas	Pronóstico por semilla y agregado acreditado
Fundacional	Serie histórica convertida al formato del modelo	Cero ajuste sobre el panel	Pronóstico y revisión inmutable del modelo

filas no puede autodeclararse completo. Los últimos 24 meses forman el conjunto reservado independiente, mientras la selección y el ajuste de hiperparámetros ocurren exclusivamente en la región anterior.

Algoritmo 1 Implementación y acreditación del recorrido temporal

Require: Panel P, tabla T, registro $\mathscr{M}$, entrenamiento mínimo L_T, conjunto reservado $H = 24$ y semilla s
Ensure: Pronósticos, métricas y recibo de cobertura de una misma ejecución

```
Verificar identidad, esquema y suma de comprobación de P
Derivar del panel la rejilla esperada K de series, modelos y meses objetivo
for all serie elegible u de T do
    Ordenar u por mes y separar selección de los últimos H objetivos
    for all modelo m declarado en 𝓜 do
        Construir m con la configuración registrada y fijar la semilla s
        for all origen mensual o posterior a L_T do
            Ajustar transformaciones únicamente con observaciones de fecha ≤ o
            if la política de m exige ajuste en o then
                Ajustar m sobre la ventana expansible disponible en o
            end if
            Pronosticar un paso, para el objetivo mensual siguiente a o
            Registrar clave, valor pronosticado, valor real si existe y máscara evaluable
        end for
        Calcular métricas sólo sobre objetivos observados, con escala previa al objetivo
    end for
end for
Rechazar duplicados, valores no finitos o cualquier diferencia entre K y lo producido
Escribir por promoción atómica artefactos y recibo ligado a datos, código y parámetros
```

Configuración gobernada. Los valores principales se concentran en un módulo de configuración y no se repiten dentro de cada algoritmo. La Tabla 20 presenta los parámetros del protocolo vigente. La semilla controla las fuentes estocásticas; el periodo 12 representa la frecuencia anual del boletín; y las ventanas mínimas distintas reconocen que FAD y DFF tienen longitudes históricas diferentes. Los modelos de bajo costo computacional se reajustan en cada origen, mientras las redes se actualizan cada doce meses para equilibrar validez temporal y costo. En los modelos probabilísticos se usan 500 muestras y su mediana como pronóstico puntual, evitando que una sola extracción aleatoria represente la predicción.

Tabla 20: Configuración principal compartida por los modelos. Los hiperparámetros internos de cada candidato permanecen versionados en el registro y no modifican la partición de evaluación.

Parámetro	Valor	Justificación operativa
Semilla global	42	Reproduce inicialización, muestreo y búsquedas estocásticas.
Periodo estacional	12 meses	Corresponde al ciclo anual de publicación del boletín.
Entrenamiento mínimo	FAD: 60; DFF: 36 meses	Evita ajustar con historia insuficiente y respeta la disponibilidad de cada tabla.
Conjunto reservado	24 meses	Proporciona una evaluación final común, fuera de selección y optimización.
Pronóstico temporal	horizonte 1; paso 1	Genera un objetivo por origen mensual y conserva el orden causal.
Reajuste de estadísticos y árboles	cada origen	Implementa una ventana expansible real con toda la historia disponible.
Reajuste de redes	cada 12 meses	Compromiso explícito entre actualización temporal y costo de entrenamiento.
Muestras probabilísticas	500 por objetivo	La mediana de la distribución se usa como pronóstico puntual estable.
Covariables de árboles	calendario en t; máscara en $t-1$	El calendario futuro es conocido; el régimen del objetivo no lo es.
Escala MASE	finita y positiva	Una escala degenerada queda indefinida y bloquea la agregación; nunca se sustituye por uno.

Optimización sin fuga. Los hiperparámetros de los árboles se buscan con Optuna [53], mediante un muestreador TPE con semilla fija y almacenamiento persistente. La región anterior al conjunto reservado se divide, a su vez, en entrenamiento, 24 meses de *val-tuning* y 12 meses de val-confirmación. El buscador observa sólo la primera cola; la segunda decide si la configuración se acepta y el conjunto reservado nunca interviene en ninguna de esas decisiones. Para las redes globales, una configuración se selecciona una sola vez y luego se vuelve a entrenar con varias semillas; así se separa la elección arquitectónica de la variabilidad debida a la inicialización.

Herramientas de implementación. La solución se desarrolla en Python 3.14 con perfiles de dependencias fijados. DuckDB y pandas proporcionan acceso tabular; NumPy, SciPy y

`statsmodels` cubren cálculo numérico y estimación estadística [8][13][14]; Darts, PyTorch y `scikit-learn` articulan los estimadores; y las bibliotecas especializadas implementan los árboles. Git conserva el código y DVC liga los datos y artefactos voluminosos a sus versiones [47]. MLflow recibe el registro de experimentos [51], mientras pytest, Ruff y mypy verifican comportamiento, estilo y tipos. GitHub Actions reproduce estas puertas antes de integrar cambios [52]. La Tabla 21 resume cada herramienta y su responsabilidad.

Tabla 21: Herramientas y responsabilidad dentro de la primera etapa de implementación.

Capa	Herramientas	Responsabilidad
Datos	pandas, DuckDB, DVC	Consultar el panel, materializar entradas y versionar productos.
Estadística	NumPy, SciPy, statsmodels	Transformaciones, escalas, modelos clásicos y métricas.
Aprendizaje automático	Darts, scikit-learn, XGBoost, LightGBM, CatBoost	Interfaz temporal común y regresores sobre diferencias.
Aprendizaje profundo	PyTorch y modelos temporales especializados	Entrenamiento local o global y predicción probabilística.
Optimización	Optuna	Búsqueda anidada, reproducible y persistente de hiperparámetros.
Seguimiento	Git, DVC y MLflow	Relacionar código, datos, configuración, ejecución y resultados.
Calidad	pytest, Ruff, mypy y GitHub Actions	Pruebas, análisis estático y verificación antes de integrar.

Persistencia, trazabilidad y manejo de errores. Cada ejecución se identifica con la versión del código, la suma de comprobación del panel, la configuración y el entorno. Los modelos con estado reutilizable se guardan de forma comprimida; los pronósticos se conservan en formato largo con serie, origen, objetivo, horizonte, valor real, máscara evaluable y escala. Una promoción atómica impide que un consumidor lea un archivo a medio escribir. Antes de publicar, un recibo vuelve a comparar el conjunto exacto de claves esperado con el observado: un faltante, un duplicado, un mes sustituido, un valor no finito o una procedencia distinta detienen la cadena.

El manejo de errores sigue una política de fallo cerrado. Cada etapa comprueba sus precondiciones y finaliza con un código distinto si falla el entorno, el linaje, la cobertura o la promoción. No se continúa con archivos antiguos por el solo hecho de que existan, ni se etiqueta como éxito una omisión. Las bitácoras se separan por ejecución y los mensajes nombran las claves ausentes y no esperadas, de modo que el diagnóstico pueda localizar el campo alterado sin revisar manualmente todo el conjunto.

Durante la implementación también se enfrentaron retos de entorno en Apple Silicon. El entrenamiento de redes recurrentes con múltiples hilos provocaba fallos de segmentación, por lo que el perfil correspondiente limita explícitamente los hilos de cómputo. Asimismo,

el orden de carga de las bibliotecas paralelas de XGBoost y PyTorch queda fijado para evitar conflictos. Estas decisiones forman parte del entorno reproducible y no dependen de ajustes manuales posteriores.

Pruebas iniciales y estado de la etapa. Las pruebas unitarias verifican escalas, transformaciones y constructores; las pruebas contractuales atacan esquemas, duplicados, valores no finitos, procedencia y cobertura; y las pruebas de integración confirman que el productor real invoca la persistencia que luego exige el consumidor. También se ejecutan controles benignos, por ejemplo un mes legítimamente no evaluable con valor real nulo, para evitar que el endurecimiento rechace casos válidos. Una prueba maestra compara las métricas antes y después de instrumentar el recorrido, y las comprobaciones de causalidad aseguran que alterar un dato futuro no modifique una característica pasada.

Esta primera etapa deja una implementación funcional, modular y verificable, preparada para la ejecución controlada de la campaña completa. La separación entre cálculo, acreditación y publicación es deliberada: permite corregir un productor o repetir una etapa sin mezclar artefactos de campañas distintas, y conserva evidencia suficiente para que otro investigador reconstruya qué datos, parámetros y código originaron cada pronóstico.

Continuación del desarrollo: integración pre-ejecución. La segunda etapa se concentra en unir los componentes anteriores dentro de una ejecución gobernada. El problema ya no es únicamente que cada estimador produzca un valor, sino demostrar que todos los valores obligatorios proceden del mismo panel, código, entorno y campaña. Para ello se incorporaron cuatro mecanismos: un registro único de modelos, un área de preparación aislada por campaña, recibos de cobertura recalculados al leer y una verificación previa (*preflight*) que bloquea la ejecución antes del primer entrenamiento si la identidad técnica no coincide.

Registro canónico y fuentes de pronóstico. El catálogo dejó de depender de listas distintas en productores, exportadores y promotores. Cada modelo posee un identificador lógico, una familia, una política de persistencia, una fuente de pronóstico y su pertenencia o no al conjunto de comparación. A partir de ese registro se derivan las vistas consumidas por el resto del sistema. Así, añadir o retirar un candidato exige una modificación explícita de la autoridad y no una coincidencia accidental entre nombres de archivos.

La Tabla 22 resume las cuatro categorías operativas. SARIMA se incluye entre los modelos persistibles porque su estado sobrevive al ciclo guardar–cargar–pronosticar. En cambio, los envoltorios automáticos de ETS y Theta no conservan un estado reutilizable para el modo de pronóstico empleado; por ello sus predicciones se transportan desde el recorrido temporal que ya las calculó. Esta limitación técnica no los vuelve opcionales: su ausencia sigue bloqueando la cobertura final.

Tabla 22: Categorías derivadas del registro canónico. La fuente describe de dónde se obtiene el pronóstico final, no la biblioteca que implementa la clase.

Categoría	Identificadores	Persistencia	Fuente del pronóstico
Locales recalculados	SARIMA, ARIMA, Kalman, CatBoost y LightGBM	Sí	Exportador acreditado
Locales transportados	ETS y Theta	No	Recorrido temporal oficial
Globales de campaña	BiTCN, PatchTST, TiDE, NHITS y AutoBiTCN	Sí	Salida multisemilla de la campaña
Pisos del conjunto reservado	naïve-1 y deriva	No	Comparación interna; no se exportan como finalistas

Transporte de pronósticos estadísticos. El recorrido temporal conserva para ETS y Theta las 24 filas objetivo por serie y modelo. Las filas nacen del pronóstico, no de un cruce con los valores reales: si un mes carece de fecha publicada, la fila permanece con `observed=false` y valor real nulo. El origen se deriva como el periodo mensual anterior al objetivo y el horizonte se fija en uno. Cada fila incluye además la escala MASE utilizada, que debe ser finita y positiva, y la identidad de campaña, código y panel. El consumidor recalcula el conjunto esperado desde el panel vivo y rechaza diferencias, duplicados o valores no finitos antes de incorporar las predicciones al archivo final.

Aislamiento de una campaña. Los productores ya no escriben directamente sobre el árbol servido. Como muestra la Figura 41, una campaña comienza con una escena limpia y acreditada, crea un espacio de preparación identificado, ejecuta productores y consumidores sobre esa misma identidad y sólo promueve el conjunto completo. Si una etapa falla, la preparación se conserva para diagnóstico y el árbol anterior permanece intacto. DVC conserva los punteros de datos voluminosos [47] y el registro experimental puede sincronizarse con MLflow [51], pero ninguna de esas operaciones sustituye la puerta de cobertura.

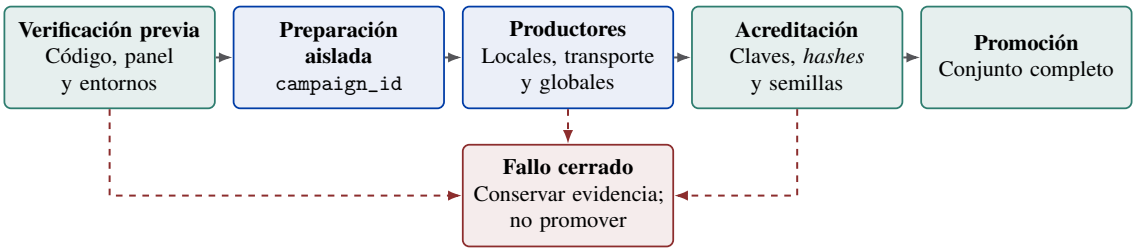


Figura 41: Orquestación de la segunda etapa. La identidad se acredita antes del cálculo; los productos nacen en un espacio aislado; y sólo un conjunto completo puede sustituir al árbol servido. Cualquier fallo conserva la versión anterior.

Cobertura de modelos globales. Las redes globales se entrenan con cinco semillas para separar el efecto de la inicialización de la configuración elegida. Por cada tabla, cada semilla debe cubrir exactamente la rejilla de 25 series por 24 meses, es decir, 600 claves $(serie, mes)$. El productor parte de esa rejilla canónica y agrega una columna finita por modelo; nunca construye la salida únicamente con las filas que lograron pronóstico. El lector vuelve a derivar la rejilla desde el panel, comprueba los valores reales, el conjunto exacto de semillas $s_1, \ldots, s_5$ y el *hash* de cada archivo, y evalúa los mismos marcos que acreditó. De esta forma, cinco archivos truncados de manera idéntica no pueden validarse entre sí por simple semejanza.

Pseudocódigo de orquestación. El Algoritmo 2 complementa el recorrido por modelo de la primera etapa. Expresa la secuencia implementada alrededor del cálculo y la propiedad central de la etapa: después del primer fallo no se ejecutan agregaciones, sincronizaciones ni promociones.

Algoritmo 2 Orquestación acreditada de la segunda etapa

Require: Repositorio limpio R, panel P, entornos sellados E y registro $\mathscr{M}$
Ensure: Árbol servido anterior o campaña completa acreditada; nunca una mezcla

Ejecutar contratos de archivos de bloqueo de dependencias (*locks*), linaje y resolución de importaciones
Emitir la verificación previa S_0 y compararla con la identidad viva antes de calcular
if S_0 no acredita exactamente $(R, P, E, \mathscr{M})$ **then**
    Abortar antes de crear artefactos
end if
Abrir una transacción y un directorio de preparación para la campaña c
for all productor requerido q en el orden del flujo **do**
    Ejecutar q con la identidad de c
    if q falla o su recibo no reproduce el conjunto esperado **then**
        Registrar el fallo, conservar la preparación y abortar inmediatamente
    end if
end for
Acreditar $s_1, \ldots, s_5$, transportar ETS/Theta y exportar los modelos requeridos
Revalidar esquema, claves, *hashes*, procedencia y ausencia de duplicados
if la cobertura observada difiere de la derivada del panel y del registro **then**
    Abortar sin tocar el árbol servido
end if
Promover atómicamente la preparación y registrar su acreditación

Configuración añadida en la etapa 2. La configuración numérica de la primera etapa permanece sin cambios; el incremento introduce parámetros de ejecución y aceptación. La Tabla 23 los separa de los hiperparámetros del modelo para impedir que una decisión de gobernanza se confunda con una búsqueda estadística.

Tabla 23: Parámetros y condiciones añadidos para la integración pre-ejecución.

Parámetro o condición	Valor	Efecto
Campaña	Identificador único	Separa preparación, bitácora, recibos y promoción.
Tablas evaluadas	FAD y DFF	Mantiene las dos superficies del boletín bajo el mismo protocolo.
Objetivos por serie	24 meses	Exige la cola completa, incluidos meses no evaluables.
Semillas globales	$1, 2, 3, 4, 5$	Permite agregar variabilidad sin repetir la búsqueda arquitectónica.
Grupo de semillas	Exactamente s_1–s_5	Rechaza faltantes, extras o archivos de otra campaña.
Escritura	Preparación + promoción atómica	Impide exponer archivos parciales a los consumidores.
Política ante fallo	Detención inmediata	Prohíbe continuar con agregación o sincronización posterior.
Cobertura	Conjunto exacto de claves	Compara lo esperado desde panel y registro contra lo producido.
Identidad	Código, panel, entorno y campaña	Bloquea la mezcla de artefactos con procedencias distintas.

Estructura del código y herramientas. La integración mantiene separado el producto de las herramientas de campaña. El módulo de configuración conserva los parámetros matemáticos; el registro define el catálogo; el recorrido temporal produce métricas y filas de pronóstico; los módulos de transporte y cobertura validan artefactos; y el lanzador sólo orquesta esas piezas. Los contratos de entorno comparan los paquetes instalados con los archivos de bloqueo, la prueba de humo (*smoke test*) importa los puntos de entrada en procesos limpios y la puerta de linaje contrasta cada instantánea con su nombre, *hash* y mes esperado. Esta estructura reduce la dependencia del conocimiento tácito y permite probar cada frontera de forma aislada. La Tabla 24 resume las responsabilidades de los módulos principales.

Pruebas de sustitución. La segunda etapa no se validó sólo con casos felices. Las pruebas sustituyen una serie conservando el conteo, compensan un faltante con un duplicado, cambian un único origen mensual, introducen una escala degenerada, mezclan otra campaña, alteran un archivo después de acreditarlo y presentan cinco semillas truncadas de la misma manera. Cada sustitución debe producir un fallo antes de que el artefacto llegue a evaluación o publicación. Los controles benignos conservan casos válidos, como un objetivo no observado con valor real nulo, para demostrar que la regla no exige datos que el boletín nunca publicó.

Estado al cierre de la etapa 2. Al cerrar esta etapa, la integración quedó verificada localmente: los entornos reproducían sus archivos de bloqueo, el linaje de las instantáneas

Tabla 24: Responsabilidades principales de los módulos integrados durante la segunda etapa.

Componente	Responsabilidad
Configuración y registro	Definir parámetros, identidad lógica, persistencia y fuente de cada pronóstico.
Recorrido temporal	Ajustar por origen, registrar 24 objetivos y calcular métricas sin fuga.
Transporte estadístico	Conservar y acreditar ETS/Theta desde el recorrido que los produjo.
Cobertura multisemilla	Validar rejilla, verdad, predicciones finitas, semillas y *hashes*.
Exportador y promotor	Exigir todos los pronósticos y promover sólo los modelos persistibles y globales.
Verificación previa y manifiesto	Acreditar código, panel, instantáneas, archivos de bloqueo, entornos y puntos de entrada.
Lanzador de campaña	Ejecutar en orden, detenerse en el primer fallo y conservar una bitácora por campaña.

estaba completo, los puntos de entrada importaban y los recibos se volvían a acreditar al consumirlos. La campaña integral no formaba parte de la segunda etapa y entonces no se había iniciado; antes de autorizar una ejecución prolongada quedaba una verificación final sobre el vínculo entre el sello de la verificación previa y la transacción que después habilitaría la publicación. Declarar ese límite evitó presentar una preparación técnicamente verde como si ya fuera un resultado experimental nuevo.

Cierre de la implementación: operación acreditada. La tercera etapa finaliza la sección 1.4.1 al convertir las piezas verificadas en un protocolo operacional completo. El objetivo no es añadir otra familia de modelos, sino establecer cuándo una ejecución puede considerarse íntegra, cómo se conserva un resultado reutilizable y qué evidencia debe existir antes de exponerlo. La Tabla 25 resume la evolución: la primera etapa construyó el recorrido por modelo; la segunda integró productores y consumidores bajo una identidad de campaña; y la tercera cierra las transiciones, la persistencia, la recuperación y las superficies de consumo.

Tabla 25: Progresión verificable de la sección 1.4.1. Cada etapa conserva los contratos de la anterior y añade una frontera distinta.

Etapa	Problema resuelto	Producto principal	Puerta de aceptación
Primera	Convertir el diseño en cálculo reproducible	Recorrido temporal, estimadores, parámetros y métricas	Pruebas unitarias, causalidad y maestro dorado
Segunda	Integrar componentes sin mezclar procedencias	Registro canónico, preparación aislada, transporte y cobertura	Verificación previa, recibos y conjuntos exactos de claves
Tercera	Cerrar el ciclo de vida del resultado	Estados de campaña, persistencia, promoción y consumo	Verificación del sello, transacción y publicación

Identidad operativa y sello de arranque. Antes de crear un artefacto, el lanzador comprueba un repositorio limpio y deriva la identidad desde fuentes vivas: revisión del código, suma del panel, inventario de instantáneas, archivos de bloqueo, entornos instalados y conjunto exacto de puntos de entrada. La verificación previa materializa esos datos en un sello de esquema cerrado; no acepta campos adicionales, listas vacías, rutas absolutas o fuera del proyecto, duplicados ni valores numéricos no finitos. El identificador de campaña incorpora el inicio de la revisión de código y una fecha válida, por lo que un nombre parecido no sustituye la identidad comprobada.

El lanzador vuelve a emitir la verificación previa inmediatamente antes de abrir la transacción y exige igualdad byte a byte con el sello registrado. Esta segunda lectura cierra la ventana entre la revisión inicial y el primer productor: si cambió una entrada, un entorno, el panel o la lista de módulos, la ejecución termina sin crear resultados. La bitácora se conserva aparte y no altera el estado Git que se acredita; aun así, cualquier archivo de cálculo no declarado mantiene el árbol sucio y bloquea el arranque.

Máquina de estados de campaña. Una campaña avanza por estados explícitos, como muestra la Figura 42. `running` indica que las precondiciones fueron aceptadas y que los productores pueden escribir únicamente en preparación; `computed` acredita que terminó el cálculo esperado, con esquema, cobertura, *hashes* y procedencia verificados; `validated` exige además una revisión humana acreditada de ese cálculo y del candidato que lo publicará, de modo que un candidato nuevo requiere otra revisión que la revalida; y `published` autoriza sustituir la versión servida. Cualquier error conduce a `failed`; nunca se interpreta la mera existencia de un archivo como una transición válida.

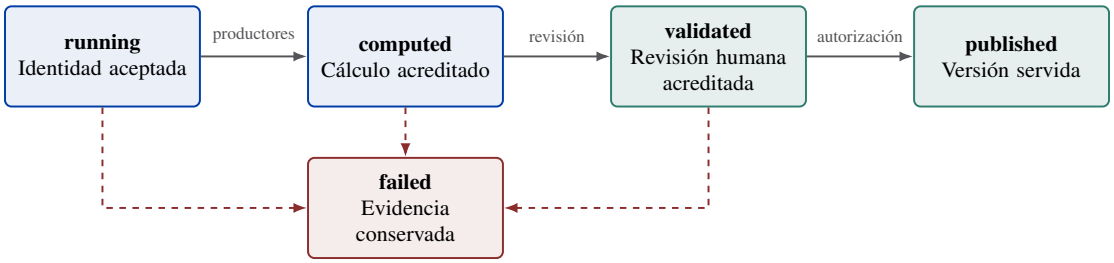


Figura 42: Máquina de estados de la campaña. Sólo una campaña calculada, validada por revisión humana y autorizada puede publicarse; cualquier fallo conserva la evidencia y la versión servida anterior.

Persistencia y ensamblaje del producto. La persistencia sigue la capacidad medida de cada modelo, no el nombre de su clase. SARIMA, ARIMA, Kalman y los regresores de árbol conservan su estado local; SARIMA utiliza serialización comprimida y una prueba de guardar–cargar–pronosticar con tolerancia cero. Los cinco modelos globales conservan sus directorios de campaña. ETS y Theta, en cambio, no se presentan como objetos reutilizables:

sus 24 pronósticos mensuales se transportan desde el recorrido temporal oficial y se vuelven a acreditar al leer.

El promotor exige exactamente los modelos persistibles y globales, mientras el exportador exige los doce pronósticos finales definidos por el registro. Esta separación impide dos errores opuestos: exigir un objeto que técnicamente no puede reutilizarse o volver opcional un pronóstico porque no produce un objeto persistente. La preparación sólo sustituye al árbol servido mediante una promoción atómica; si falta un modelo, una serie o un mes, el árbol anterior permanece intacto.

Clasificación de artefactos y recuperación. La inspección de una escena no asigna una sola causa por archivo. Un artefacto puede estar incompleto y contaminado al mismo tiempo: incompleto cuando no cubre el conjunto esperado; contaminado cuando mezcla campañas, versiones, fechas o procedencias. El clasificador aplica ambas etiquetas de manera independiente y también inspecciona punteros DVC, pues un archivo pequeño puede acreditar un árbol voluminoso incoherente. La Tabla 26 relaciona cada clase de fallo con su respuesta segura.

Tabla 26: Taxonomía operacional empleada para detener, diagnosticar y recuperar una campaña sin heredar artefactos dudosos.

Fallo	Detección	Respuesta	Recuperación
Entorno divergente	Inventario instalado distinto del archivo de bloqueo	Abortar antes de calcular	Reconstruir el entorno aislado
Linaje inválido	Nombre, mes o *hash* de instantánea distinto	Rechazar la etapa de datos	Restaurar o adquirir la evidencia correcta
Salida incompleta	Claves esperadas ausentes	Conservar preparación; no agregar	Corregir el productor y repetir su etapa
Contaminación	Identidades o añadas incompatibles	Etiquetar y aislar el conjunto	Reconstruir desde entradas acreditadas
Mutación posterior	*Hash* distinto o segunda lectura inconsistente	Invalidar el recibo	Regenerar artefacto y recibo
Publicación no vinculada	Sello y transacción sin enlace acreditado	Bloquear la promoción final	Verificar y registrar la identidad común

Superficies de consumo. El producto no entrena a petición del usuario. Una campaña validada materializa archivos CSV y JSON para consulta, tablas y figuras para el documento académico y datos estáticos para el portal. Todos se derivan de la misma versión y se publican después de la promoción; ninguna interfaz vuelve a calcular silenciosamente un modelo ni busca un archivo antiguo como respaldo. Esta arquitectura reduce costo, separa el cálculo prolongado de la consulta y permite que una persona sin herramientas de programación consuma los resultados mediante el sitio web.

Pseudocódigo del cierre operacional. El Algoritmo 3 reúne el recorrido final. Contiene tres puertas humanas separadas: una verificación de sólo lectura del estado sellado antes de ejecutar la campaña, una revisión humana acreditada antes de considerarla validada y una autorización explícita antes de publicarla. Omitir cualquiera de ellas convertiría una preparación local en un resultado experimental sin acreditación suficiente.

Algoritmo 3 Cierre operacional y publicación acreditada

Require: Sello registrado S_0 con dictamen de verificación de sólo lectura, registro $\mathscr{M}$, panel P y árbol servido V
Ensure: V intacto o una nueva versión completa, acreditada y autorizada
Reemitir la verificación previa viva S_1
if $S_1 \neq S_0$, el esquema de S_0 es inválido o falta el dictamen sobre S_0 **then**
    Abortar antes de abrir la transacción
end if
Abrir la transacción T en estado `running` y preparar el espacio aislado
for all etapa requerida q en el orden declarado **do**
    Ejecutar q y acreditar sus salidas contra $(S_0, P, \mathscr{M}, T)$
    if q falla o produce claves, *hashes* o identidad incompatibles **then**
        Marcar T como `failed`, conservar evidencia y devolver V
    end if
end for
Marcar T como `computed` y revalidar todos los recibos al leer
if la cobertura final no es exacta **then**
    Marcar T como `failed` y devolver V
end if
Recibir la revisión humana H, ligada a T, a su cómputo y al árbol candidato A
if H no se acredita o su decisión no es aprobatoria **then**
    Conservar T en `computed` sin modificar V
else
    Marcar T como `validated`; un candidato nuevo exige otra revisión, que la revalida
    if falta la autorización de publicación o el árbol integrado difiere de A **then**
        Conservar la campaña validada sin modificar V
    else
        Con T bloqueada, publicar, marcar `published` y exponer la versión
    end if
end if

Configuración consolidada. La Tabla 27 reúne los parámetros que determinan el comportamiento final. Los valores de aceptación no se optimizan junto con el modelo: constituyen el protocolo bajo el cual una métrica o un pronóstico adquiere validez.

Tabla 27: Configuración matemática y operacional consolidada al finalizar la sección 1.4.1.

Elemento	Valor	Justificación
Superficies	FAD y DFF	Mantener ambos criterios del boletín bajo un protocolo común
Universo por superficie	25 series elegibles	Derivar cobertura desde el panel y no desde la salida
Cola de evaluación	24 objetivos mensuales	Conservar meses observados y no observados
Recorrido estadístico	Horizonte 1, paso 1, último punto	Reproducir el recorrido oficial por origen mensual
ETS y Theta	Reajuste en cada paso	Respetar la semántica de los envoltorios automáticos
Modelos globales	Cinco semillas, s_1–s_5	Separar configuración e incertidumbre de inicialización
Escala MASE	Finita y estrictamente positiva	Impedir cocientes sin interpretación métrica
Persistencia SARIMA	Compresión nivel 3	Reducir tamaño sin perder el estado reutilizable
Identidad	Código, panel, instantáneas, archivos de bloqueo, entornos y campaña	Evitar semejanzas sin procedencia demostrable
Promoción	Cobertura exacta y autorización	Prohibir versiones parciales o no verificadas

Evidencia y pruebas finales. Las comprobaciones se distribuyen por nivel para evitar que un conjunto de pruebas sintéticas acredite una ruta que el lanzador nunca invoca. La Tabla 28 resume qué evidencia aporta cada técnica. Los controles benignos son tan importantes como las sustituciones: un objetivo no evaluable debe conservarse con `observed=false` y valor real nulo, mientras una predicción o escala no finita debe fallar cerradamente.

Tabla 28: Capas de verificación empleadas en el cierre de la implementación. Ninguna capa sustituye a las demás.

Técnica	Propiedad comprobada	Evidencia esperada
Prueba unitaria	Escalas, constructores, esquemas y tipos	Error localizado o control benigno aceptado
Prueba contractual	Claves, *hashes*, duplicados, cobertura e identidad	Recibo recalculable y diagnóstico completo
Prueba de integración	El productor real alimenta al consumidor real	Ruta del lanzador ejercitada sin atajos de fixture
Maestro dorado	Instrumentar no altera las métricas existentes	Campos numéricos invariantes antes y después
Prueba metamórfica	Un dato futuro no modifica una entrada pasada	Igualdad de características en orígenes previos
Prueba de sustitución	Sustituciones que conservan conteos o forma	Rechazo antes de agregación, promoción o publicación
Verificación de sólo lectura	Código, entorno, datos y protocolo concuerdan	Dictamen de sólo lectura sobre un único estado

Herramientas, legibilidad y mantenimiento. Python organiza los módulos de datos, modelado, acreditación y publicación; DuckDB materializa el almacén analítico; Git y DVC separan código, punteros y cargas voluminosas; y MLflow puede recibir el historial de una campaña sin convertirse en autoridad de cobertura. pytest ejecuta controles unitarios y de integración, Ruff y mypy revisan la calidad estática, y los flujos automatizados repiten esas puertas antes de integrar cambios.

La mantenibilidad se apoya en identificadores lógicos, esquemas cerrados y funciones con una responsabilidad verificable. Las listas duplicadas de modelos se sustituyen por vistas derivadas del registro; los lectores reciben rutas y derivan la identidad en lugar de aceptar declaraciones del llamador; y los mensajes muestran claves ausentes y no esperadas completas. El comentario explica la razón de una regla excepcional, mientras el nombre de la función y su contrato expresan el comportamiento ordinario.

Cierre de la sección 1.4.1. Las tres etapas dejan documentado el proceso inicial, la integración y el cierre operacional de la implementación. El sistema dispone de un recorrido temporal causal, catálogo canónico, entornos reproducibles, persistencia según capacidad real, cobertura exacta, preparación aislada, estados explícitos, promoción atómica y pruebas que atacan tanto piezas como rutas completas. Con ello se satisface el objetivo de convertir el diseño en una solución funcional, mantenible y evaluable.

El estado se declaró sin anticipar resultados: al cierre de la tercera etapa la implementación estaba verificada localmente, pero la campaña prolongada no se había ejecutado y la publicación quedaba fuera de ese alcance. Antes de autorizarla se exigió una verificación de sólo lectura sobre el mismo estado que se pretendía ejecutar y, en particular, sobre el vínculo entre el sello comparado al arrancar, la transacción y los artefactos que una publicación posterior consumiría. Esa frontera separó la finalización del software de la obtención de evidencia experimental nueva. La campaña causal se ejecutó después, en octubre de 2026, una vez superada esa verificación. Su corte publicado siguió el orden del Algoritmo 3: primero se reconcilió con sus complementos acreditados (Apéndice A.10); después, una revisión humana del candidato reconciliado la validó y, cuando el candidato cambió, la revalidó con una revisión nueva; sólo entonces se publicó. Sus resultados alimentan las secciones 1.4.2 a 1.4.4 de este documento.

1.4.2 Ajustes al modelo con diferentes configuraciones

Las métricas de evaluación de este documento provienen de la campaña causal sobre el corte de evaluación de septiembre de 2026; los censos descriptivos de las secciones 1.1 y 1.2 corresponden al panel operativo vigente de noviembre de 2026, que incorpora boletines nuevos sin rehacer la evaluación.

La validación temporal usa una ventana inicial de 60 meses para FAD y de 36 para DFF, con paso mensual, reservando los últimos 24 meses como conjunto de prueba independiente.

Los modelos estadísticos se reentrenan en cada origen (ventana expansible verdadera); las redes neuronales se reentrenan cada doce meses, un compromiso documentado entre costo computacional y validez. La selección de hiperparámetros se realiza dentro de cada ventana de entrenamiento, nunca sobre el conjunto de prueba, para impedir la fuga de información.

Configuraciones comparadas y alcance de la atribución. Las variantes se organizaron por familia de modelos. En los métodos clásicos se contrastaron persistencia, tendencia amortiguada, descomposición y componentes autorregresivos; en los árboles se modificaron los rezagos, la profundidad y la regularización; en las redes se estudiaron la representación temporal, la capacidad y el esquema de entrenamiento. La variable objetivo de los árboles es el avance mensual, cuya suma reconstruye la fecha, para evitar que el algoritmo sólo reproduzca el nivel creciente del calendario. La configuración se decide antes de consultar el conjunto reservado; una mejora de selección no es todavía una mejora de generalización. Los cambios concretos que corrigieron la especificación de las redes (primera diferencia en lugar del nivel, escalado que ya no se congela en la ventana inicial y 500 muestras de la distribución predictiva en lugar de una) se describen en la sección 1.3.1.

La comparación causal vigente conserva una conclusión incómoda: aumentar la complejidad no garantiza superar al método de persistencia en el pronóstico a un mes. En FAD, las medias de MASE de ETS y Theta son 0.167 y 0.171, frente a 0.157 del naïve-1. Estos agregados deben leerse con la cobertura de cada modelo y no equivalen a una prueba pareada sobre una población idéntica. La Tabla 29 resume las configuraciones ensayadas y su efecto medido. En DFF, BiTCN alcanza una media 0.122 frente a 0.125 del piso; esa diferencia es descriptiva y no demuestra superioridad estadística frente al naïve-1.

Tabla 29: Configuraciones ensayadas por familia y efecto medido en el conjunto reservado de 24 meses (MASE medio a un paso; FAD sobre las series familiares). Ninguna configuración mejora el piso del naïve-1 en FAD.

Configuración	Qué se modificó	Efecto medido
Persistencia (naïve-1)	Ninguna: repite el último corte publicado	FAD 0.157; DFF 0.125. Piso de referencia
Clásicos	Tendencia amortiguada (ETS), Theta y orden ARIMA por criterio de información	FAD: ETS 0.167, Theta 0.171, Auto-ARIMA 0.212; DFF: Auto-ARIMA 0.146. No mejoran el piso
Árboles optimizados	Tasa de aprendizaje, profundidad y submuestreo de filas y columnas; 150 a 300 ensayos por grupo	Aceptados 9 de 12 grupos en la cola de confirmación; FAD reservado entre 0.172 y 0.176
Redes globales	Arquitectura, capacidad y regularización; cinco semillas	DFF: BiTCN 0.122 (desviación 0.0006); FAD: AutoBiTCN 0.162 (desviación 0.005)
Preparación causal	Relleno con la última observación y máscaras de ausencia	Cambia junto con el tramo evaluado; su efecto aislado no se identifica

Las variantes históricas de representación y relleno se conservaron como diagnóstico. La re-derivación causal cambia simultáneamente la preparación y el periodo evaluado; por ello, la diferencia respecto de una versión anterior no identifica el efecto aislado de una sola decisión. La selección de descriptores tampoco autoriza una conclusión predictiva: con el protocolo aplicado, 0 de 44 candidatos superaron el control de falsos descubrimientos sobre 50 series, pero esos descriptores no constituyen las entradas del repertorio predictivo comparado.

1.4.3 Evaluación del modelo

La evaluación responde dos preguntas distintas: el error retrospectivo de un modelo ajustado sin información futura y el comportamiento de los pronósticos congelados antes de conocer sus objetivos. No se mezclan sus poblaciones ni sus horizontes. MAE expresa el error absoluto en días; RMSE da mayor peso a errores grandes; sMAPE aporta una escala relativa y debe interpretarse con cautela en avances cercanos a cero. MASE divide el error por una escala calculada únicamente con el entrenamiento [54]. Una MASE menor que uno respecto del naïve estacional no prueba, por sí misma, que se haya superado el pronóstico naïve-1 fuera de muestra: esa comparación requiere los mismos pares observados y el contraste correspondiente.

Las métricas puntuales se calculan sólo donde el boletín publica una fecha. Los estados `C` y `U` conservan su semántica y no se puntúan como fechas reales ni como clases predichas. Precisión, exhaustividad y F1 no son las métricas primarias de esta tarea de pronóstico temporal. Para la incertidumbre se informa cobertura empírica, amplitud de los intervalos y la puntuación de probabilidad continua ordenada (*Continuous Ranked Probability Score*, CRPS) [55], con el protocolo y la procedencia de las muestras. Una cobertura elevada por intervalos excesivamente anchos tampoco basta para declarar útil una configuración.

El registro por horizonte contiene 2,944 pronósticos puntuados, con MAE de 146 días y MASE de 0.347 sobre la escala estacional. Son agregados de ambas tablas y varios horizontes, no el resultado del campeón FAD a un paso. La cobertura empírica al 95 % es 0.92; se distingue el conjunto usado para calibrar de los pares reservados para evaluar. Los contrastes de Diebold–Mariano y los procedimientos de comparación múltiple complementan el tamaño del efecto, sin convertir falta de significancia en equivalencia [56].

La Tabla 30 desagrega el conjunto reservado a un paso por tabla. En FAD, el naïve-1 obtiene MASE medio 0.157 y mediano 0.135, frente a 0.167 de ETS y 0.171 de Theta; en DFF, el naïve-1 obtiene 0.125 de media y 0.101 de mediana. Al comparar sobre las series distintas, que descuentan las pseudo-réplicas del corte mundial, el campeón desplegado promedia 0.152 en FAD frente a 0.140 del naïve-1, y 0.121 en DFF frente a 0.103. Su CRPS acreditado es de 41.5 días en FAD y 27.9 en DFF. La lectura conjunta es que el campeón desplegado aporta un pronóstico probabilístico calibrado, pero su error puntual no supera al de la persistencia.

Tabla 30: Evaluación en el conjunto reservado a un paso, por tabla. MASE media y mediana del naïve-1 sobre las series familiares; el campeón se compara con el naïve-1 sobre las mismas series distintas.

Indicador	FAD	DFF
MASE del naïve-1 (media y mediana)	0.157 y 0.135	0.125 y 0.101
MASE de ETS y Theta (media)	0.167 y 0.171	0.129 y 0.125
MASE del campeón desplegado (series distintas)	0.152	0.121
MASE del naïve-1 en las mismas series	0.140	0.103
CRPS del campeón (días)	41.5	27.9

1.4.4 Optimización de parámetros y pruebas avanzadas

Los árboles de potenciación de gradiente se optimizan con *Optuna* [53] (muestreo TPE, *Tree-structured Parzen Estimator*, multivariante, semilla fija, con poda por mediana y almacenamiento persistente de los estudios) bajo un protocolo *anidado y libre de fuga* con **tres particiones**: la región de selección se divide en entrenamiento, una cola de *val-tuning* (24 meses) donde Optuna optimiza, y una cola de *val-confirmación* (12 meses), que ni el buscador ni la configuración incumbente vieron jamás, donde se decide la **aceptación**; el conjunto reservado de 24 meses queda solo para el número publicado y *nunca* interviene en la búsqueda ni en la decisión. El objetivo puntúa únicamente los meses con fecha publicada (máscara $e = F$) y descuenta las series pseudo-replicadas del corte mundial, para que la búsqueda no optimice meses de relleno ni sobrepondere series repetidas. El presupuesto es real (150 ensayos por grupo modelo$\times$tabla$\times$bloque, incluidas **por primera vez las categorías de empleo**) y el espacio, amplio y sesgado a la regularización (tasa de aprendizaje en escala logarítmica, profundidad, submuestreo de filas y columnas). La regla de aceptación compara las medias en val-confirmación y se reporta **siempre acompañada de la mediana y del porcentaje de series que mejoran**, con reversión por serie a los valores por defecto cuando estos ganan. Para las redes globales, la búsqueda incorpora la arquitectura (tamaño oculto, *dropout*, núcleo) con parada temprana, se ejecuta *una sola vez* y la configuración ganadora se reentrena con cinco semillas. Los modelos estadísticos no entran en esta búsqueda porque su propia selección por criterio de información (AICc) ya cumple esa función.

Elección de la estrategia de búsqueda. La búsqueda en cuadrícula recorre todas las combinaciones de un espacio predefinido y su costo crece de forma exponencial con el número de hiperparámetros; la búsqueda aleatoria reduce ese costo al muestrear el espacio y suele encontrar configuraciones competitivas con menos evaluaciones, porque sólo algunos hiperparámetros influyen de forma decisiva [57]. Aquí se prefirió el muestreo TPE, que aprende de los ensayos previos y concentra los siguientes en las regiones prometedoras: el espacio mezcla escalas logarítmicas y enteras, y cada entrenamiento es costoso. La

validación es temporal y no un *k-fold* aleatorio, porque mezclar meses futuros con pasados filtraría información [58].

Resultado de la optimización. El resultado se mide en dos niveles. En la cola de confirmación se aceptó una configuración distinta de la predeterminada en 9 de 12 grupos (5 familiares y 4 de empleo), con reversión por serie a los valores predeterminados cuando estos ganan. En el conjunto reservado, los árboles optimizados (LightGBM, CatBoost y XGBoost) quedan entre 0.172 y 0.176 de MASE en FAD, frente a 0.157 del naïve-1: la optimización mejora la selección, pero no supera el piso ingenuo, y se informa como un resultado negativo. En las redes globales, la configuración ganadora de la búsqueda única, reentrenada con cinco semillas, deja a AutoBiTCN en 0.162 en FAD, por debajo del par ETS-Theta y por encima del naïve-1.

Pruebas avanzadas y costo computacional. Las pruebas avanzadas comprenden la evaluación en varios horizontes, las repeticiones con semillas controladas y las cohortes registradas de antemano de series estables y no estables. El barrido de arquitecturas profundas se ejecutó en una instancia efímera en la nube con acelerador NVIDIA A10G, terminada al concluir, y los estudios de Optuna se almacenan de forma persistente para verificar las configuraciones ensayadas y descartadas. Una repetición idéntica confirma la reproducibilidad del cálculo, no una certeza estadística.

Los intervalos de predicción al 95 % se generan por tres mecanismos complementarios. El primero es el probabilístico: ARIMA, SARIMA y DeepAR muestrean su distribución predictiva, de la que se leen los cuantiles 2.5 % y 97.5 %. El segundo es el conforme dividido, un método no paramétrico y agnóstico al modelo que fija el semiancho a partir del cuantil de los errores absolutos de calibración (calculados solo sobre meses con fecha publicada), con cobertura garantizada bajo intercambiabilidad [59]; al no depender del modelo, sirve de red de seguridad uniforme para los 24. El tercero es el que **despliega el demostrador**: bandas cuyo semiancho por horizonte $h = 1, \ldots, 12$ se calibra con el *cuantil empírico* de los errores realmente observados en el registro de evaluación por horizonte (sección 1.4.3), separadas por tabla y nivel (80 y 95 %), y ajustadas en línea con inferencia conforme adaptativa conforme llegan boletines nuevos; este mecanismo sustituyó al factor de ensanchamiento paramétrico único de la primera versión, cuya cobertura se degradaba en los horizontes largos. La cobertura empírica resultante se informa en la sección 1.4.3 y el detalle operativo en el Apéndice A.10.

Referencias

[1] P. Chapman *et al.*, "CRISP-DM 1.0: Step-by-step data mining guide," SPSS Inc., 2000.

[2] U.S. Department of State, Bureau of Consular Affairs, "Visa Bulletin." [En línea]. Disponible en: `https://travel.state.gov/content/travel/en/legal/visa-law0/visa-bulletin.html`. [Accedido: 23-oct-2026].

[3] *Immigration and Nationality Act*, 8 U.S.C. § 1152, "Numerical limitations on individual foreign states." [En línea]. Disponible en: `https://uscode.house.gov/`. [Accedido: 29-oct-2026].

[4] U.S. Citizenship and Immigration Services, "Adjustment of Status Filing Charts from the Visa Bulletin." [En línea]. Disponible en: `https://www.uscis.gov/green-card/green-card-processes-and-procedures/visa-availability-priority-dates/adjustment-of-status-filing-charts-from-the-visa-bulletin`. [Accedido: 29-oct-2026].

[5] U.S. Department of State, Bureau of Consular Affairs, "Annual Report of the Visa Office." [En línea]. Disponible en: `https://travel.state.gov/content/travel/en/legal/visa-law0/visa-statistics/annual-reports.html`. [Accedido: 1-oct-2026].

[6] K. Reitz, "Requests: HTTP for Humans," documentación del proyecto, 2026. [En línea]. Disponible en: `https://requests.readthedocs.io`. [Accedido: 29-oct-2026].

[7] L. Richardson, "Beautiful Soup documentation," 2026. [En línea]. Disponible en: `https://www.crummy.com/software/BeautifulSoup/bs4/doc/`. [Accedido: 29-oct-2026].

[8] W. McKinney, "Data structures for statistical computing in Python," en *Proc. 9th Python in Science Conf. (SciPy)*, 2010, pp. 56–61.

[9] H. Wickham, "Tidy data," *Journal of Statistical Software*, vol. 59, n.º 10, pp. 1–23, 2014.

[10] Apache Software Foundation, "Apache Parquet," software de código abierto, 2026. [En línea]. Disponible en: `https://parquet.apache.org`. [Accedido: 29-oct-2026].

[11] J. D. Hunter, "Matplotlib: A 2D graphics environment," *Computing in Science & Engineering*, vol. 9, n.º 3, pp. 90–95, 2007.

[12] M. L. Waskom, "seaborn: statistical data visualization," *Journal of Open Source Software*, vol. 6, n.º 60, art. 3021, 2021.

[13] S. Seabold y J. Perktold, "statsmodels: Econometric and statistical modeling with Python," en *Proc. 9th Python in Science Conf. (SciPy)*, 2010, pp. 92–96.

[14] P. Virtanen *et al.*, "SciPy 1.0: Fundamental algorithms for scientific computing in Python," *Nature Methods*, vol. 17, n.º 3, pp. 261–272, 2020.

[15] C. Truong, L. Oudre y N. Vayatis, "Selective review of offline change point detection methods," *Signal Processing*, vol. 167, art. 107299, 2020.

[16] C. H. Lubba, S. S. Sethi, P. Knaute, S. R. Schultz, B. D. Fulcher, y N. S. Jones, "catch22: CAnonical Time-series CHaracteristics," *Data Mining and Knowledge Discovery*, vol. 33, n.º 6, pp. 1821–1852, 2019.

[17] M. Raasveldt y H. Mühleisen, "DuckDB: An embeddable analytical database," en *Proc. ACM SIGMOD Int. Conf. on Management of Data*, 2019, pp. 1981–1984.

[18] R. B. Cleveland, W. S. Cleveland, J. E. McRae, y I. Terpenning, "STL: A seasonal-trend decomposition procedure based on loess," *Journal of Official Statistics*, vol. 6, n.º 1, pp. 3–73, 1990.

[19] D. Kwiatkowski, P. C. B. Phillips, P. Schmidt, y Y. Shin, "Testing the null hypothesis of stationarity against the alternative of a unit root," *Journal of Econometrics*, vol. 54, n.º 1–3, pp. 159–178, 1992.

[20] G. Elliott, T. J. Rothenberg, y J. H. Stock, "Efficient tests for an autoregressive unit root," *Econometrica*, vol. 64, n.º 4, pp. 813–836, 1996.

[21] X. Wang, K. Smith, y R. J. Hyndman, "Characteristic-based clustering for time series data," *Data Mining and Knowledge Discovery*, vol. 13, n.º 3, pp. 335–364, 2006.

[22] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.ª ed. Melbourne, Australia: OTexts, 2021.

[23] R. Killick, P. Fearnhead, y I. A. Eckley, "Optimal detection of changepoints with a linear computational cost," *Journal of the American Statistical Association*, vol. 107, n.º 500, pp. 1590–1598, 2012.

[24] W. A. Brock, W. D. Dechert, J. A. Scheinkman, y B. LeBaron, "A test for independence based on the correlation dimension," *Econometric Reviews*, vol. 15, n.º 3, pp. 197–235, 1996.

[25] M. Christ, N. Braun, J. Neuffer, y A. W. Kempa-Liehr, "Time series feature extraction on basis of scalable hypothesis tests (tsfresh – A Python package)," *Neurocomputing*, vol. 307, pp. 72–77, 2018.

[26] C. Ding y H. Peng, "Minimum redundancy feature selection from microarray gene expression data," *Journal of Bioinformatics and Computational Biology*, vol. 3, n.º 2, pp. 185–205, 2005.

[27] T. Henderson y B. D. Fulcher, "An empirical evaluation of time-series feature sets," en *Proc. 2021 Int. Conf. on Data Mining Workshops (ICDMW)*, 2021, pp. 1032–1038.

[28] S. Moritz y T. Bartz-Beielstein, "imputeTS: Time series missing value imputation in R," *The R Journal*, vol. 9, n.º 1, pp. 207–218, 2017.

[29] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, y G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5.ª ed. Hoboken, NJ: Wiley, 2015.

[30] E. S. Gardner, Jr. y E. McKenzie, "Forecasting trends in time series," *Management Science*, vol. 31, n.º 10, pp. 1237–1246, 1985.

[31] R. J. Hyndman, A. B. Koehler, J. K. Ord, y R. D. Snyder, *Forecasting with Exponential Smoothing: The State Space Approach*. Berlín: Springer, 2008.

[32] V. Assimakopoulos y K. Nikolopoulos, "The theta model: A decomposition approach to forecasting," *International Journal of Forecasting*, vol. 16, n.º 4, pp. 521–530, 2000.

[33] R. E. Kalman, "A new approach to linear filtering and prediction problems," *Journal of Basic Engineering*, vol. 82, n.º 1, pp. 35–45, 1960.

[34] S. J. Taylor y B. Letham, "Forecasting at scale," *The American Statistician*, vol. 72, n.º 1, pp. 37–45, 2018.

[35] T. Chen y C. Guestrin, "XGBoost: A scalable tree boosting system," en *Proc. 22nd ACM SIGKDD*, 2016, pp. 785–794.

[36] G. Ke *et al.*, "LightGBM: A highly efficient gradient boosting decision tree," en *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 3146–3154.

[37] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, y A. Gulin, "CatBoost: Unbiased boosting with categorical features," en *Advances in Neural Information Processing Systems*, vol. 31, 2018, pp. 6638–6648.

[38] S. Hochreiter y J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, n.º 8, pp. 1735–1780, 1997.

[39] D. Salinas, V. Flunkert, J. Gasthaus, y T. Januschowski, "DeepAR: Probabilistic forecasting with autoregressive recurrent networks," *International Journal of Forecasting*, vol. 36, n.º 3, pp. 1181–1191, 2020.

[40] G. P. Zhang, "Time series forecasting using a hybrid ARIMA and neural network model," *Neurocomputing*, vol. 50, pp. 159–175, 2003.

[41] A. Zeng, M. Chen, L. Zhang, y Q. Xu, "Are transformers effective for time series forecasting?," en *Proc. AAAI Conf. Artificial Intelligence*, vol. 37, n.º 9, pp. 11121–11128, 2023.

[42] A. Das, W. Kong, A. Leach, S. Mathur, R. Sen, y R. Yu, "Long-term forecasting with TiDE: Time-series dense encoder," *Transactions on Machine Learning Research*, 2023, arXiv:2304.08424.

[43] B. N. Oreshkin, D. Carpov, N. Chapados, y Y. Bengio, "N-BEATS: Neural basis expansion analysis for interpretable time series forecasting," en *Int. Conf. on Learning Representations (ICLR)*, 2020, arXiv:1905.10437.

[44] C. Challu, K. G. Olivares, B. N. Oreshkin, F. Garza, M. Mergenthaler-Canseco, y A. Dubrawski, "NHITS: Neural hierarchical interpolation for time series forecasting," en *Proc. AAAI Conf. Artificial Intelligence*, vol. 37, n.º 6, pp. 6989–6997, 2023.

[45] B. Lim, S. Ö. Arık, N. Loeff, y T. Pfister, "Temporal fusion transformers for interpretable multi-horizon time series forecasting," *International Journal of Forecasting*, vol. 37, n.º 4, pp. 1748–1764, 2021.

[46] A. F. Ansari *et al.*, "Chronos: Learning the language of time series," *Transactions on Machine Learning Research*, 2024, arXiv:2403.07815.

[47] R. Kuprieiev *et al.*, "DVC: Data Version Control, Git for data & models," Iterative, software de código abierto, 2024. [En línea]. Disponible en: `https://dvc.org`. [Accedido: 29-oct-2026].

[48] J. Herzen *et al.*, "Darts: User-friendly modern machine learning for time series," *Journal of Machine Learning Research*, vol. 23, n.º 124, pp. 1–6, 2022.

[49] A. Paszke *et al.*, "PyTorch: An imperative style, high-performance deep learning library," en *Advances in Neural Information Processing Systems*, vol. 32, 2019, pp. 8026–8037.

[50] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[51] M. Zaharia *et al.*, "Accelerating the machine learning lifecycle with MLflow," *IEEE Data Engineering Bulletin*, vol. 41, n.º 4, pp. 39–45, 2018.

[52] GitHub, "GitHub Actions documentation," 2026. [En línea]. Disponible en: `https://docs.github.com/actions`. [Accedido: 29-oct-2026].

[53] T. Akiba, S. Sano, T. Yanase, T. Ohta, y M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," en *Proc. 25th ACM SIGKDD*, 2019, pp. 2623–2631.

[54] R. J. Hyndman y A. B. Koehler, "Another look at measures of forecast accuracy," *International Journal of Forecasting*, vol. 22, n.º 4, pp. 679–688, 2006.

[55] T. Gneiting y A. E. Raftery, "Strictly proper scoring rules, prediction, and estimation," *Journal of the American Statistical Association*, vol. 102, n.º 477, pp. 359–378, 2007.

[56] F. X. Diebold y R. S. Mariano, "Comparing predictive accuracy," *Journal of Business & Economic Statistics*, vol. 13, n.º 3, pp. 253–263, 1995.

[57] J. Bergstra y Y. Bengio, "Random search for hyper-parameter optimization," *Journal of Machine Learning Research*, vol. 13, pp. 281–305, 2012.

[58] C. Bergmeir y J. M. Benítez, "On the use of cross-validation for time series predictor evaluation," *Information Sciences*, vol. 191, pp. 192–213, 2012.

[59] V. Vovk, A. Gammerman, y G. Shafer, *Algorithmic Learning in a Random World*. Nueva York: Springer, 2005.

Apéndice

Este apéndice reúne el material de respaldo de las secciones 1.1 y 1.2: el diccionario de datos del panel obtenido (A.1), el catálogo de las dimensiones efectivamente observadas (A.2), el registro de limpieza del corte vigente (A.3), la cadena reproducible que regenera los artefactos (A.4), una consulta de verificación sobre el almacén (A.5), el entorno y los comandos exactos de reproducción (A.6), el repositorio público donde reside todo lo anterior (A.7), las órdenes que reproducen el análisis exploratorio de la sección 1.2.1 junto con los mecanismos que lo mantienen trazable (A.8) y las que reproducen el preprocesamiento de la sección 1.2.2 con sus salvaguardas de integridad (A.9). Los apéndices A.10 y A.11 respaldan la sección 1.4: los guardarraíles que seleccionan el modelo desplegado y la integración y entrega continuas.

A.1 Diccionario de datos del panel

El panel largo `visa_panel_long.csv` es la salida de la conversión descrita en la sección 1.1.2 y la fuente abierta de la que se derivan el almacén y el archivo columnar. Cada fila es una observación del grano (área de cargabilidad, categoría, tabla, mes de boletín) y consta de las nueve variables de la Tabla 31, ilustradas con una fila real del corte de julio de 2026.

Tabla 31: Diccionario de las nueve variables del panel largo, con su dominio y el valor que toman en una observación real (México, F3, FAD, julio de 2026).

Variable	Tipo	Dominio	Ejemplo
`country`	Texto	Área de cargabilidad: `mexico`, `india`, `china`, `philippines`, `all_chargeability`	`mexico`
`block`	Texto	Bloque de preferencia: `family` o `employment`	`family`
`category`	Texto	21 códigos canónicos (F1–F4 y EB1–EB5 con subcategorías)	`F3`
`table`	Texto	Tipo de tabla: `FAD` o `DFF`	`FAD`
`bulletin_date`	Fecha	Primer día del mes del boletín, de 2001-12 a 2026-11	`2026-07-01`
`status`	Texto	Régimen e: `F`, `C`, `U` o `UNK`	`F`
`priority_date`	Fecha	Fecha de prioridad publicada; definida solo si `status = F`	`2001-06-01`
`days_since_base`	Entero	Variable dependiente $y_{p,c,b,t}$: días desde $t_0 =$ 1975-01-01; definida solo si `status = F`	`9648`
`raw_value`	Texto	Contenido de la celda tal como se publicó, sin normalizar	`01JUN01`

Estas definiciones no son una convención de documentación: se declaran como restricciones del almacén y se verifican al cargar. La clave primaria es la cuádrupla del grano, de

modo que una observación duplicada es imposible; `days_iff_F` y `pdate_iff_F` exigen que la variable dependiente y la fecha de prioridad existan si y solo si el régimen es F; `days_is_datediff` recalcula la resta contra la época base y rechaza cualquier fila cuya variable dependiente no corresponda a su fecha; y una verificación adicional impide valores negativos, que delatarían una fecha anterior a t_0.

A.2 Catálogo de dimensiones observadas

El panel cubre cinco áreas de cargabilidad y veintiuna categorías migratorias. La Tabla 32 presenta el catálogo con el número de observaciones de cada categoría, que explica por qué las 194 series estructurales no equivalen al producto cartesiano de las dimensiones: varias subcategorías nacieron o desaparecieron a lo largo del periodo (por ejemplo, las reservas de EB-5 creadas en 2022 o la categoría de traductores), de modo que solo existen en una fracción de los meses.

Tabla 32: Categorías migratorias observadas en el panel, por bloque de preferencia, con su número de observaciones. Las cinco áreas de cargabilidad aportan entre 38 y 39 series cada una, para un total de 194.

Bloque	Categoría	Obs.	Bloque	Categoría	Obs.
Familiar	F1	2,113	Empleo	EB5	480
Familiar	F2A	2,113	Empleo	EB5_TEA	729
Familiar	F2B	2,113	Empleo	EB5_PILOT	105
Familiar	F3	2,113	Empleo	EB5_RC	805
Familiar	F4	2,113	Empleo	EB5_NONRC	790
Empleo	EB1	2,084	Empleo	EB5_UNRESERVED	550
Empleo	EB2	2,084	Empleo	EB5_RURAL	550
Empleo	EB3	2,084	Empleo	EB5_HIGHUNEMP	550
Empleo	EB3_OW	2,084	Empleo	EB5_INFRA	550
Empleo	EB4	2,084	**Total familiar**		**10,565**
Empleo	EB4_RW	2,077	**Total empleo**		**17,646**
Empleo	EB4_TRANS	40	**Total panel**		**28,211**

A.3 Registro de limpieza del corte vigente

Cada construcción del panel escribe un registro de limpieza determinista, versionado junto al código, que documenta qué produjo esa añada y qué guardas se evaluaron. El registro del corte operativo de noviembre de 2026 es el siguiente. El panel y los pronósticos operativos se actualizan mensualmente; las comparaciones retrospectivas conservan el corte causal de septiembre usado por la campaña, sin recalcularse al incorporar otro boletín:

```
{
 "vintage": "2026-11",
 "n_rows": 28211,
```

```
 "n_series": 194,
 "rows_by_status": {"F": 16323, "C": 11262, "U": 625, "UNK": 1},
 "dup_collapsed": 0,
 "bulletin_date_unparseable": 0,
 "f_priority_date_unparseable": 0,
 "epoch_underflow": 0,
 "big_jumps_gt_8y": 14
}
```


Los cuatro contadores en cero corresponden a guardas que **abortan** la construcción cuando se violan, de modo que su valor no puede ser distinto de cero en un panel publicado: documentan la invariante vigente, no una ausencia casual de incidencias. El campo `vintage` es la clave de versión de la añada y sustituye deliberadamente a una marca de reloj, para que dos reconstrucciones del mismo corte produzcan archivos idénticos byte a byte.

A.4 Pipeline reproducible y versionado de datos

La cadena de datos abiertos se declara como un grafo de dependencias versionado con la herramienta de control de versiones de datos (*Data Version Control*, DVC [47]). El comando `dvc repro` reconstruye *en orden y solo lo que cambió* la secuencia `scrape` $\rightarrow$ `panel` $\rightarrow$ {`bulletins`, almacén, cifras canónicas}, con la carpeta de *snapshots* HTML congelados como raíz determinista (el único paso con red queda fuera del grafo). Los artefactos abiertos (panel y tablas en formato CSV) permanecen versionados en Git como entregable descargable, mientras que los binarios derivados se respaldan en almacenamiento de objetos. Un archivo de bloqueo (`dvc.lock`) fija el *hash* de cada entrada y salida del grafo: es la prueba de reproducibilidad, pues ata cada resultado al estado exacto de código y datos que lo generó. Dos ejecuciones consecutivas confirman el determinismo (la segunda no recomputa nada) y un mismo *rebuild* produce datos idénticos byte a byte.

A.5 Almacén dimensional en estrella

El panel se carga en un almacén dimensional en estrella implementado sobre la base de datos analítica embebida DuckDB [17]. El modelo (ya presentado en la Figura 5) comprende doce tablas: siete dimensiones, dos tablas de hechos y tres de gobernanza y procedencia (la versión del esquema, la bitácora de ejecución ampliada y el linaje de artefactos fuente, que ata cada mes del panel al HTML congelado que lo publicó, con su suma de verificación), además de vistas y marts, con restricciones de clave e integridad que actúan como contrato de calidad al cargar. El esquema se construye por migraciones versionadas con suma de verificación por archivo y una verja de historia inmutable: una migración alterada o faltante aborta la carga en lugar de degradarla en silencio, y la única degradación admitida (insumos de linaje ausentes bajo una bandera explícita) queda registrada en la bitácora de ejecución. Las marcas `created_at`/`updated_at` de las tablas de datos se derivan exclusivamente del

dato: corresponden al mes del boletín que publicó la celda, y una actualización real avanza `updated_at` al vintage del corte que la introdujo, detectada por *hash* de contenido por fila, nunca por el reloj del sistema, de modo que una reconstrucción sin cambios las reproduce byte-idénticas; el reloj real queda confinado a la bitácora `etl_run`. A modo de ejemplo, la siguiente consulta resume las observaciones entrenables (estado *F*) por bloque y tipo de tabla directamente desde un *mart*, con el resultado en la Tabla 33:

Tabla 33: Salida real de la consulta anterior sobre el almacén: observaciones entrenables por bloque y tabla. La suma de `obs_F` (6964+3859+3225+2275) reproduce las 16,323 observaciones entrenables del panel.

block	tabla	series	obs_F	pct_F
family	FAD	25	6 964	96.5
employment	FAD	80	3 859	32.8
family	DFF	25	3 225	96.3
employment	DFF	64	2 275	38.6

```
SELECT block, "table" AS tabla, count(*) AS series,
       sum(n_trainable) AS obs_F,
       round(100.0*sum(n_trainable)/sum(n_obs),1) AS pct_F
FROM mart_series_summary GROUP BY block, "table"
ORDER BY obs_F DESC;
```

A.6 Entorno de ejecución y órdenes de reproducción

La cadena de obtención, conversión y análisis corre sobre Python 3.14 con las versiones fijadas de la Tabla 34; el archivo de proyecto las declara con versión exacta, de modo que una instalación limpia reproduce el mismo entorno.

Con ese entorno, la cadena completa se reproduce con seis órdenes, en este orden:

```
make freeze   # congela boletines nuevos (paso con red)
make scrape   # parsea las instantáneas HTML sin conexión
make panel    # consolida el panel + registro de limpieza
make db       # construye el almacén DuckDB y el Parquet
make audit    # verificación del panel (cobertura, claves)
make eda-all  # censo del EDA + figuras por serie y galería
```

Como alternativa, `make repro` ejecuta el grafo de dependencias completo y reconstruye solo las etapas cuyas entradas cambiaron, y `make test` corre la batería de pruebas automatizadas de la capa de datos.

Carga de boletines: el congelado automático y la carga manual. `make freeze` es el paso que la tarea programada de días hábiles ejecuta para descargar y congelar cada boletín nuevo. El cortafuegos de aplicación del sitio del Departamento de

Tabla 34: Principales componentes y versiones fijadas del entorno de obtención, conversión y análisis de los datos, declarados con versión exacta en el archivo de proyecto del repositorio.

Componente	Versión	Función en la cadena
Python	3.14	Intérprete de todo el flujo
`requests` [6]	2.33.0	Descarga de las páginas del boletín
`beautifulsoup4` [7]	4.14.3	Análisis sintáctico del HTML congelado
`pandas` [8]	3.0.0	Consolidación y conversión al panel largo
`duckdb` [17]	1.5.3	Almacén dimensional y archivo columnar
`tqdm`	4.67.3	Barra de progreso de los recorridos largos
DVC [47]	*fijada por perfil*	Grafo de dependencias y versionado de datos
`matplotlib`	3.10.8	Motor de todas las figuras, con paleta institucional única
`seaborn`	0.13.2	Diagramas de violín y de caja, y mapas de calor con agrupamiento jerárquico
`statsmodels`	0.14.6	Descomposición estacional, pruebas de raíz unitaria y de estacionariedad, autocorrelaciones y pruebas de ruido blanco
`scipy`	1.17.1	Periodograma, estimación de densidad, asimetría y curtosis
`ruptures`	1.1.9	Detección de cambios de régimen
`pycatch22`	0.4.5	Conjunto canónico de características de series de tiempo
`antropy`	0.2.2	Entropías de permutación y de muestra

Estado rechaza esa descarga automática, de modo que el congelado ya no obtiene la página del mes: la tarea registra la fuente como bloqueada en el feed de ingesta (`reports/governance/ingestion_state.json`), que declara el estado vigente, desde cuándo rige y su causa, y no fabrica ni reutiliza datos. Mientras dure el bloqueo, cada boletín se **carga de forma manual** por una de dos órdenes gobernadas: `make ingest-manual FILE=...` valida e ingiere la página HTML que una persona descargó del sitio oficial, y `make bulletin MONTH=AAAA-MM` parte del PDF oficial del boletín. Ambas conservan el congelado inmutable en S3 sin sobrescribir una fuente previa, las sumas de verificación y las mismas puertas de calidad y de publicación: cambia cómo se obtiene la fuente, no cómo se valida. Por esta vía entraron los boletines de agosto a noviembre de 2026, y mientras el bloqueo persista la actualización del panel depende de esa intervención humana.

A.7 Repositorio del proyecto

El código, los datos procesados y la documentación residen en un repositorio público de GitHub bajo licencia MIT:

`https://github.com/UACJ-MIAAD/VisaPredictAI`

El repositorio reúne el flujo completo del proyecto: la extracción del *Visa Bulletin* a partir de instantáneas HTML congeladas (procesamiento sin red), la construcción del panel

multiserie $y_{p,c,b,t}$, el almacén dimensional en DuckDB con su esquema estrella, el módulo de modelado `vp_model` con los 24 modelos del repertorio y la red profunda global, y la suite de pruebas con integración continua y piso de cobertura. Incluye un `README` y un `Makefile` que reproducen, paso a paso y con semilla fija, las figuras y tablas que este documento genera por código.

A.8 Reproducción y trazabilidad del análisis exploratorio

Ninguna cifra ni figura de la sección 1.2.1 se produjo a mano. El análisis completo es un paso más del flujo reproducible descrito en el Apéndice A.4 y se regenera con tres órdenes sobre el mismo entorno del Apéndice A.6, cuyas salidas se depositan en el directorio `reports/eda/` del repositorio:

```
make eda-facts   # censo del panel -> eda_facts.json
make eda-all     # censo + figuras por serie y galería
make eda-report  # reporte ejecutivo -> eda_report.pdf
```

El primero recorre el panel completo y escribe un censo en formato `JSON` con diez bloques: la añada del corte, el censo del panel, la composición de regímenes, el resumen de estacionariedad, la ficha por serie, los episodios de retrogresión, la brecha entre FAD y DFF, el atraso vigente, el avance mensual mediano y el sorteo de diversidad. De ese archivo salen, sin transcripción manual, todas las cifras censales que aparecen en la prosa de la sección: se inyectan en el documento como macros derivadas, de modo que una re-derivación de los datos actualiza el texto sin que nadie tenga que reescribirlo. El segundo genera la galería de once figuras insignia y las figuras por serie con una paleta única. El tercero compone un reporte ejecutivo de catorce páginas que reúne la galería con los titulares derivados del censo.

La trazabilidad no depende de la disciplina del autor. Tres mecanismos la sostienen. El análisis se ejecuta como paso propio del proceso continuo que incorpora cada boletín nuevo, de modo que el censo y las figuras nunca quedan rezagados respecto de los datos; una verificación previa detecta si el censo va por detrás del panel y reconstruye lo que haga falta antes de publicar. Un verificador de consistencia compara después las cifras del censo contra las del documento, del repositorio y del portal de divulgación, y falla si una misma cifra discrepa entre artefactos. Y una guarda de completitud impide publicar un censo parcial: si alguna serie no pudo caracterizarse, queda marcada como fallida en lugar de desaparecer del conteo. El censo, el reporte y la galería quedan versionados en el repositorio público (Sección A.7), de modo que cualquier lector puede reproducir el análisis o verificar una cifra concreta contra la observación que la origina.

A.9 Reproducción y trazabilidad del preprocesamiento

Como el análisis exploratorio, el preprocesamiento de la sección 1.2.2 se regenera por completo con tres órdenes sobre el mismo entorno del Apéndice A.6, cuyas salidas se

depositan en el directorio `reports/fe/` del repositorio:

```
make fe-facts    # catálogo de decisiones y selección -> fe_facts.json
make fe-figures  # galería de figuras del preprocesamiento
make fe-report   # reporte ejecutivo bilingüe -> fe_report.pdf
```

La primera orden escribe el catálogo en formato `JSON` con las 9 decisiones de ingeniería de características y las 12 decisiones de limpieza (cada una con su identificador, el módulo de código responsable y su justificación), junto con el resultado de la selección FRESH y mRMR reportado en las secciones 1.2.1 y 1.2.2. De ese archivo salen como macros derivadas las cifras del preprocesamiento que aparecen en la prosa, con el mismo mecanismo del censo exploratorio: una re-derivación de los datos actualiza el texto sin transcripción manual. La segunda orden regenera las figuras de la sección 1.2.2 y la tercera compone un reporte ejecutivo del preprocesamiento en español y en inglés.

Dos salvaguardas adicionales protegen esta etapa. La construcción de la matriz de características está cubierta por una prueba de maestro dorado (*golden master*) que compara la salida byte a byte contra una referencia versionada: cualquier cambio de código que altere la matriz, aunque sea en un solo valor, hace fallar la verificación continua hasta que el cambio se declare deliberado. Y la causalidad del relleno se verifica con pruebas metamórficas automatizadas: mutar observaciones posteriores a un origen de pronóstico no debe alterar ningún insumo construido en ese origen ni antes de él, y la prueba falla si lo hace.

A.10 Guardarraíles automáticos y selección del modelo desplegado

La plataforma incorpora cuatro guardarraíles que se ejecutan en integración continua y **rompen la construcción** ante cualquier desviación (Tabla 35). El guardián de consistencia computa las cifras canónicas del proyecto desde una fuente única de verdad y verifica que el documento entregable, el portal y la documentación declaren *el mismo número*; la prueba de regresión de modelos fija el error de una rejilla determinista y falla si un cambio de código lo degrada; el monitor de *drift* vigila desempeño, cobertura y movimientos sin precedente del último boletín; y la tarjeta de modelo se regenera con su linaje (*commit* de Git y *hash* del panel) para no quedar obsoleta.

Tabla 35: Los cuatro guardarraíles automáticos, su disparador y dónde se ejecutan. Todos actúan como contrato verificable, no como documentación pasiva.

Guardarraíl	Qué verifica	Dónde corre
Consistencia	Toda cifra del documento, portal y docs coincide con la fuente única de verdad	CI + previo a *push*
Regresión de modelos	El error del conjunto reservado de una rejilla fija no se degrada	CI (capa de modelado)
Monitor de *drift*	Desempeño, cobertura y datos del último boletín	Proceso mensual
Tarjeta de modelo	La ficha del sistema no diverge de las cifras canónicas	CI (capa base)

La receta desplegada no se fija a mano: es un **dato versionado** (un manifiesto) que solo cambia mediante un procedimiento verificado de campeón-retador. Este evalúa la receta en producción frente a un conjunto de alternativas sobre el conjunto reservado, mediante una prueba de rangos con signo de Wilcoxon por serie con control del error por comparaciones múltiples, y emite un veredicto: una alternativa solo se recomienda si supera al campeón con significancia y un margen material. El veredicto vigente es el más instructivo del proyecto. En FAD, el retador que cruza el umbral es el **naïve-1** (MASE del conjunto reservado, en **media sobre las series deduplicadas**: 0.140 frente al campeón 0.152, con significancia bajo la prueba y la corrección ya descritas, y margen material). En DFF, el naïve-1 promedia todavía menos error (0.103 frente a 0.121), pero su ventaja no sobrevive a la corrección por comparaciones múltiples, y el único retador apto es la **mediana de SARIMA, ETS y Theta** (0.107). La aptitud retrospectiva no autoriza por sí sola la promoción, que se **retiene** por una decisión de gobernanza documentada: el gate evalúa el pronóstico a un paso y el producto sirve horizontes de 1–12 meses, donde repetir el último valor se degrada, de modo que la decide el gate prospectivo pre-registrado. En su lugar, el procedimiento activó un **despliegue en sombra**: cada mes, el cron congela también la añada del retador en un registro paralelo e inmutable (*shadow ledger*), de modo que la promoción se decidirá con evidencia prospectiva multi-horizonte y no con una extrapolación del gate. La receta campeona (mediana de Theta+ETS+SARIMA en FAD y SARIMA en DFF) permanece desplegada y se aplica por serie; su veredicto campeón-retador se computa sobre el conjunto de series donde los modelos convergen, la misma restricción de comparabilidad por la que la evaluación no lee el promedio global de SARIMA como referencia. Las series de DFF donde SARIMA no converge se **omiten** de la añada de ese mes (no se sirven con un modelo no comparable), una limitación documentada del alcance mensual, no del método. Permanece, además, con su distribución predictiva evaluada (CRPS 41.5/27.9 días como criterio informativo del gate) y con las bandas por horizonte e inferencia conforme adaptativa descritas en la sección 1.4.4. La Figura 43 ilustra cómo el almacén de experimentos registra un veredicto campeón-retador; es una captura histórica, anterior a la reconciliación de octubre, y no muestra el veredicto vigente.

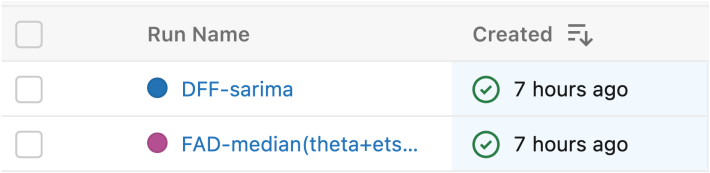


Figura 43: Registro del procedimiento campeón-retador en el almacén de experimentos: las recetas desplegadas para FAD y DFF conservadas como corridas trazables; sus métricas se consultan en el detalle de cada corrida. Captura histórica, anterior a la reconciliación de octubre. Fuente: recorte de la captura de la interfaz de MLflow.

A.11 Integración y entrega continua

Todo lo anterior se ejecuta en integración continua. Un primer flujo valida cada cambio de código (lint, verificación de tipos, suite de pruebas con piso de cobertura, la capa de modelado y el guardián de consistencia); un segundo flujo, disparado al publicarse un boletín nuevo, reconstruye el panel y el almacén de forma incremental, regenera los pronósticos del demostrador (proyectados al cono de coherencia y con sus bandas por horizonte), califica las predicciones previamente congeladas contra los cortes recién realizados, congela en paralelo la añada del retador en sombra, actualiza la tasa de la inferencia conforme adaptativa con los aciertos y fallos del registro, ejecuta el veredicto campeón-retador, actualiza las cifras canónicas y la tarjeta de modelo, ejecuta el monitor de *drift* (que compara ahora mezclas equivalentes de horizontes) y, si todo pasa, redepliega el demostrador. El registro prospectivo es inmutable: la añada 2026-07 corresponde al congelado del 3 de julio con el método de bandas previo, de modo que la primera añada calificada con las bandas por cuantil por horizonte fue la de 2026-09. Cada corte publicable queda además identificado por un manifiesto de *release* con suma de verificación SHA-256 por artefacto. Los descriptores del panel de este documento corresponden a la añada 2026-11 (hash 399cd7b48931); las métricas retrospectivas, a la ventana causal del corte de septiembre de 2026, que los boletines posteriores no modifican. Así, el sistema se mantiene reproducible y verificado. La puesta al día, en cambio, depende de que la fuente siga siendo alcanzable de forma automática: cuando su cortafuegos rechaza al cliente del proceso desatendido, la ingesta del mes pasa a un procedimiento manual gobernado que conserva el congelado inmutable, las sumas de verificación y los mismos gates.

Acerca del autor y del asesor



Javier Augusto Rebull Saucedo

Tesista · MIAAD · UACJ

Estudiante de la Maestría en Inteligencia Artificial y Analítica de Datos (MIAAD) de la Universidad Autónoma de Ciudad Juárez (UACJ), con matrícula 263483. En el ámbito profesional se desempeña como *Sr. Associate Application Developer* en Banco Santander US, con residencia en Boston, Massachusetts, EE. UU. Su interés académico se centra en el modelado predictivo de fenómenos sociales con impacto en comunidades migrantes, combinando técnicas de aprendizaje profundo, series de tiempo y analítica de datos aplicada.

► `al263483@alumnos.uacj.mx`



Dr. Vicente García Jiménez

Director de tesis · UACJ

Profesor-investigador del Departamento de Ingeniería Eléctrica y Computación de la Universidad Autónoma de Ciudad Juárez (UACJ) y miembro del núcleo académico del programa de Maestría en Inteligencia Artificial y Analítica de Datos (MIAAD). Su línea de investigación comprende aprendizaje automático aplicado, clasificación con conjuntos desbalanceados y minería de datos. Como asesor de la presente tesis, orienta el diseño metodológico, el rigor experimental y la coherencia teórica del sistema experimental.

► `vicente.jimenez@uacj.mx`